

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه اصفهان

دانشکده مهندسی کامپیوتر

گروه مهندسی هوش مصنوعی

پایان نامه کارشناسی

رشته مهندسی کامپیوتر گرایش هوش مصنوعی

عنوان پایان نامه

ارزیابی عملکرد مدل های زبانی-بصری مبتنی بر رویکردهای پرامپت نویسی مختلف در حوزه

مسائل استدلالی-ادراکی آکادمیک

استاد راهنما:

دکتر حمیدرضا برادران کاشانی

پژوهشگر:

سیده ثنا سبحانی

زهره مرتضوی

شهریور ۱۴۰۳



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر
گروه مهندسی

پروژه کارشناسی رشته‌ی مهندسی کامپیوتر گرایش
آقای/خانم
تحت عنوان
.....

در تاریخ / / ۱۴ توسط هیأت داوران زیر بررسی و با نمره به تصویب نهایی رسید.

۱- استاد راهنمای پروژه:

امضا

دکتر

۲- استاد داور :

امضا

دکتر

امضای مدیر گروه

تشکر و قدردانی

بر خود لازم می‌دانیم مراتب سپاس و قدردانی خود را از جناب آقای دکتر حمیدرضا برادران کاشانی، استاد راهنمای این پروژه، به سبب همراهی‌ها و راهنمایی‌های ارزشمند ایشان در طول انجام این پژوهش ابراز نماییم و از زمانی که برای هدایت و بررسی مراحل مختلف پروژه اختصاص دادند، صمیمانه قدردانی می‌کنیم.

چکیده:

مدل‌های زبانی-بصری توانایی قابل‌توجهی در پردازش هم‌زمان اطلاعات متنی و تصویری نشان داده‌اند، اما عملکرد مناسب در وظایف عمومی لزوماً به معنای توانایی حل مسائل پیچیده دانشگاهی نیست. این مسائل معمولاً به ترکیبی از ادراک بصری، دانش تخصصی و استدلال چندمرحله‌ای نیاز دارند. هدف این پژوهش، ارزیابی عملکرد مدل‌های زبانی-بصری در مسائل دانشگاهی چندوجهی و بررسی تأثیر راهبردهای مختلف پرامپت‌دهی بر دقت و نوع خطاهای آن‌ها است.

در این پژوهش، هفت مدل زبانی-بصری با معماری‌ها و اندازه‌های متفاوت روی زیرمجموعه‌ای متوازن شامل ۳۰۰ نمونه از ۳۰ موضوع مجموعه داده MMMU-Pro ارزیابی شدند. روش‌های زنجیره استدلال، برنامه‌ریزی و حل، گراف صحنه، تولید دانش و چند روش چندنمونه‌ای بررسی شدند و خطاهای ادراکی، دانشی و استدلالی نیز با داوری انسانی تحلیل شدند.

نتایج نشان دادند که هیچ راهبرد پرامپت‌گذاری واحدی برای همه مدل‌ها و مسائل بهترین نیست و یک روش می‌تواند هم‌زمان برخی انواع خطا را کاهش و برخی دیگر را افزایش دهد. در ادامه، یک روش انتخاب تطبیقی پرامپت بر اساس حوزه علمی سؤال طراحی شد که در ارزیابی مستقل ۵۰۰ نمونه‌ای، دقت Gemma 4 26B را از حدود ۶۰ تا ۶۴ درصد به ۷۰٫۲ درصد افزایش داد.

واژگان کلیدی: مدل‌های بینایی-زبانی، MMMU-Pro، پرامپت‌دهی، استدلال چندوجهی، تحلیل خطا، یادگیری درون‌متنی، انتخاب تطبیقی پرامپت.

۱۱	فصل اول مقدمه
۱۱	۱-۱- هدف پروژه
۱۲	۲-۱- کاربردهای پروژه
۱۳	۳-۱- ساختار پایان نامه
۱۴	فصل دوم مفاهیم
۱۴	۱-۲- مقدمه
۱۴	۲-۲- مدل های تک وجهی و چندوجهی
۱۴	۱-۲-۲- مدل های زبانی
۱۵	۲-۲-۲- مدل های بینایی
۱۵	۳-۲-۲- مدل های چندوجهی
۱۵	۲-۳- مدل های بینایی-زبانی
۱۶	۱-۳-۲- ساختار کلی مدل های بینایی-زبانی
۱۶	۲-۳-۲- مفاهیم معماری مدل های بینایی-زبانی
۱۹	۳-۳-۲- فرایند پردازش ورودی و تولید پاسخ
۱۹	۴-۳-۲- کاربردهای مدل های بینایی-زبانی
۱۹	۵-۳-۲- قابلیت ها و چالش های مدل های بینایی-زبانی
۲۰	۴-۲- استدلال چندوجهی
۲۰	۱-۴-۲- ادراک بصری
۲۰	۲-۴-۲- دانش
۲۰	۳-۴-۲- استدلال
۲۰	۵-۲- روش های پرامپت دهی به مدل های چندوجهی
۲۱	۱-۵-۲- پرامپت دهی بدون نمونه
۲۱	۲-۵-۲- زنجیره استدلال

فهرست مطالب

صفحه

عنوان

۲۱.....	۳-۵-۲- پرامپت‌دهی چندنمونه‌ای
۲۱.....	۴-۵-۲- انتخاب نمونه‌های نمایشی
۲۱.....	۵-۵-۲- پرامپت‌دهی ساختاریافته و چندمرحله‌ای
۲۱.....	۶-۲- ارزیابی مدل‌های زبانی-بصری و بنچمارک‌های چندوجهی
۲۲.....	۱-۶-۲- ویژگی‌های بنچمارک‌های چندوجهی
۲۲.....	۲-۶-۲- بنچمارک‌های دانشگاهی و چندرشته‌ای
۲۲.....	۲-۶-۳- پرسش‌های چندگزینه‌ای و معیار دقت
۲۲.....	۷-۲- تحلیل خطا در مدل‌های بینایی-زبانی
۲۳.....	۱-۷-۲- خطای ادراکی
۲۳.....	۲-۷-۲- خطای استدلالی
۲۳.....	۳-۷-۲- خطای دانشی
۲۳.....	۸-۲- ارزیابی مبتنی بر مدل و مدل به‌عنوان داور
۲۴.....	۱-۸-۲- داوری در مسائل چندوجهی
۲۴.....	۲-۸-۲- مزایا و محدودیت‌ها
۲۴.....	۹-۲- ارزیابی انسانی
۲۵.....	۱۰-۲- اهمیت ارزیابی مدل‌های زبانی-بصری در مسائل دانشگاهی چندرشته‌ای
۲۵.....	۱۱-۲- جمع‌بندی
۲۶.....	فصل سوم شرح پروژه
۲۶.....	۱-۳- مقدمه
۲۷.....	۲-۳- مجموعه داده و ساخت مجموعه ارزیابی
۲۷.....	۱-۲-۳- معرفی MMMU و دلیل انتخاب MMMU-Pro
۲۸.....	۲-۲-۳- تفاوت حالت (10 options) Standard با MMMU
۲۹.....	۳-۲-۳- ساخت زیرمجموعه ۳۰۰ نمونه‌ای
۳۰.....	۳-۳- مدل‌های زبانی-بصری مورد ارزیابی
۳۰.....	۱-۳-۳- معیارهای انتخاب مدل‌ها
۳۱.....	۲-۳-۳- Gemma 4 26B-A4B

فهرست مطالب

صفحه

عنوان

۳۱.....	Gemma 4 31B ۳-۳-۳
۳۲.....	InternVL3.5-8B ۴-۳-۳
۳۲.....	NVIDIA Nemotron 3 Nano Omni -۵-۳-۳
۳۳.....	Qwen3.8-27B -۶-۳-۳
۳۳.....	Qwen3.5-9B -۷-۳-۳
۳۴.....	Qwen3-VL-30B-A3B-Instruct -۸-۳-۳
۳۴.....	۹-۳-۳ تنظیمات مشترک استنتاج
۳۵.....	۴-۳ ساخت داده‌های کمکی برای روش‌های چندنمونه‌ای و تولید دانش
۳۵.....	۱-۴-۳ ستون Explanation و کاربرد آن
۳۵.....	۲-۴-۳ انتخاب اولیه نمونه‌ها با اولویت Explanation
۳۶.....	۳-۴-۳ تولید زنجیره استدلال با Gemma 4 31B
۳۷.....	۴-۴-۳ اعتبارسنجی زنجیره استدلال با استفاده از Explanation
۳۸.....	۵-۴-۳ تشکیل بانک نهایی ۴۰۵ نمونه‌ای
۳۹.....	۶-۴-۳ ساخت بانک دانش
۴۰.....	۷-۴-۳ ساخت بازنمایی‌های برداری
۴۰.....	۵-۳ روش‌های پرامپت‌دهی
۴۰.....	۱-۵-۳ معیار انتخاب روش‌های پرامپت‌دهی
۴۱.....	۲-۵-۳ روش‌های بدون نمونه
۴۱.....	۳-۵-۳ حالت پایه
۴۲.....	۴-۵-۳ زنجیره استدلال بدون نمونه
۴۲.....	۵-۵-۳ Plan-and-Solve
۴۳.....	۶-۵-۳ زنجیره استدلال ترکیبی و گراف صحنه
۴۴.....	۷-۵-۳ تولید دانش
۴۵.....	۸-۵-۳ روش‌های چندنمونه‌ای و یادگیری درون‌متنی
۴۶.....	۹-۵-۳ سه‌نمونه‌ای تصادفی بدون زنجیره استدلال
۴۷.....	۱۰-۵-۳ چندنمونه‌ای مبتنی بر شباهت بدون زنجیره استدلال

فهرست مطالب

صفحه

عنوان

۴۸.....	۳-۵-۱۱- چند نمونه‌ای مبتنی بر شباهت همراه زنجیره استدلال
۴۹.....	۳-۵-۱۲- انتخاب نمونه بر اساس پیچیدگی زنجیره استدلال
۵۰.....	۳-۶-۶- پروتکل اجرا و استخراج پاسخ
۵۰.....	۳-۶-۱- محیط اجرای آزمایش‌ها
۵۰.....	۳-۶-۲- حفظ ترتیب تصاویر
۵۰.....	۳-۶-۳- ضرورت طراحی استخراج‌گر پاسخ
۵۱.....	۳-۶-۴- فضای پویا برای گزینه‌های پاسخ
۵۱.....	۳-۶-۵- قالب پاسخ نهایی
۵۲.....	۳-۶-۶- استخراج پاسخ از آخرین خط
۵۲.....	۳-۶-۷- عدم حدس پاسخ از متن استدلال
۵۲.....	۳-۶-۸- پاسخ‌های ناقص و پایان ناشی از محدودیت طول
۵۳.....	۳-۶-۹- عدم استفاده از انتخاب تصادفی جایگزین
۵۳.....	۳-۶-۱۰- تفکیک استخراج پاسخ از رعایت دقیق قالب
۵۳.....	۳-۶-۱۱- مستقل بودن استخراج‌گر از پاسخ صحیح
۵۴.....	۳-۶-۱۲- ثابت بودن استخراج‌گر میان تمام روش‌ها
۵۴.....	۳-۶-۱۳- جداسازی خطای قالب از خطای محتوایی
۵۴.....	۳-۶-۱۴- کنترل نسخه‌ها و بازتولیدپذیری
۵۵.....	۳-۷-۷- بررسی امکان استفاده از مدل داور برای تشخیص نوع خطا
۵۵.....	۳-۷-۱- انگیزه و هدف آزمایش
۵۵.....	۳-۷-۲- انتخاب انواع خطا و ساخت مجموعه ارزیابی
۵۶.....	۳-۷-۳- ارزیابی LLaVA-Critic-7B به عنوان مدل داور
۵۸.....	۳-۷-۴- استفاده از Gemma 4 31B به عنوان مدل داور
۵۹.....	۳-۷-۵- نتایج Gemma 4 31B در تشخیص نوع خطا
۶۱.....	۳-۷-۶- مقایسه دو رویکرد داوری خودکار
۶۲.....	۳-۸-۸- انتخاب تحلیل انسانی به عنوان روش نهایی
۶۲.....	۳-۸-۱- انتخاب تحلیل انسانی و تعیین دامنه بررسی

فهرست مطالب

صفحه

عنوان

۶۳	۳-۸-۲- دسته‌های خطا و تدوین دستورالعمل عملیاتی
۶۴	۳-۸-۳- بررسی ارتباط خطا با پاسخ نهایی
۶۴	۳-۸-۴- دآوری مستقل توسط دو ارزیاب
۶۵	۳-۸-۵- مدیریت موارد مبهم و پاسخ‌های دارای چند خطا
۶۵	۳-۸-۶- حل اختلاف و تعیین برجسب انسانی نهایی
۶۶	۳-۸-۷- حل اختلاف و تعیین برجسب انسانی نهایی
۶۷	۳-۹-۹- طراحی سامانه انتخاب تطبیقی روش پرامپت
۶۷	۳-۹-۱- انگیزه طراحی
۶۷	۳-۹-۲- بررسی دو سطح موضوع و حوزه
۶۸	۳-۹-۳- قاعده انتخاب روش پرامپت‌دهی برای هر حوزه
۶۹	۳-۹-۴- تشکیل مجموعه مستقل برای ارزیابی روش
۶۹	۳-۹-۵- طبقه‌بند چندوجهی حوزه
۶۹	۳-۹-۶- آماده‌سازی داده و جلوگیری از هم‌پوشانی
۷۰	۳-۹-۷- تنظیم مدل
۷۰	۳-۹-۸- اتصال طبقه‌بند به مسیر یاب و مدل پاسخ‌دهنده
۷۱	۳-۹-۹- پیاده‌سازی نهایی سامانه
۷۲	۳-۱۰- جمع‌بندی
۷۳	فصل چهارم نتایج
۷۳	۴-۱- مقدمه
۷۳	۴-۲- ارزیابی عملکرد مدل‌های زبانی-بصری در شرایط خط پایه
۷۴	۴-۲-۱- عملکرد Gemma 4 31B
۷۴	۴-۲-۲- عملکرد Gemma 4 26B
۷۴	۴-۲-۳- عملکرد Qwen3.8-27B
۷۵	۴-۲-۴- عملکرد Qwen3.5-9B
۷۵	۴-۲-۵- عملکرد Qwen3-VL-30B-A3B
۷۵	۴-۲-۶- عملکرد InternVL3.5-8B

فهرست مطالب

صفحه

عنوان

۷۶	۷-۲-۴ عملکرد Nemotron 3 Nano Omni
۷۶	۸-۲-۴ مقایسه تطبیقی عملکرد پایه مدل‌ها
۷۸	۳-۴ تحلیل عملکرد مدل‌ها بر اساس ویژگی‌های مجموعه داده
۷۸	۱-۳-۴ حوزه علمی
۷۹	۲-۳-۴ موضوع
۸۰	۳-۳-۴ سطح دشواری
۸۱	۴-۳-۴ نوع محتوای بصری
۸۲	۴-۴ ارزیابی روش‌های پرآمپت‌دهی
۸۲	۱-۴-۴ زنجیره استدلال بدون نمونه
۸۳	۲-۴-۴ گراف صحنه
۸۴	۳-۴-۴ روش برنامه‌ریزی و حل
۸۵	۴-۴-۴ تولید دانش
۸۶	۵-۴-۴ روش سه‌نمونه‌ای با انتخاب تصادفی
۸۶	۶-۴-۴ روش سه‌نمونه‌ای مبتنی بر شباهت بدون زنجیره استدلال
۸۷	۷-۴-۴ روش سه‌نمونه‌ای مبتنی بر شباهت همراه با زنجیره استدلال
۸۸	۸-۴-۴ روش سه‌نمونه‌ای مبتنی بر پیچیدگی استدلال
۸۸	۵-۴ تحلیل اثر روش‌های پرآمپت‌دهی بر حوزه علمی و ویژگی‌های بصری
۸۹	۱-۵-۴ تحلیل حوزه‌ای اثر روش‌های پرآمپت‌دهی
۹۲	۲-۵-۴ تحلیل اثر روش‌های پرآمپت‌دهی بر اساس ویژگی‌های تصویر
۹۴	۳-۵-۴ جمع‌بندی تحلیل بر اساس ویژگی مسئله
۹۴	۶-۴ تحلیل نوع خطا مبتنی بر برچسب‌گذاری انسانی
۹۴	۱-۶-۴ تحلیل نوع خطا در Gemma 4 26B
۹۶	۲-۶-۴ تحلیل نوع خطا در InternVL3.5-8B
۹۸	۳-۶-۴ مقایسه الگوی خطا در Gemma 4 26B و InternVL3.5-8B
۹۸	۷-۴ مقایسه جامع روش‌های پرآمپت‌دهی
۹۹	۱-۷-۴ رابطه هزینه و عملکرد

فهرست مطالب

صفحه

عنوان

۱۰۰	۴-۷-۲- جمع‌بندی مقایسه روش‌ها
۱۰۱	۴-۸-۸- ارزیابی روش انتخاب تطبیقی پرامپت
۱۰۱	۴-۸-۱- مقایسه انتخاب روش در سطح موضوع و حوزه
۱۰۳	۴-۷-۲- روش‌های دارای بیشترین دقت در هر حوزه
۱۰۳	۴-۸-۳- حل تساوی میان روش‌های برتر
۱۰۴	۴-۸-۴- ارزیابی طبقه‌بند حوزه
۱۰۵	۴-۸-۵- ارزیابی سیاست مسیریابی روی مجموعه مستقل
۱۰۵	۴-۸-۶- ارزیابی پاسخ مستقیم
۱۰۵	۴-۸-۷- مقایسه عملکرد و هزینه در روش انتخاب تطبیقی پرامپت
۱۰۷	۴-۹-۹- جمع‌بندی
۱۰۸	فصل پنجم نتیجه‌گیری و پیشنهادات
۱۰۸	۵-۱- نتیجه‌گیری
۱۱۱	۲-۵- محدودیت‌ها
۱۱۱	۵-۳- پیشنهادات برای ادامه پژوهش
۱۱۳	منابع:
۱۱۵	پیوست ۱: لیست برنامه‌ها

فهرست شکل‌ها و جدول‌ها

عنوان	صفحه
جدول ۱-۳: دقت مدل LLaVA-Critic-7B در تفکیک منشأ خطا.....	۵۸
جدول ۲-۳: دقت مدل Gemma 4 31B در تفکیک منشأ خطا.....	۶۰
جدول ۳-۳: ماتریس درهم‌ریختگی نتایج تفکیک خطا توسط Gemma4 31B.....	۶۰
جدول ۴-۳: قواعدتصمیم‌گیری در تحلیل خطا.....	۶۳
جدول ۱-۴: مقایسه‌ی عملکرد مدل‌ها در شرایط خط پایه.....	۷۷
جدول ۲-۴: میزان تاثیر روش‌های مختلف پرامپت‌دهی بر عملکرد مدل‌ها.....	۸۲
جدول ۳-۴: عملکرد روش زنجیره‌ی استدلال بدون نمونه در چهار مدل.....	۸۲
جدول ۴-۴: عملکرد روش گراف صحنه در چهار مدل.....	۸۳
جدول ۵-۴: عملکرد روش برنامه‌ریزی و حل در چهار مدل.....	۸۴
جدول ۶-۴: عملکرد روش تولید دانش در دو مدل.....	۸۵
جدول ۷-۴: عملکرد روش سه‌نمونه‌ای با انتخاب تصادفی در چهار مدل.....	۸۶
جدول ۸-۴: عملکرد روش سه نمونه‌ای مبتنی بر شباهت بدون زنجیره استدلال در چهار مدل.....	۸۶
جدول ۹-۴: عملکرد روش سه نمونه‌ای مبتنی بر شباهت همراه با زنجیره استدلال در چهار مدل.....	۸۷
جدول ۱۰-۴: عملکرد روش سه نمونه‌ای مبتنی بر پیچیدگی در چهار مدل.....	۸۸
جدول ۱۱-۴: الگوهای مشترک حوزه‌ای میان مدل‌ها.....	۹۲
جدول ۱۳-۴: تراز خالص انواع خطا در Gemma 4 26B.....	۹۵
جدول ۱۴-۴: تراز خالص انواع خطا در InternVL3.5-8B.....	۹۶
جدول ۱۵-۴: بهترین روش مشاهده شده برای هر مدل.....	۹۹
جدول ۱۶-۴: دقت روش انتخاب تطبیقی پرامپت در سطح حوزه برای مدل Gemma426B-A4B.....	۱۰۱
جدول ۱۷-۴: دقت حاصل از روش انتخاب تطبیقی پرامپت در سطح موضوع برای مدل Gemma 4 26B-.....	۱۰۲
A4B	
جدول ۱۸-۴: روش‌های دارای بیشترین دقت در هر حوزه برای مدل Gemma 4 26B-A4B.....	۱۰۳
جدول ۱۹-۴: سیاست نهایی انتخاب پرامپت در سطح حوزه برای مدل Gemma 4 26B-A4B.....	۱۰۴
جدول ۲۰-۴: دقت مدل Gemma 4 26B-A4B در شرایط خط پایه روی ۵۰۰ نمونه.....	۱۰۵
جدول ۲۱-۴: مقایسه‌ی عملکرد و هزینه در روش انتخاب تطبیقی پرامپت برای مدل Gemma 4 26B-.....	۱۰۶
A4B	

فهرست شکل‌ها و جدول‌ها

صفحه

عنوان

۲۸.....	شکل ۳-۱: داده‌ای از دیتاست mmmu-pro
۳۸.....	شکل ۳-۲: نمونه‌ای از زنجیره‌ی استدلال تولید شده توسط Gemma4 31B
۳۹.....	شکل ۳-۳: مراحل تولید زنجیره‌ی استدلال برای دیتاست کمکی توسط Gemma4 31B
۴۴.....	شکل ۳-۴: نمونه‌ای از مراحل پرامپت گراف صحنه
۶۶.....	شکل ۳-۵: مراحل برچسب‌گذاری انسانی برای تحلیل نوع خطا
۷۱.....	شکل ۳-۶: خط لوله‌ی طراحی سامانه انتخاب تطبیقی روش پرامپت‌دهی
۷۸.....	شکل ۴-۱: دقت مدل‌ها در شرایط خط پایه
۷۹.....	شکل ۴-۲: مقایسه‌ی دقت مدل‌ها در شرایط خط پایه در سطح حوزه‌ی علمی
۸۰.....	شکل ۴-۳: مقایسه‌ی دقت مدل‌ها در شرایط خط پایه در سطح موضوع
۸۱.....	شکل ۴-۴: عملکرد مدل‌ها در سطوح دشواری مختلف در شرایط خط پایه
۸۱.....	شکل ۴-۵: مقایسه‌ی عملکرد مدل‌ها در شرایط خط پایه برای انواع محتواهای بصری
۸۹.....	شکل ۴-۶: اثر روش‌های پرامپت‌دهی در سطح حوزه‌ی علمی در مدل Gemma4 26B
۹۰.....	شکل ۴-۷: اثر روش‌های پرامپت‌دهی در سطح حوزه‌ی علمی در مدل Qwen3.5-9B
۹۰.....	شکل ۴-۸: اثر روش‌های پرامپت‌دهی در سطح حوزه‌ی علمی در مدل InternVL3.5-8B
۹۱.....	شکل ۴-۹: اثر روش‌های پرامپت‌دهی در سطح حوزه‌ی علمی در مدل Nemotron3 Nano Omni
۹۶.....	شکل ۴-۱۰: تراز خالص انواع خطا در Gemma 4 26B
۹۸.....	شکل ۴-۱۱: تراز خالص انواع خطا در InternVL3.5-8B
۱۰۰.....	شکل ۴-۱۲: رابطه‌ی هزینه و عملکرد روش‌های پرامپت‌دهی در مدل‌های مختلف

مخفف	عبارت کامل
API	Application Programming Interface
BLIP-2	Bootstrapping Language-Image Pre-training 2
CCoT	Compositional Chain-of-Thought
CLIP	Contrastive Language-Image Pre-training
CoT	Chain-of-Thought
F1	F1 Score
GGUF	GPT-Generated Unified Format
GKP	Generated Knowledge Prompting
GPU	Graphics Processing Unit
GPT	Generative Pre-trained Transformer
IT	Instruction-Tuned
JSON	JavaScript Object Notation
KDE	Knowledge Deployment Error
LLaVA	Large Language and Vision Assistant
LMM	Large Multimodal Model
LoRA	Low-Rank Adaptation
MCC	Matthews Correlation Coefficient
MMErrorR	A Benchmark for Erroneous Reasoning in Vision-Language Models
MMMU	Massive Multi-discipline Multimodal Understanding and Reasoning
MMMU-Pro	MMMU-Pro: A More Robust Multimodal Understanding Benchmark
MoE	Mixture of Experts
OCR	Optical Character Recognition
Q-Former	Querying Transformer
QLoRA	Quantized Low-Rank Adaptation
RE	Reasoning Error
RICES	Retrieval-based In-Context Example Selection
SHA-256	Secure Hash Algorithm 256-bit
ViT	Vision Transformer
VISCO	Benchmarking Fine-Grained Critique and Correction Towards Self-Improvement in Visual Reasoning
VLM	Vision-Language Model
VPE	Visual Perception Error

فصل اول

مقدمه

۱-۱- هدف پروژه

مدل‌های زبانی-بصری^۱ در سال‌های اخیر توانایی قابل‌توجهی در پردازش هم‌زمان متن و تصویر به دست آورده‌اند. با این حال، عملکرد مناسب در مسائل عمومی لزوماً به معنای توانایی حل مسائل تخصصی و دانشگاهی نیست. در چنین مسائلی، مدل ممکن است برای رسیدن به پاسخ صحیح ناچار باشد اطلاعات مورد نیاز را از تصویر استخراج کند، دانش تخصصی مرتبط را به کار گیرد و چند مرحله استدلال یا محاسبه را به‌درستی انجام دهد. در نتیجه، یک پاسخ نادرست می‌تواند از ضعف در هر یک از این مراحل ناشی شود. به همین دلیل، گزارش دقت نهایی به‌تنهایی برای شناخت رفتار مدل کافی نیست و لازم است مشخص شود مدل در چه نوع مسائلی موفق یا ناموفق است و منشأ خطاهای آن چیست.

از سوی دیگر، نحوه ارائه مسئله به مدل نیز می‌تواند بر پاسخ آن اثر بگذارد. در بسیاری از کاربردها امکان آموزش مجدد یا تغییر وزن‌های یک مدل بزرگ وجود ندارد، اما می‌توان از طریق طراحی پرامپت، نحوه حل مسئله را هدایت کرد. مسئله مهم این است که چنین روش‌هایی تا چه اندازه واقعاً مفید هستند. پیچیده‌تر کردن پرامپت یا افزودن مثال و استدلال بیشتر الزاماً به پاسخ بهتر منجر نمی‌شود و تأثیر یک روش می‌تواند با مدل، حوزه علمی و ویژگی‌های خود سؤال تغییر کند. بنابراین، مقایسه روش‌های پرامپت‌دهی تنها بر اساس یک مدل یا یک مقدار دقت کلی، برای نتیجه‌گیری درباره کارایی آن‌ها کافی نیست.

هدف اصلی این پژوهش، بررسی عملکرد مدل‌های زبانی-بصری در مسائل دانشگاهی چندوجهی و مطالعه این موضوع است که آیا می‌توان بدون تغییر وزن‌های مدل و صرفاً از طریق تغییر نحوه ارائه مسئله، عملکرد آن‌ها را بهبود داد یا خیر. برای پاسخ به این پرسش، مسئله تنها از دید دقت نهایی بررسی نمی‌شود، بلکه سه جنبه مکمل در کنار یکدیگر مورد مطالعه قرار می‌گیرند: توانایی اولیه مدل‌های مختلف در حل مسائل دانشگاهی

^۱ Vision-Language Models

چند رشته‌ای، میزان و جهت تأثیر روش‌های مختلف پرامپت‌دهی و نوع خطاهایی که در اثر استفاده از این روش‌ها اصلاح یا ایجاد می‌شوند. به این ترتیب، اثر پرامپت‌دهی نه صرفاً به شکل تغییر یک عدد در دقت، بلکه به عنوان تغییری در رفتار حل مسئله مدل بررسی می‌شود.

در نهایت، تفاوت مشاهده‌شده در اثر روش‌های پرامپت‌دهی، مسئله دیگری را مطرح می‌کند: اگر یک پرامپت برای همه سؤالات بهترین نیست، آیا می‌توان پیش از حل هر مسئله، روش مناسب‌تری برای آن انتخاب کرد؟ بر همین اساس، در بخش پایانی پروژه یک سامانه انتخاب تطبیقی روش پرامپت طراحی شده است. این سامانه ابتدا حوزه علمی مسئله را تشخیص می‌دهد و سپس بر اساس سیاستی که از نتایج آزمایش‌ها استخراج شده است، روش مناسب را انتخاب می‌کند. برای آن‌که این فرایند به برجسته‌ترین حوزه موجود در بنچمارک وابسته نباشد، یک طبقه‌بند چندوجهی نیز برای تشخیص حوزه تنظیم شده و اجزای طبقه‌بندی، مسیریابی، بازیابی نمونه، اجرای پرامپت و استخراج پاسخ در یک خط لوله واحد ترکیب شده‌اند.

۱-۲- کاربردهای پروژه

ارزیابی و مقایسه مدل‌های بینایی-زبانی: این چارچوب برای پژوهشگرانی که قصد مقایسه مدل‌های زبانی-بصری را دارند، امکان ارزیابی مدل‌های مختلف در یک شرایط کنترل‌شده و بررسی عملکرد آن‌ها فراتر از یک مقدار دقت کلی را فراهم می‌کند. تفکیک نتایج بر اساس حوزه علمی، دشواری و نوع محتوای بصری می‌تواند نشان دهد یک مدل در چه نوع مسائلی قابل اتکاتر است و در چه شرایطی با ضعف بیشتری مواجه می‌شود.

انتخاب و طراحی روش پرامپت: نتایج پژوهش می‌تواند برای انتخاب آگاهانه‌تر روش هدایت مدل استفاده شود. به جای فرض اینکه روش‌هایی مانند زنجیره استدلال، نمونه‌های مشابه یا برنامه‌ریزی همیشه موجب بهبود می‌شوند، می‌توان اثر آن‌ها را برای مدل و مسئله مورد نظر در نظر گرفت. این موضوع در کاربردهایی که هزینه استنتاج اهمیت دارد نیز مفید است؛ زیرا روش‌های پیچیده‌تر معمولاً زمینه طولانی‌تر یا تعداد فراخوانی بیشتری نیاز دارند و در صورت نبود بهبود، این هزینه توجیهی نخواهد داشت.

تحلیل نوع خطا: در این پژوهش، خطاهای ادراکی، دانشی و استدلالی در نمونه‌هایی بررسی می‌شوند که پاسخ مدل در اثر تغییر روش پرامپت نسبت به خط پایه تغییر کرده است. این تحلیل کمک می‌کند مشخص شود یک روش پرامپت‌دهی در نمونه‌های تغییر کرده، بیشتر موجب اصلاح یا ایجاد کدام نوع خطا شده است. به این ترتیب، اثر هر روش تنها بر اساس تغییر دقت نهایی سنجیده نمی‌شود، بلکه می‌توان بررسی کرد بهبود یا افت مشاهده‌شده بیشتر به تغییر در کدام بخش از فرایند حل مسئله مربوط بوده است.

انتخاب تطبیقی روش پرامپت: از منظر عملی، سامانه انتخاب تطبیقی روش پرامپت نیز می‌تواند الگویی برای سامانه‌هایی باشد که به جای اجرای یک دستور ثابت برای همه ورودی‌ها، ابتدا ویژگی‌های مسئله را تشخیص داده و سپس شیوه مناسب پاسخ‌گویی را انتخاب می‌کنند. مزیت این دیدگاه آن است که برای هر سؤال نیازی

به اجرای تمام روش‌های موجود و انتخاب بهترین پاسخ پس از آن نیست؛ بلکه تلاش می‌شود پیش از استنتاج، روش مناسب تعیین شود. ساختار نهایی پروژه نیز اجزای طبقه‌بندی، انتخاب روش، بازیابی نمونه و تولید پاسخ را در قالب یک رابط یکپارچه در اختیار قرار می‌دهد.

در نهایت، اجزای پیاده‌سازی شده در پروژه، از جمله مجموعه ارزیابی ثابت، بانک نمونه‌های نمایشی ساخته شده، بازنمایی‌های چندوجهی، استخراج‌گر پاسخ و سازوکارهای ثبت و کنترل اجرا، می‌توانند برای توسعه آزمایش‌های بعدی نیز مورد استفاده قرار گیرند. به همین دلیل، کاربرد پروژه تنها به نتایج گزارش شده در این پایان‌نامه محدود نیست و می‌تواند به‌عنوان مبنایی برای ارزیابی مدل‌ها یا روش‌های جدید در مسائل دانشگاهی چندوجهی به کار رود.

۱-۳- ساختار پایان‌نامه

این پایان‌نامه در پنج فصل تنظیم شده است. در این فصل به معرفی کلی مسئله، اهداف، ارزش و کاربردهای پژوهش اختصاص پرداخته شد و دیدی کلی از مسیر پروژه ارائه شد.

در فصل دوم مفاهیم نظری مورد نیاز برای دنبال کردن پژوهش معرفی می‌شوند. این فصل برای خواننده‌ای که با مدل‌های بینایی-زبانی، معماری‌های متراکم و MOE، استدلال چندوجهی، روش‌های پرامپت‌دهی، بنچمارک‌های چندوجهی، تحلیل خطا و مفهوم مدل به‌عنوان داور آشنایی کافی ندارد، زمینه لازم را فراهم می‌کند. بنابراین، خواننده‌ای که بیشتر به مبانی و مفاهیم مورد استفاده در پژوهش علاقه‌مند است می‌تواند به این فصل مراجعه کند.

فصل سوم روش‌شناسی و پیاده‌سازی پروژه را تشریح می‌کند. در این فصل نحوه انتخاب مجموعه داده و ساخت مجموعه ارزیابی، مدل‌های مورد بررسی و تنظیمات اجرا، ساخت بانک‌های کمکی، پیاده‌سازی روش‌های پرامپت‌دهی، پروتکل ارزیابی و استخراج پاسخ، روش تحلیل خطا و فرایند طراحی سامانه انتخاب تطبیقی روش پرامپت توضیح داده می‌شوند. این فصل برای خواننده‌ای که قصد بررسی دقیق نحوه انجام آزمایش‌ها یا بازتولید روش پژوهش را دارد، مهم‌ترین بخش گزارش است.

در فصل چهارم نتایج آزمایش‌ها ارائه و تحلیل می‌شوند. ابتدا عملکرد پایه مدل‌ها و تأثیر ویژگی‌های مسئله بر نتایج بررسی شده و سپس اثر روش‌های مختلف پرامپت‌دهی مقایسه می‌شود. تحلیل تغییر انواع خطا، بررسی هزینه روش‌ها و نتایج سامانه انتخاب تطبیقی نیز در همین فصل ارائه می‌شوند. بنابراین، خواننده‌ای که عمدتاً به یافته‌های تجربی و مقایسه مدل‌ها و روش‌ها علاقه‌مند است می‌تواند مستقیماً به این فصل مراجعه کند.

در نهایت، فصل پنجم مهم‌ترین یافته‌های پژوهش را در کنار یکدیگر جمع‌بندی می‌کند، محدودیت‌های آزمایش‌ها را بیان می‌کند و مسیرهای مناسب برای ادامه کار را پیشنهاد می‌دهد. این فصل برای دستیابی به تصویری فشرده از نتیجه نهایی پژوهش و فرصت‌های توسعه آن مناسب است.

فصل دوم

مفاهیم

۲-۱- مقدمه

در این فصل، مفاهیم اصلی مورد نیاز برای بررسی مدل‌های زبانی-بصری معرفی می‌شوند. ابتدا تفاوت میان مدل‌های تک‌وجهی و چندوجهی بیان شده و سپس ساختار کلی مدل‌های زبانی-بصری و مهم‌ترین مفاهیم معماری آن‌ها بررسی می‌شود. در ادامه، مفهوم استدلال چندوجهی، روش‌های پرامپت‌دهی، اصول ارزیابی و تحلیل خطا توضیح داده می‌شوند. استفاده از مدل‌های زبانی و زبانی-بصری به‌عنوان داور و همچنین داوری انسانی معرفی شده و در پایان، اهمیت ارزیابی این مدل‌ها در مسائل دانشگاهی چندرشته‌ای مورد بحث قرار می‌گیرد.

۲-۲- مدل‌های تک‌وجهی و چندوجهی

مدل‌های یادگیری را می‌توان از نظر نوع اطلاعاتی که دریافت و پردازش می‌کنند به دو گروه کلی تک‌وجهی و چندوجهی تقسیم کرد. مدل تک‌وجهی برای کار با یک نوع داده، مانند متن، تصویر یا صوت طراحی شده است؛ در حالی که مدل چندوجهی می‌تواند اطلاعات حاصل از چند نوع داده را در یک چارچوب مشترک پردازش کند.

اهمیت مدل‌های چندوجهی از آنجا ناشی می‌شود که بسیاری از مسائل واقعی تنها بر پایه یک نوع داده قابل حل نیستند. برای مثال، در یک سؤال علمی ممکن است متن پرسش، اطلاعات لازم برای تعیین مسئله را فراهم کند، در حالی که مقادیر مورد نیاز برای حل آن تنها در یک نمودار یا شکل وجود داشته باشند. در چنین شرایطی، مدل باید بتواند اطلاعات متنی و بصری را به‌صورت مرتبط با یکدیگر پردازش کند.

۲-۲-۱- مدل‌های زبانی

مدل‌های زبانی بزرگ با آموزش بر حجم گسترده‌ای از داده‌های متنی، توانایی‌هایی مانند تولید متن،

پاسخ‌گویی به پرسش، خلاصه‌سازی و انجام برخی استدلال‌های زبانی را به دست می‌آورند. این مدل‌ها می‌توانند از دانش آموخته‌شده در فرایند پیش‌آموزش برای انجام طیف وسیعی از وظایف استفاده کنند. با این حال، یک مدل صرفاً زبانی دسترسی مستقیمی به محتوای تصویر ندارد. بنابراین، اگر اطلاعات مورد نیاز برای پاسخ تنها در یک نمودار، تصویر یا دیاگرام وجود داشته باشد، مدل زبانی بدون دریافت توصیفی متنی از آن نمی‌تواند مستقیماً از این اطلاعات استفاده کند.

۲-۲-۲- مدل‌های بینایی

مدل‌های بینایی برای استخراج و تحلیل اطلاعات موجود در تصاویر طراحی شده‌اند. دسته‌بندی تصویر، تشخیص اشیاء، قطعه‌بندی و استخراج ویژگی‌های بصری از جمله کاربردهای این مدل‌ها هستند. اگرچه مدل‌های بینایی در پردازش ساختار بصری توانمند هستند، معمولاً به‌تنهایی برای فهم دستورهای زبانی پیچیده، استفاده از دانش گسترده یا تولید پاسخ متنی آزاد طراحی نشده‌اند. این محدودیت، یکی از دلایل توسعه سامانه‌هایی است که توانایی‌های بینایی و زبان را در کنار یکدیگر قرار می‌دهند.

۲-۲-۳- مدل‌های چندوجهی

مدل‌های چندوجهی برای پردازش بیش از یک نوع داده طراحی می‌شوند. هدف این مدل‌ها صرفاً دریافت چند ورودی مختلف نیست، بلکه باید بتوانند میان اطلاعات حاصل از این ورودی‌ها ارتباط برقرار کنند. برای مثال، در یک سامانه متن-تصویر، تشخیص یک شیء در تصویر به‌تنهایی کافی نیست؛ مدل باید بتواند تشخیص دهد که کدام بخش از تصویر با پرسش مرتبط است و چگونه اطلاعات استخراج‌شده را در پاسخ به آن پرسش به کار گیرد. از مهم‌ترین انواع مدل‌های چندوجهی می‌توان به **مدل‌های زبانی-بصری** اشاره کرد که محور اصلی این پژوهش را تشکیل می‌دهند.

۲-۳- مدل‌های زبانی-بصری

مدل‌های زبانی-بصری یا **VLMs**^۱ دسته‌ای از مدل‌های چندوجهی هستند که برای پردازش هم‌زمان اطلاعات تصویری و زبانی توسعه یافته‌اند. این مدل‌ها می‌توانند یک یا چند تصویر را در کنار متن دریافت کرده و بر اساس اطلاعات حاصل از هر دو وجه، پاسخ تولید کنند. در چنین سامانه‌هایی، پردازش تصویر معمولاً توسط یک بخش بینایی انجام می‌شود و اطلاعات استخراج‌شده به شکلی مناسب در اختیار بخش زبانی قرار می‌گیرد. مدل زبانی سپس با در نظر گرفتن پرسش

^۱Vision-Language Models

و اطلاعات بصری، پاسخ را تولید می‌کند. معماری‌هایی مانند [۱] Flamingo، [۲] BLIP-2 و LLaVA² نمونه‌هایی از روش‌های متفاوت برای ایجاد این ارتباط میان تصویر و زبان هستند.

۲-۳-۱- ساختار کلی مدل‌های بینایی-زبانی

با وجود تفاوت‌های معماری، بسیاری از مدل‌های زبانی-بصری را می‌توان به صورت کلی متشکل از سه بخش در نظر گرفت:

کدگذار بینایی → بخش اتصال چندوجهی → مدل زبانی

کدگذار بینایی وظیفه استخراج ویژگی‌های مورد نیاز از تصویر را بر عهده دارد. خروجی این بخش معمولاً مجموعه‌ای از بردارهای عددی است که محتوای بصری تصویر را نمایش می‌دهند.

بخش اتصال چندوجهی ویژگی‌های تصویری را به قالبی تبدیل می‌کند که مدل زبانی بتواند آن‌ها را پردازش کند. ساختار این بخش در مدل‌های مختلف متفاوت است و می‌تواند از یک نگاشت ساده تا معماری‌های پیچیده‌تر مبتنی بر توجه متغیر باشد.

در نهایت، **مدل زبانی** اطلاعات متنی و بصری را در کنار یکدیگر پردازش کرده و پاسخ را تولید می‌کند.

۲-۳-۲- مفاهیم معماری مدل‌های بینایی-زبانی

مدل‌های مورد استفاده در سامانه‌های چندوجهی از نظر اندازه، ساختار مدل زبانی، نوع کدگذار بینایی و نحوه اتصال این اجزا با یکدیگر متفاوت هستند. برای درک معماری مدل‌های بررسی‌شده در این پژوهش، آشنایی با چند مفهوم پایه ضروری است.

۲-۳-۲-۱- معماری ترنسفورمر

ترنسفورمر (Transformer) یکی از معماری‌های اصلی در مدل‌های زبانی و چندوجهی امروزی است. این معماری بر سازوکار **توجه (Attention)** استوار است و امکان بررسی رابطه میان بخش‌های مختلف ورودی را فراهم می‌کند. [۴]

یکی از مهم‌ترین اجزای آن **خودتوجهی (Self-Attention)** است که به مدل اجازه می‌دهد هنگام ایجاد بازنمایی هر توکن، میزان ارتباط آن را با سایر توکن‌های موجود در زمینه محاسبه کند. بسیاری از مدل‌های زبانی بزرگ از گونه‌های مختلف معماری ترنسفورمر استفاده می‌کنند و پاسخ را به صورت خودبازگشتی، یعنی با پیش‌بینی پی‌درپی توکن بعدی، تولید می‌کنند.

¹ Bootstrapping Language-Image Pre-training 2

² Large Language and Vision Assistant

۲-۳-۲- ترنسفورمر بینایی و کدگذار بصری

برای استفاده از تصویر در یک مدل چندوجهی، ابتدا باید محتوای آن به بازنمایی عددی تبدیل شود. این وظیفه معمولاً بر عهده کدگذار بینایی (Vision Encoder) است.

یکی از معماری‌های متداول برای این منظور، ترنسفورمر بینایی Vision Transformer یا (ViT) است. در این معماری، تصویر به قطعه‌های کوچک‌تر تقسیم می‌شود و هر قطعه پس از تبدیل به یک بردار، مشابه یک توکن توسط ترنسفورمر پردازش می‌شود.

خروجی این بخش، مجموعه‌ای از ویژگی‌های بصری است که در مراحل بعد برای ایجاد ارتباط میان تصویر و متن مورد استفاده قرار می‌گیرند. [۵]

۲-۳-۳- اتصال‌دهنده چندوجهی

ویژگی‌های تولیدشده توسط کدگذار بینایی معمولاً مستقیماً با فضای ورودی مدل زبانی سازگار نیستند. به همین دلیل، بسیاری از مدل‌ها از بخشی با عنوان اتصال‌دهنده چندوجهی (Multimodal Connector) استفاده می‌کنند.

وظیفه این بخش، تبدیل ویژگی‌های بصری به بازنمایی‌ای است که مدل زبانی بتواند از آن استفاده کند. نحوه انجام این تبدیل در معماری‌های مختلف متفاوت است. برای مثال، LLaVA از یک نگاشت قابل آموزش میان کدگذار تصویر و مدل زبانی استفاده می‌کند، در حالی که BLIP-2 ساختاری با عنوان Q-Former^۱ را برای برقراری ارتباط میان این دو بخش به کار می‌گیرد [۲].

بنابراین، حتی مدل‌هایی که از بخش‌های زبانی مشابه استفاده می‌کنند ممکن است به دلیل تفاوت در نحوه انتقال اطلاعات تصویری، رفتار متفاوتی در مسائل چندوجهی داشته باشند.

۲-۳-۴- توکن‌های بصری

اطلاعات استخراج‌شده از تصویر در بسیاری از معماری‌ها به شکل مجموعه‌ای از توکن‌های بصری (Visual Tokens) در اختیار مدل زبانی قرار می‌گیرد. این توکن‌ها بازنمایی بخش‌های مختلف تصویر یا اطلاعات فشرده‌شده حاصل از آن هستند.

مدل می‌تواند این توکن‌های بصری را در کنار توکن‌های متن سؤال پردازش کند. تعداد و نحوه تولید توکن‌های بصری بر میزان جزئیات قابل دسترس برای مدل و همچنین هزینه پردازش تأثیر می‌گذارد.

^۱ Querying Transformer

۲-۳-۵- معماری متراکم

در معماری متراکم (Dense)، مجموعه واحدی از پارامترها برای پردازش ورودی‌ها استفاده می‌شود. در چنین مدلی، برخلاف معماری‌های مبتنی بر MOE^1 برای هر توکن مسیر محاسباتی جداگانه‌ای میان چند زیرشبکه انتخاب نمی‌شود.

از این رو، تعداد کل پارامترهای یک مدل متراکم معمولاً تصویر نسبتاً مستقیمی از اندازه مدل ارائه می‌دهد؛ هرچند هزینه واقعی استنتاج علاوه بر تعداد پارامترها به عواملی مانند طول ورودی، تعداد توکن‌های بصری و شیوه پیاده‌سازی نیز وابسته است.

۲-۳-۶- معماری MOE

در معماری MoE، برخی لایه‌های مدل شامل چند زیرشبکه مستقل هستند که «متخصص» نامیده می‌شوند. در هنگام پردازش هر توکن، تنها تعداد محدودی از این متخصصان فعال می‌شوند.

یک مسیریاب (Router) تعیین می‌کند که هر توکن برای پردازش به کدام متخصص یا متخصصان ارسال شود. در نتیجه، مدل می‌تواند تعداد کل پارامترهای زیادی داشته باشد، در حالی که تنها بخشی از آن‌ها برای پردازش هر توکن فعال هستند. [۶]

هدف اصلی این معماری افزایش ظرفیت مدل بدون افزایش متناسب هزینه محاسباتی هر توکن است.

۲-۳-۷- پارامترهای کل و پارامترهای فعال

در مدل‌های MoE باید میان پارامترهای کل و پارامترهای فعال تفاوت قائل شد.

پارامترهای کل شامل همه پارامترهای موجود در شبکه و تمامی متخصصان هستند، در حالی که پارامترهای فعال تنها به بخشی از مدل اشاره دارند که هنگام پردازش یک توکن مشخص در محاسبات شرکت می‌کند.

به همین دلیل، مقایسه یک مدل MoE با یک مدل متراکم تنها بر اساس تعداد کل پارامترها می‌تواند گمراه‌کننده باشد. برای توصیف دقیق‌تر چنین مدل‌هایی، بهتر است در صورت در دسترس بودن، هر دو مقدار گزارش شوند.

۲-۳-۸- ادغام اطلاعات بصری و زبانی

پس از استخراج ویژگی‌های تصویری، مدل باید ارتباط میان آن‌ها و اطلاعات متنی را برقرار کند. این فرایند را می‌توان ادغام چندوجهی (Multimodal Fusion) نامید.

¹ Mixture of Experts

در برخی معماری‌ها، ویژگی‌های تصویری پس از تبدیل مناسب در کنار توکن‌های متن قرار می‌گیرند. در برخی دیگر، سازوکار **توجه متقاطع (Cross-Attention)** برای ایجاد ارتباط میان بازنمایی‌های تصویری و متنی به کار می‌رود. Flamingo نمونه‌ای از معماری‌هایی است که از این رویکرد استفاده می‌کند. [۱، ۶]

بنابراین، نحوه ادغام اطلاعات تصویری و زبانی یکی از تفاوت‌های مهم میان معماری مدل‌های زبانی-بصری محسوب می‌شود.

۲-۳-۳- فرایند پردازش ورودی و تولید پاسخ

در یک مسئله بینایی-زبانی، متن و تصویر ابتدا از مسیرهای متناسب با نوع داده پردازش می‌شوند. تصویر توسط کدگذار بینایی به مجموعه‌ای از ویژگی‌ها یا توکن‌های بصری تبدیل می‌شود و متن نیز به توکن‌های زبانی شکسته می‌شود.

پس از انتقال اطلاعات تصویری به فضای مناسب، مدل زبانی می‌تواند آن‌ها را همراه با متن سؤال پردازش کند. در ادامه، پاسخ معمولاً به صورت خودبازگشتی و توکن‌به‌توکن تولید می‌شود.

در مسائل پیچیده، این فرایند تنها به تشخیص محتوای تصویر محدود نیست. مدل باید مشخص کند کدام بخش از تصویر برای سؤال اهمیت دارد و چگونه اطلاعات آن را با دانش و متن ورودی ترکیب کند.

۲-۳-۴- کاربردهای مدل‌های بینایی-زبانی

مدل‌های زبانی-بصری در وظایفی مانند پاسخ‌گویی به پرسش‌های تصویری، توصیف تصویر، درک اسناد، خواندن متن موجود در تصاویر و تحلیل جدول و نمودار کاربرد دارند.

با توسعه مدل‌های جدیدتر، این کاربردها به مسائل پیچیده‌تری گسترش یافته‌اند که نیازمند ترکیب اطلاعات تصویری و متنی هستند. در حوزه‌های علمی و آموزشی نیز این مدل‌ها می‌توانند برای تحلیل نمودارها، شکل‌های هندسی، نقشه‌ها، ساختارهای علمی و سایر نمایش‌های بصری مورد استفاده قرار گیرند.

۲-۳-۵- قابلیت‌ها و چالش‌های مدل‌های بینایی-زبانی

مهم‌ترین قابلیت مدل‌های بینایی-زبانی، امکان ترکیب اطلاعات متنی و تصویری در یک فرایند مشترک است. این ویژگی به مدل اجازه می‌دهد اطلاعات مورد نیاز را از تصویر استخراج کرده، آن‌ها را با پرسش و دانش خود ترکیب کند و پاسخ را به صورت زبانی ارائه دهد.

با این حال، عملکرد این مدل‌ها ممکن است در مراحل مختلف با خطا همراه باشد. مدل ممکن است اطلاعات بصری را نادرست تشخیص دهد، دانش لازم را در اختیار نداشته باشد یا پس از دریافت صحیح اطلاعات در استدلال دچار اشتباه شود.

همچنین عملکرد مدل می‌تواند تحت تأثیر نحوه ارائه سؤال و ساختار پرامپت قرار گیرد. این ویژگی باعث شده بررسی روش‌های مختلف پرامپت‌دهی نیز بخش مهمی از ارزیابی مدل‌های زبانی-بصری باشد.

۲-۴- استدلال چندوجهی

استدلال چندوجهی (Multimodal Reasoning) به فرایندی گفته می‌شود که در آن برای رسیدن به پاسخ، اطلاعات حاصل از چند نوع داده باید به صورت مرتبط با یکدیگر پردازش شوند. در یک مسئله بینایی-زبانی، این فرایند می‌تواند شامل درک متن پرسش، استخراج اطلاعات مرتبط از تصویر، استفاده از دانش مورد نیاز و انجام یک یا چند مرحله استنتاج باشد. در مسائل دانشگاهی، این مؤلفه‌ها معمولاً به صورت هم‌زمان مورد نیاز هستند. در این پژوهش، سه مؤلفه ادراک بصری، دانش و استدلال اهمیت ویژه‌ای دارند.

۲-۴-۱- ادراک بصری

ادراک بصری به توانایی مدل در استخراج و تفسیر صحیح اطلاعات موجود در تصویر اشاره دارد. این اطلاعات ممکن است شامل اشیاء، اعداد، نوشته‌ها، رنگ‌ها، موقعیت‌ها، نمودارها، جدول‌ها یا روابط میان عناصر باشند. در مسائل دانشگاهی، تصویر می‌تواند یک نمودار، دیاگرام، نقشه، شکل هندسی یا ساختار علمی باشد. بنابراین، توانایی پردازش انواع مختلف اطلاعات بصری برای حل صحیح این مسائل اهمیت دارد. [۸]

۲-۴-۲- دانش

برخی مسائل تنها بر اساس اطلاعات صریح موجود در تصویر و متن قابل حل نیستند و به دانش پیشین مدل نیاز دارند. این دانش می‌تواند شامل مفاهیم علمی، قوانین، روابط ریاضی یا اطلاعات تخصصی یک حوزه باشد. مدل ممکن است تصویر را به درستی درک کند، اما به دلیل نداشتن یا به کارگیری نادرست دانش مورد نیاز به پاسخ اشتباه برسد.

۲-۴-۳- استدلال

استدلال به فرایند استفاده از اطلاعات دریافت‌شده و دانش موجود برای رسیدن به نتیجه اشاره دارد. این فرایند می‌تواند شامل محاسبه، مقایسه، ترکیب چند داده یا استنتاج منطقی باشد. تمایز میان دانش و استدلال اهمیت دارد؛ زیرا ممکن است مدل دانش لازم را در اختیار داشته باشد اما در استفاده از آن یا انجام مراحل حل اشتباه کند.

۲-۵- روش‌های پرامپت‌دهی به مدل‌های چندوجهی

پرامپت مجموعه دستورها و اطلاعاتی است که وظیفه مورد انتظار از مدل را مشخص می‌کند. نحوه ارائه مسئله می‌تواند بدون تغییر در وزن‌های مدل، بر شیوه پاسخ‌گویی آن اثر بگذارد. [۹]

۲-۵-۱- پرامپت‌دهی بدون نمونه

در روش بدون نمونه (Zero-shot)، مدل پیش از مسئله اصلی نمونه حل‌شده‌ای دریافت نمی‌کند و تنها بر اساس دستور و ورودی ارائه‌شده پاسخ می‌دهد. این روش معمولاً به‌عنوان یکی از حالت‌های پایه برای ارزیابی توانایی مدل استفاده می‌شود.

۲-۵-۲- زنجیره استدلال

در روش زنجیره استدلال (Chain-of-Thought) مدل به تولید مراحل میانی حل مسئله پیش از پاسخ نهایی هدایت می‌شود. این رویکرد در برخی مسائل استدلالی باعث بهبود عملکرد مدل‌های زبانی شده است. با این حال، تأثیر زنجیره استدلال به مدل، نوع مسئله و نحوه طراحی پرامپت وابسته است و لزوماً در همه شرایط باعث افزایش دقت نمی‌شود.

۲-۵-۳- پرامپت‌دهی چندنمونه‌ای

در پرامپت‌دهی چندنمونه‌ای (Few-shot Prompting) تعدادی مثال حل‌شده پیش از سؤال اصلی در اختیار مدل قرار می‌گیرند. این نمونه‌ها می‌توانند قالب پاسخ یا شیوه حل مورد انتظار را به مدل نشان دهند [۹]. در مدل‌های چندوجهی، نمونه‌ها می‌توانند علاوه بر متن شامل تصویر و زنجیره استدلال نیز باشند.

۲-۵-۴- انتخاب نمونه‌های نمایشی

نمونه‌های مورد استفاده در پرامپت‌های چندنمونه‌ای می‌توانند به‌صورت تصادفی یا بر اساس معیارهایی مانند شباهت، دشواری یا پیچیدگی استدلال انتخاب شوند. هدف از انتخاب هدفمند آن است که نمونه‌هایی در اختیار مدل قرار گیرند که ارتباط بیشتری با مسئله هدف داشته باشند. جزئیات معیارهای انتخاب و بازیابی نمونه‌ها به طراحی هر روش وابسته است و در فصل روش‌شناسی توضیح داده خواهد شد.

۲-۵-۵- پرامپت‌دهی ساختاریافته و چندمرحله‌ای

در برخی روش‌ها، حل مسئله به چند مرحله تقسیم می‌شود. برای مثال، در **Plan-and-Solve** ابتدا برنامه‌ای برای حل مسئله تولید شده و سپس مراحل آن اجرا می‌شوند [۱۰]. در روش **Compositional Chain-of-Thought** نیز ابتدا اطلاعات بصری در قالب ساختاریافته‌ای مانند گراف صحنه استخراج و سپس برای پاسخ‌گویی مورد استفاده قرار می‌گیرند [۱۱].

۲-۶- ارزیابی مدل‌های زبانی-بصری و بنچمارک‌های چندوجهی

بنچمارک مجموعه‌ای از داده‌ها و یک روش ارزیابی مشخص است که امکان مقایسه مدل‌های مختلف را

در شرایط مشابه فراهم می‌کند.

در ارزیابی چندوجهی، تنها تعداد سؤالات اهمیت ندارد؛ بلکه نوع تصویر، میزان وابستگی پاسخ به تصویر، دانش مورد نیاز و سطح استدلال نیز باید با هدف ارزیابی هماهنگ باشند.

۲-۶-۱- ویژگی‌های بنچمارک‌های چندوجهی

بنچمارک‌های چندوجهی ممکن است شامل تصاویر طبیعی، نمودارها، جدول‌ها، نقشه‌ها، دیاگرام‌ها یا سایر نمایش‌های تخصصی باشند.

یکی از ویژگی‌های مهم این بنچمارک‌ها، وابستگی واقعی پاسخ به اطلاعات چندوجهی است. اگر سؤال بدون مشاهده تصویر نیز قابل حل باشد، نتیجه آن الزاماً توانایی چندوجهی مدل را نشان نمی‌دهد.

۲-۶-۲- بنچمارک‌های دانشگاهی و چندرشته‌ای

مسائل دانشگاهی معمولاً به ترکیبی از ادراک، دانش و استدلال نیاز دارند. برای مثال، یک سؤال ممکن است ابتدا نیازمند استخراج مقدار از یک نمودار و سپس استفاده از یک رابطه علمی برای محاسبه پاسخ باشد. به همین دلیل، بنچمارک‌های دانشگاهی امکان بررسی جامع‌تر توانایی مدل‌های زبانی-بصری را فراهم می‌کنند. [4]

۲-۶-۳- پرسش‌های چندگزینه‌ای و معیار دقت

در پرسش‌های چندگزینه‌ای، پاسخ مدل را می‌توان با گزینه مرجع مقایسه کرد. یکی از معیارهای اصلی در چنین مسائلی دقت است:

$$Accuracy = \frac{N_{correct}}{N_{total}}$$

که در آن $N_{correct}$ تعداد پاسخ‌های صحیح و N_{total} تعداد کل نمونه‌های معتبر ارزیابی شده است. دقت معیار ساده و قابل مقایسه‌ای است، اما تنها صحیح یا نادرست بودن پاسخ نهایی را نشان می‌دهد و علت شکست مدل را مشخص نمی‌کند. به همین دلیل، برای تحلیل دقیق‌تر رفتار مدل به بررسی نوع خطا نیاز است.

۲-۷- تحلیل خطا در مدل‌های بینایی-زبانی

تحلیل خطا با هدف شناسایی منشأ پاسخ‌های نادرست انجام می‌شود. در مدل‌های چندوجهی، یک پاسخ اشتباه ممکن است ناشی از برداشت نادرست از تصویر، استفاده نادرست از دانش یا خطا در مراحل استدلال باشد.

در این پژوهش، سه گروه خطای ادراکی، استدلالی و دانشی مورد توجه قرار می‌گیرند. تعاریف عملیاتی

این خطاها با اقتباس از چارچوب طبقه‌بندی خطا در مجموعه داده MMErrorR تنظیم شده‌اند [۱۲].

۲-۷-۱- خطای ادراکی

خطای ادراکی (Visual Perception Error) زمانی رخ می‌دهد که مدل اطلاعات موجود در تصویر را به‌درستی استخراج یا تفسیر نکند. این خطا می‌تواند شامل اشتباه در خواندن متن یا اعداد، تفسیر نادرست مقادیر نمودار و جدول، تشخیص نادرست رنگ، شکل، موقعیت یا تعداد اشیا و همچنین تعیین اشتباه محل عناصر تصویر باشد. در این نوع خطا، اگر اطلاعات بصری نادرستی که مدل دریافت کرده است صحیح فرض شوند، روند استدلال بعدی مدل باید تا حد زیادی منطقی و سازگار باشد. [۱۲]

۲-۷-۲- خطای استدلالی

خطای استدلالی (Reasoning Error) زمانی رخ می‌دهد که مدل اطلاعات بصری مورد نیاز را به‌درستی دریافت کرده باشد، اما در مراحل استدلال دچار اشتباه شود. خطا در محاسبات، ترکیب نادرست مقادیر، واحدها یا نسبت‌ها و همچنین استنتاج منطقی یا استدلال مرحله‌به‌مرحله نادرست در این گروه قرار می‌گیرند. در این حالت، اطلاعات استخراج‌شده از تصویر صحیح هستند و منشأ خطا به فرایند استدلال مدل مربوط می‌شود. [۱۲]

۲-۷-۳- خطای دانشی

خطای دانشی (Knowledge Deployment Error) زمانی رخ می‌دهد که مدل تصویر را به‌درستی درک کرده و سؤال را نیز صحیح فهمیده باشد، اما در استفاده از دانش مورد نیاز برای حل مسئله دچار خطا شود. استفاده از یک واقعیت علمی یا تخصصی نادرست، به‌کارگیری اشتباه یک فرمول یا مفهوم، یا استفاده از دانشی نامرتبط و ناسازگار با مسئله در این دسته قرار می‌گیرد. بنابراین، در این نوع خطا ادراک بصری و درک سؤال صحیح است و منشأ خطا به انتخاب یا به‌کارگیری نادرست دانش زمینه‌ای مربوط می‌شود. تفکیک این سه نوع خطا امکان می‌دهد اثر یک روش تنها از طریق تغییر دقت بررسی نشود و مشخص شود بهبود یا افت عملکرد بیشتر به کدام بخش از توانایی مدل مربوط است. [۱۲]

۲-۸- ارزیابی مبتنی بر مدل و مدل به‌عنوان داور

در برخی وظایف، به‌ویژه زمانی که خروجی شامل توضیح یا استدلال است، معیارهای ساده قادر به ارزیابی کامل پاسخ نیستند. یکی از روش‌های مورد استفاده برای این منظور، به‌کارگیری یک مدل قدرتمند به‌عنوان داور (Model-as-a-Judge) است.

در این روش، مدل داور بر اساس سؤال، پاسخ تولیدشده و معیارهای مشخص، درباره ویژگی یا کیفیت پاسخ تصمیم می‌گیرد. [۱۳]

۲-۸-۱- داوری در مسائل چندوجهی

در مسائل چندوجهی ممکن است تشخیص صحت یا نوع خطا بدون مشاهده تصویر امکان پذیر نباشد. در چنین شرایطی می توان از یک مدل زبانی-بصری به عنوان داور استفاده کرد. رویکرد **VLM-as-a-Judge** امکان می دهد داور علاوه بر متن سؤال و پاسخ مدل، محتوای تصویر را نیز در تصمیم خود در نظر بگیرد. Prometheus-Vision نمونه ای از این رویکرد است. [۱۴]

۲-۸-۲- مزایا و محدودیت ها

داوری خودکار امکان بررسی تعداد زیادی خروجی را با هزینه و زمان کمتر از ارزیابی کاملاً انسانی فراهم می کند. با این حال، قضاوت مدل ممکن است تحت تأثیر سوگیری های خود داور قرار گیرد و نباید به عنوان حقیقت قطعی در نظر گرفته شود. در مسائل چندوجهی نیز صحت داوری به توانایی خود مدل در درک تصویر وابسته است. به همین دلیل، اعتبارسنجی نتایج داور خودکار با نمونه ای از قضاوت های انسانی اهمیت دارد.

۲-۹- ارزیابی انسانی

ارزیابی انسانی (**Human Evaluation**) یکی از روش های اصلی برای ارزیابی خروجی مدل ها در مواردی است که معیارهای خودکار برای قضاوت دقیق کافی نیستند. این روش به ویژه در بررسی پاسخ های توضیحی، استدلال های چندمرحله ای و تشخیص نوع خطا اهمیت دارد؛ زیرا ارزیاب می تواند علاوه بر پاسخ نهایی، شواهد موجود در ورودی و مسیر استدلال مدل را نیز بررسی کند. برای کاهش وابستگی نتیجه به نظر یک فرد، ارزیابی انسانی معمولاً بر اساس دستورالعمل و معیارهای از پیش تعریف شده انجام می شود و در صورت استفاده از چند ارزیاب، اختلاف ها می توانند با بازبینی مجدد و فرایند حل اختلاف برطرف شوند.

استفاده از بررسی انسانی در تحلیل خطای بنچمارک های چندوجهی نیز سابقه دارد. برای نمونه، در **MMMU-Pro** بخشی از پاسخ های نادرست GPT-4o به صورت موردی بررسی و در گروه هایی مانند خطای ادراکی، کمبود دانش و خطای استدلالی دسته بندی شدند؛ رویکردی که امکان بررسی منشأ خطا را فراتر از صرف صحیح یا غلط بودن پاسخ فراهم می کند. [۱۵]

با وجود دقت و انعطاف بیشتر این روش در تحلیل های پیچیده، داوری انسانی زمان بر و پرهزینه است و ممکن است تحت تأثیر تفاوت در برداشت ارزیابان قرار گیرد. از این رو، استفاده از معیارهای روشن و دستورالعمل مشخص برای افزایش ثبات و قابلیت اعتماد نتایج اهمیت دارد.

۲-۱۰- اهمیت ارزیابی مدل‌های زبانی-بصری در مسائل دانشگاهی چندرشته‌ای

مسائل دانشگاهی محیط مناسبی برای ارزیابی مدل‌های زبانی-بصری فراهم می‌کنند، زیرا حل بسیاری از آن‌ها نیازمند استفاده هم‌زمان از ادراک بصری، دانش تخصصی و استدلال است. برای نمونه، پاسخ به یک سؤال فیزیک ممکن است ابتدا نیازمند استخراج اطلاعات از نمودار، سپس تشخیص رابطه علمی مرتبط و در نهایت انجام محاسبه باشد. در چنین مسئله‌ای، ضعف در هر یک از این مراحل می‌تواند به پاسخ نادرست منجر شود.

بنچمارک‌های چندرشته‌ای مانند MMMU نشان داده‌اند که حتی مدل‌های قدرتمند نیز در چنین مسائل ترکیبی با محدودیت‌هایی در ادراک، دانش و استدلال روبه‌رو هستند. توسعه بنچمارک‌های دشوارتر نیز نشان داده است که کاهش امکان پاسخ‌گویی بر اساس سرنخ‌های متنی، ارزیابی واقع‌بینانه‌تری از توانایی چندوجهی مدل‌ها فراهم می‌کند. [۸]

بنابراین، ارزیابی در مسائل دانشگاهی علاوه بر مقایسه دقت مدل‌ها، امکان بررسی نقاط ضعف آن‌ها و تأثیر روش‌های مختلف پرامپت‌دهی بر انواع توانایی‌ها را نیز فراهم می‌کند.

۲-۱۱- جمع‌بندی

در این فصل، ابتدا تفاوت میان مدل‌های تک‌وجهی و چندوجهی بیان شد و سپس مدل‌های بینایی-زبانی، ساختار کلی و مفاهیم معماری مرتبط با آن‌ها معرفی شدند. مفاهیمی مانند ترنسفورمر، کدگذار بینایی، اتصال‌دهنده چندوجهی، معماری متراکم و MOE نیز به‌عنوان زمینه لازم برای معرفی مدل‌های مورد استفاده در پژوهش توضیح داده شدند.

در ادامه، استدلال چندوجهی و سه مؤلفه ادراک بصری، دانش و استدلال بررسی شد. سپس روش‌های اصلی پرامپت‌دهی، اصول ارزیابی مدل‌های چندوجهی و تحلیل خطا معرفی شدند. همچنین کاربرد و مفهوم استفاده از مدل به‌عنوان داور و داوری انسانی در مسائل چندوجهی مورد بررسی قرار گرفت.

مباحث این فصل زمینه نظری لازم برای فصل بعد را فراهم می‌کنند؛ در فصل بعد، مجموعه داده مورد استفاده، نحوه انتخاب داده‌های ارزیابی، مدل‌های مورد بررسی و ویژگی‌های معماری آن‌ها، روش‌های پرامپت‌دهی و فرایند عملی ارزیابی و تحلیل خطا تشریح خواهند شد.

فصل سوم

شرح پروژه

۳-۱- مقدمه

این فصل به تشریح روش‌شناسی و مراحل اجرایی پژوهش اختصاص دارد. ابتدا مجموعه داده-MMM Pro، دلیل انتخاب آن و نحوه تشکیل زیرمجموعه ارزیابی ۳۰۰ نمونه‌ای توضیح داده می‌شود [۱۵]. سپس هفت مدل زبانی-بصری مورد بررسی، تفاوت‌های اصلی معماری آن‌ها و تنظیمات مشترک استنتاج معرفی می‌شوند تا شرایط مقایسه مدل‌ها مشخص باشد.

در ادامه، فرایند ساخت داده‌های کمکی مورد نیاز آزمایش‌ها تشریح می‌شود؛ این بخش شامل تولید و اعتبارسنجی زنجیره‌های استدلال، تشکیل بانک نمونه‌های نمایشی و دانش، و ساخت بازنمایی‌های متنی و تصویری برای بازیابی نمونه‌های مشابه است. پس از آن، روش‌های پرامپت‌دهی در دو گروه بدون نمونه و چندنمونه‌ای معرفی شده و نحوه پیاده‌سازی هر روش، از جمله زنجیره استدلال، برنامه‌ریزی و حل، گراف صحنه، تولید دانش و روش‌های مختلف انتخاب نمونه نمایشی بیان می‌شود.

برای آن‌که تفاوت نتایج تا حد امکان ناشی از خود روش‌ها باشد، پروتکل اجرای آزمایش‌ها، نحوه حفظ ترتیب تصاویر، استخراج پاسخ نهایی، برخورد با خروجی‌های ناقص و کنترل‌های مربوط به بازتولیدپذیری نیز به‌صورت مشخص تعریف شده‌اند. علاوه بر ارزیابی دقت، امکان استفاده از مدل زبانی-بصری به‌عنوان داور برای تشخیص نوع خطا بررسی می‌شود و پس از ارزیابی این روش، فرایند نهایی برچسب‌گذاری انسانی با داوری مستقل و حل اختلاف تشریح خواهد شد.

در بخش پایانی فصل، بر پایه تفاوت مشاهده‌شده میان اثر روش‌های پرامپت‌دهی در حوزه‌های مختلف، طراحی سامانه انتخاب تطبیقی روش پرامپت ارائه می‌شود. در این سامانه ابتدا حوزه علمی سؤال تشخیص داده شده و سپس روشی انتخاب می‌شود که بر اساس نتایج مرحله توسعه برای آن حوزه مناسب‌تر بوده است؛ اجرای تشخیص حوزه، انتخاب روش، بازیابی نمونه و استخراج پاسخ نیز در یک خط لوله یکپارچه قرار گرفته‌اند.

در مجموع، این فصل مشخص می‌کند داده‌ها چگونه انتخاب شده‌اند، مدل‌ها تحت چه شرایطی اجرا

شده‌اند، روش‌های پرامپت‌دهی چگونه پیاده‌سازی شده‌اند، تحلیل خطا با چه سازوکاری انجام شده و سامانه نهایی انتخاب تطبیقی چگونه طراحی شده است؛ در نتیجه، مبنای لازم برای تفسیر نتایج ارائه‌شده در فصل بعد را فراهم می‌کند.

۲-۳ مجموعه داده و ساخت مجموعه ارزیابی

۱-۲-۳ معرفی MMMU و دلیل انتخاب MMMU-Pro

مجموعه داده MMMU با نام کامل *Massive Multi-discipline Multimodal Understanding and Reasoning* برای ارزیابی مدل‌های چندوجهی در مسائلی طراحی شده است که صرف تشخیص اشیا یا استخراج اطلاعات سطحی از تصویر برای حل آن‌ها کافی نیست. [۸] این مجموعه شامل حدود ۱۱۰۵ هزار مسئله دانشگاهی از آزمون‌ها، کتاب‌های درسی و منابع آموزشی مختلف است و شش حوزه اصلی، ۳۰ موضوع و ۱۸۳ زیرحوزه را پوشش می‌دهد. [۸] در سؤالات این مجموعه حدود ۳۰ نوع محتوای بصری مختلف، از جمله نمودار، جدول، نقشه، دیاگرام، ساختار شیمیایی، نت موسیقی و تصاویر تخصصی مورد استفاده قرار گرفته است. یکی از ویژگی‌های اصلی MMMU این است که طراحان آن صرفاً توانایی مشاهده تصویر را هدف قرار نداده‌اند. بسیاری از مسائل آن به ترکیبی از درک بصری، دانش تخصصی در سطح دانشگاهی و استدلال چندمرحله‌ای نیاز دارند. به همین دلیل این مجموعه نسبت به بسیاری از مجموعه‌های کلاسیک پاسخ‌گویی به پرسش‌های بصری، ارزیابی دشوارتری از قابلیت‌های مدل‌های زبانی-بصری ارائه می‌کند.

بررسی‌های بعدی نشان دادند که بخشی از سؤالات MMMU را می‌توان بدون استفاده مؤثر از اطلاعات تصویر و تنها با اتکا به متن سؤال، دانش زبانی یا ساختار گزینه‌ها پاسخ داد. همچنین تعداد محدود گزینه‌ها در بسیاری از مسائل چندگزینه‌ای، احتمال موفقیت از طریق حدس یا حذف ساده گزینه‌ها را افزایش می‌داد.

برای کاهش این مشکلات، نسخه مقاوم‌تری با عنوان **MMMU-Pro** ارائه شد. [۱۵] در ساخت-MMMU-Pro سه تغییر اصلی نسبت به MMMU اعمال شده است. نخست، سؤال‌هایی که مدل‌های قوی متنی می‌توانستند بدون دسترسی واقعی به تصویر حل کنند، تا حد زیادی فیلتر شدند. دوم، تعداد گزینه‌های پاسخ افزایش یافت تا احتمال موفقیت از طریق حدس یا حذف ساده گزینه‌ها کاهش یابد. سوم، علاوه بر حالت استاندارد، حالتی با عنوان *Vision Setting* معرفی شد که در آن متن سؤال نیز در داخل تصویر قرار می‌گیرد و مدل ناچار است تمام اطلاعات مسئله را به‌صورت بصری پردازش کند. [۱۵]

در پژوهش حاضر از حالت استاندارد MMMU-Pro استفاده شده است. دلیل این انتخاب آن بود که هدف پژوهش بررسی عملکرد مدل در شرایطی بود که سؤال متنی، اطلاعات بصری، دانش تخصصی و استدلال به‌طور هم‌زمان در حل مسئله نقش داشته باشند.

انتخاب MMMU-Pro برای این پژوهش از دو جهت اهمیت داشت. نخست، پوشش ۳۰ موضوع دانشگاهی

سبب می‌شود ارزیابی به یک حوزه محدود نشود و رفتار مدل‌ها در مسائل علوم، مهندسی، پزشکی، هنر، علوم انسانی و کسب‌وکار بررسی شود. دوم، ماهیت مسائل این مجموعه‌داده با هدف بخش پرامپت‌دهی پژوهش‌سازگار است؛ زیرا امکان بررسی این موضوع را فراهم می‌کند که آیا با تغییر نحوه هدایت مدل می‌توان عملکرد آن را در سه مؤلفه اصلی ادراک، دانش و استدلال بهبود داد یا خیر.


۳-۲-۲- تفاوت حالت Standard (10 options) با MMMU

یکی از مهم‌ترین تغییرات MMMU-Pro نسبت به MMMU اصلی، افزایش تعداد گزینه‌های پاسخ است. در MMMU اصلی بسیاری از سؤالات چندگزینه‌ای دارای چهار گزینه بودند. در چنین شرایطی حتی در صورت انتخاب کاملاً تصادفی، احتمال انتخاب پاسخ صحیح برابر است با:

$$P(\text{Correct by Chance}) = \frac{1}{4} = 25\%.$$

علاوه بر آن، در برخی مسائل مدل می‌تواند بدون حل کامل سؤال و تنها با حذف یک یا دو گزینه نامحتمل به احتمال نسبتاً بالایی برای انتخاب پاسخ صحیح برسد.

در MMMU-Pro، گزینه‌های انحرافی بیشتری به سؤالات اضافه شده‌اند و حالت اصلی مجموعه با عنوان **Standard (10 options)** عرضه شده است [۱۵]. هدف از این تغییر، افزایش دشواری انتخاب پاسخ و کاهش اثر حدس و حذف ساده گزینه‌ها است.

Sample ID: test_Math_209	Subject: Math	Difficulty: Easy
Question Image: 		Question: Use the information in the diagram to determine the height of the tree. The diagram is not to scale.
		Options: A. 65ft B. 100ft C. 75ft D. 37.5ft E. 80ft F. 35.5ft G. 45ft H. 50ft I. 150ft J. 60ft
		Correct Answer: C — 75ft

شکل ۳-۱: داده‌ای از دیتاست mmmu-pro

بررسی نسخه واقعی در این پژوهش نشان داد که عبارت standard(10 options) به این معنا نیست که تمام ردیف‌های مجموعه‌داده الزاماً دقیقاً ده گزینه دارند. در نسخه ثابت‌شده مورد استفاده، بیشترین تعداد سؤالات دارای ده گزینه هستند، اما نمونه‌هایی با تعداد گزینه کمتر و در یک مورد بیشتر نیز وجود دارند.

از این رو، در پیاده سازی پژوهش تعداد گزینه ها به صورت ثابت برابر ده در نظر گرفته نشد. گزینه های هر سؤال دقیقاً مطابق منبع اصلی حفظ شدند و مجموعه حروف مجاز پاسخ به صورت پویا بر اساس تعداد گزینه های همان نمونه ساخته شد.

برای مثال، اگر سؤال دارای چهار گزینه باشد:

$$L(q) = \{A, B, C, D\},$$

و اگر سؤال دارای ده گزینه باشد:

$$L(q) = \{A, B, \dots, J\}.$$

هیچ گزینه ای برای رسیدن مصنوعی به تعداد ده حذف، اضافه یا بازنویسی نشد. همین سیاست بعداً در طراحی استخراج گر پاسخ نیز مورد استفاده قرار گرفت.

منبع اصلی داده در آزمایش ها مخزن:

MMMU/MMMU_Pro

با پیکربندی:

standard (10 options)

بود. نسخه مجموعه داده نیز در تمام آزمایش ها ثابت نگه داشته شد تا تغییر احتمالی محتوای مخزن در آینده بر بازتولید نتایج اثر نگذارد.

۳-۲-۳ ساخت زیرمجموعه ۳۰۰ نمونه ای

اجرای هفت مدل در چندین وضعیت مختلف پرامپت دهی، به ویژه روش های چند مرحله ای مانند CoT، Plan-and-Solve و GKP، روی تمام ۱۷۳۰ سؤال هزینه محاسباتی و زمانی بالایی ایجاد می کرد. محدودیت زمانی نشست های Kaggle و محدودیت سرویس های ارائه دهنده مدل نیز انجام تمام ترکیب های آزمایشی روی کل مجموعه را دشوار می ساخت.

به همین دلیل، یک زیرمجموعه ثابت شامل ۳۰۰ نمونه تشکیل شد.

هدف اصلی در انتخاب نمونه ها حفظ توازن موضوعی بود MMMU-Pro. شامل ۳۰ موضوع است و از هر موضوع دقیقاً ده سؤال انتخاب شد. هدف اولیه این بود که از هر موضوع سه سؤال آسان، چهار سؤال متوسط و سه سؤال دشوار انتخاب شود:

$$3E + 4M + 3H = 10.$$

با این حال، علاوه بر توازن سطح دشواری، یک محدودیت مهم دیگر نیز وجود داشت: نمونه های مجموعه ارزیابی نباید با مجموعه نمونه های نمایشی مورد استفاده در روش های چند نمونه ای هم پوشانی داشته باشند.

پس از اعمال این شرط و بررسی نمونه های قابل استفاده، در دو موضوع دستیابی کامل به نسبت ۳/۴/۳

امکان‌پذیر نبود. در موضوع Electronics توزیع نهایی به‌صورت:

$$1E + 6M + 3H$$

و در موضوع Literature به‌صورت:

$$3E + 6M + 1H$$

درآمد. در سایر ۲۸ موضوع نسبت ۳/۴/۳ حفظ شد.

در نتیجه، توزیع نهایی سطح دشواری در مجموعه ۳۰۰ نمونه‌ای برابر بود با:

$$N_{Easy} = 88, N_{Medium} = 124, N_{Hard} = 88.$$

اگرچه توزیع سطح دشواری کاملاً ۹۰/۱۲۰/۹۰ نیست، مجموعه از نظر موضوعی کاملاً متوازن باقی مانده و هر ۳۰ موضوع دقیقاً ده نمونه دارند.

پس از نهایی‌شدن انتخاب نمونه‌ها، شناسه آن‌ها در فایل ثابتی ذخیره شد. از این مرحله به بعد هیچ‌یک از آزمایش‌های مدل‌ها نمونه‌گیری جدیدی انجام نمی‌دهند و تمام اجراها دقیقاً همان ۳۰۰ شناسه و همان ترتیب را بازسازی می‌کنند.

همچنین بررسی شد که میان مجموعه ارزیابی و بانک نمونه‌های نمایشی هم‌پوشانی وجود نداشته باشد:

$$Q_{Eval} \cap D_{Demo} = \emptyset.$$

این جداسازی مانع از آن می‌شود که مدل در آزمایش‌های چندنمونه‌ای، خود سؤال هدف یا نسخه‌ای از همان سؤال را به‌عنوان نمونه حل‌شده مشاهده کند.

۳-۳ مدل‌های زبانی-بصری مورد ارزیابی

۱-۳-۳ معیارهای انتخاب مدل‌ها

در انتخاب مدل‌های مورد ارزیابی تلاش شد تنوع معماری و مقیاس حفظ شود تا نتایج پژوهش تنها به رفتار یک مدل یا یک خانواده خاص وابسته نباشد.

هفت مدل از چهار مجموعه اصلی شامل NVIDIA ، OpenGVLab ، Google DeepMind و Qwen انتخاب شدند. این مدل‌ها از نظر تعداد پارامترها، معماری متراکم یا MOE ، نوع بخش زبانی، پردازش اطلاعات بصری و روش اجرا با یکدیگر تفاوت دارند.

در یک سوی این مجموعه مدل‌هایی در محدوده ۸ تا ۹ میلیارد پارامتر مانند InternVL3.5-8B و Qwen3.5-9B قرار دارند و در سوی دیگر مدل‌هایی در محدوده ۲۷ تا ۳۱ میلیارد پارامتر ارزیابی شده‌اند. همچنین مدل‌های متراکم در کنار مدل‌های دارای معماری Mixture-of-Experts قرار گرفته‌اند.

این انتخاب امکان بررسی دو پرسش را فراهم می‌کند: نخست، آیا یک روش پرامپت‌دهی در مدل‌های متفاوت رفتار مشابهی ایجاد می‌کند؟ و دوم، آیا اندازه یا ساختار معماری مدل می‌تواند بر میزان بهره‌مندی آن از یک روش خاص اثرگذار باشد؟

Gemma 4 26B-A4B ۲-۳-۳

Gemma خانواده‌ای از مدل‌های توسعه‌یافته توسط Google DeepMind است. نسل چهارم این خانواده شامل مدل‌های چندوجهی با اندازه‌ها و معماری‌های متفاوت است. [۱۶]

Gemma 4 26B-A4B از معماری MOE استفاده می‌کند. این مدل حدود ۲۵٫۲ میلیارد پارامتر کلی دارد، اما در هر مرحله تنها حدود ۳٫۸ میلیارد پارامتر آن فعال می‌شوند. مدل دارای ۳۰ لایه و مجموعه‌ای از متخصصان است که تنها بخشی از آن‌ها برای هر نشانه فعال می‌شوند. [۱۶]

بخش پردازش تصویر نیز در داخل معماری چندوجهی مدل قرار دارد و اطلاعات بصری را برای استفاده بخش زبانی آماده می‌کند. Gemma 4 همچنین از ترکیبی از توجه محلی و توجه سراسری استفاده می‌کند. [۱۶]

دلیل انتخاب این مدل، علاوه بر توانایی چندوجهی، بررسی یک مدل بزرگ اما کم‌تراکم بود. وجود Gemma 4 31B در کنار آن نیز امکان مقایسه دو طراحی متفاوت از یک خانواده را فراهم می‌کند.

در اجرای اصلی، نسخه دستورپذیر این مدل از طریق رابط برنامه‌نویسی Google مورد استفاده قرار گرفت. با توجه به عملکرد پایدار این مدل در ارزیابی حالت پایه، از آن در مرحله ارزیابی و مقایسه روش‌های مختلف پرامپت‌دهی نیز استفاده شد.

Gemma 4 31B ۳-۳-۳

Gemma 4 31B عضو بزرگ‌تر و متراکم خانواده Gemma 4 است و حدود ۳۰٫۷ میلیارد پارامتر دارد. برخلاف نسخه B-A4B، ۲۶ این مدل از ساختار متراکم استفاده می‌کند و تمام پارامترهای مربوط به لایه‌های آن در استنتاج شرکت دارند. این مدل نیز قابلیت دریافت متن و تصویر را دارد و برای وظایف چندوجهی و استدلالی قابل استفاده است. [۱۶]

وجود دو مدل Gemma در آزمایش‌ها امکان مقایسه نسبی میان معماری متراکم و MOE در یک خانواده را ایجاد می‌کند.

Gemma 4 31B همچنین در ارزیابی‌های اولیه پژوهش عملکرد بالایی داشت. به همین دلیل، تصمیم گرفته شد از این مدل برای ارزیابی روش‌های پرامپت‌دهی استفاده نشود و ظرفیت آن برای وظایفی که به توان استدلالی و دقت بالاتری نیاز داشتند، اختصاص یابد. در نهایت، از آن در مرحله ساخت زنجیره‌های استدلال نمونه‌های نمایشی و به‌عنوان داور در تحلیل خطا نیز استفاده شد که جزئیات آن در بخش ۴ ارائه می‌شود.

در اجرای اصلی، نسخه gemma-4-31b-it از طریق رابط برنامه‌نویسی Google مورد استفاده قرار گرفت.

۳-۳-۴ InternVL3.5-8B

خانواده InternVL توسط OpenGVLab توسعه یافته است و یکی از خانواده‌های شناخته‌شده مدل‌های زبانی-بصری متن‌باز محسوب می‌شود.

نسخه InternVL3.5-8B تقریباً ۸.۵ میلیارد پارامتر دارد که بخش عمده آن مربوط به مدل زبانی و بخشی مربوط به رمزگذار تصویر است. [۱۷]

دلیل انتخاب این مدل، افزودن یک مدل نسبتاً کوچک‌تر به مجموعه آزمایش‌ها بود. بدین ترتیب می‌توان بررسی کرد که آیا روش‌های مؤثر بر مدل‌های چندده میلیارد پارامتری روی یک مدل حدود ۸ میلیارد پارامتری نیز اثر مشابهی دارند یا خیر.

همچنین، معماری و فرایند آموزش InternVL3.5 با تأکید بر تقویت درک بصری و استدلال چندوجهی توسعه یافته است. مستندات رسمی مدل، MMMU را به‌طور مشخص به‌عنوان یکی از وظایف استدلالی پایین‌دستی ذکر می‌کنند که از روش Cascade Reinforcement Learning مدل بهره می‌برد. علاوه‌براین، داده‌های آموزشی مدل حوزه‌هایی نظیر علوم، ریاضیات، نمودارها، OCR و grounding دانش را پوشش می‌دهند که با ماهیت چندرشته‌ای و دانش‌محور MMMU هم‌راستا هستند.

این مدل به‌صورت محلی در Kaggle اجرا شد. برای امکان اجرای پایدار آن از نسخه کم‌دقت Q4_K_M همراه با نگاشتگر چندوجهی استفاده شد و استنتاج از طریق llama.cpp انجام گرفت. با توجه به عملکرد پایدار این مدل در ارزیابی حالت پایه، از آن در مرحله ارزیابی و مقایسه روش‌های مختلف پرامپت‌دهی نیز استفاده شد.

۳-۳-۵ NVIDIA Nemotron 3 Nano Omni

مدل Nemotron 3 Nano Omni 30B-A3B توسط NVIDIA توسعه یافته است. این مدل برخلاف بسیاری از مدل‌های متن-تصویر، برای پشتیبانی از چند نوع ورودی از جمله متن، تصویر، صوت و ویدئو طراحی شده است. در این پژوهش تنها قابلیت متنی و تصویری آن مورد استفاده قرار گرفت. [۱۸]

این مدل از معماری ترکیبی Mixture-of-Experts استفاده می‌کند و حدود ۳۰ میلیارد پارامتر کلی دارد، در حالی که تنها حدود ۳ میلیارد پارامتر در هر مرحله فعال می‌شوند. بخش زبانی آن ترکیبی از ساختارهای Mamba و Transformer است و بخش بصری نیز از رمزگذار مخصوص تصویر استفاده می‌کند. [۱۸]

دلیل انتخاب Nemotron، افزایش تنوع معماری بود. ساختار ترکیبی Mamba و Attention آن با مدل‌های عمده‌تاً Transformer محور سایر خانواده‌ها تفاوت دارد.

Nemotron از طریق سرویس میزبانی‌شده NVIDIA فراخوانی شد.

با توجه به عملکرد پایدار این مدل در ارزیابی حالت پایه، از آن در مرحله ارزیابی و مقایسه روش‌های

مختلف پرامپت‌دهی نیز استفاده شد.

Qwen3.8-27B -۶-۳-۳

Qwen3.8-27B یک مدل چندوجهی متراکم با حدود ۲۷ میلیارد پارامتر است. این مدل نیز از معماری ترکیبی Gated DeltaNet و Attention استفاده می‌کند، اما نسبت به Qwen3.5-9B دارای تعداد لایه و ظرفیت بیشتری است. [۱۹]

دلیل انتخاب این مدل، بررسی یک مدل متراکم بزرگ و همچنین امکان مقایسه آن با نسخه کوچک‌تر خانواده Qwen بود.

نسخه مورد استفاده به صورت کم‌دقت UD-Q4_K_M در محیط Kaggle و با استفاده از llama.cpp اجرا شد.

این مدل در تعداد قابل توجهی از نمونه‌ها پیش از تولید پاسخ نهایی به سقف مجاز توکن‌های خروجی می‌رسید و در نتیجه پاسخ معتبری برای آن‌ها ثبت نمی‌شد. بررسی خروجی‌ها نشان داد که مدل در برخی موارد وارد چرخه‌ای تکرارشونده از بازبینی و اصلاح پاسخ خود می‌شود؛ رفتاری که به‌ویژه در نمونه‌های دارای تصاویر پیچیده یا گزینه‌های پاسخ بسیار مشابه بیشتر مشاهده شد. برای بررسی این مسئله، آزمایش با افزایش حداکثر طول خروجی تکرار شد، اما الگوی مذکور همچنان ادامه داشت. بررسی مستندات مدل نیز نشان داد که استفاده از تنظیمات پیشنهادی و پیش‌فرض خانواده Qwen می‌تواند شدت چنین رفتارهایی را کاهش دهد. با این حال، از آنجا که در طراحی آزمایش حاضر لازم بود تنظیمات تولید در میان مدل‌ها تا حد امکان ثابت نگه داشته شوند و سایر متغیرها تحت کنترل باقی بمانند، اعمال تنظیمات اختصاصی این مدل با پروتکل ارزیابی سازگار نبود. بنابراین، به منظور حفظ قابلیت مقایسه منصفانه نتایج، این مدل از مرحله ارزیابی روش‌های پرامپت‌دهی کنار گذاشته شد.

Qwen3.5-9B -۷-۳-۳

Qwen3.5-9B یکی از مدل‌های چندوجهی خانواده Qwen است. بخش زبانی آن حدود ۹ میلیارد پارامتر دارد و از معماری ترکیبی شامل Gated DeltaNet و Attention استفاده می‌کند. [۲۰]

دلیل انتخاب این مدل، بررسی یک مدل نسبتاً کوچک و در عین حال چندوجهی بود. حضور آن در کنار Qwen3.8-27B امکان بررسی تأثیر افزایش مقیاس در مدل‌های نزدیک از یک خانواده را نیز فراهم می‌کند. Qwen3.5-9B به صورت محلی در Kaggle اجرا شد و به منظور کاهش مصرف حافظه، نسخه کم‌دقت Q4_K_M مورد استفاده قرار گرفت.

این مدل نیز مشابه مدل بزرگ‌تر Qwen3.8-27B با پدیده ورود به چرخه تکرارشونده در فرایند پاسخ‌گویی مواجه بود؛ با این تفاوت که این رفتار در تعداد کمتری از نمونه‌ها مشاهده می‌شد. از این رو، این مدل گزینه

مناسبتی برای ارزیابی روش‌های مختلف پرامپت‌دهی در نظر گرفته شد، زیرا امکان بررسی تأثیر این روش‌ها بر کاهش یا تشدید رفتار تکرارشونده در مدل‌های خانواده Qwen را فراهم می‌کرد. علاوه بر این، به دلیل محدودتر بودن تعداد نمونه‌های درگیر با این مشکل، اثر آن بر نتایج کلی ارزیابی نیز کمتر بود.

۳-۳-۸- Qwen3-VL-30B-A3B-Instruct

Qwen3-VL-30B-A3B-Instruct یکی از مدل‌های چندوجهی مبتنی بر معماری MOE در خانواده Qwen است. این مدل حدود ۳۰ میلیارد پارامتر کلی دارد، اما تنها بخشی از متخصصان آن در هر مرحله فعال می‌شوند. [۲۱]

معماری Qwen3-VL به‌طور ویژه برای درک چندوجهی طراحی شده و از سازوکارهایی برای مدل‌سازی روابط مکانی و انتقال اطلاعات چندسطحی از بخش بصری به بخش زبانی استفاده می‌کند. [۲۱]

دلیل انتخاب این مدل، افزودن یک معماری MoE با تمرکز مستقیم بر وظایف چندوجهی بود. حضور آن در کنار Qwen3.8-27B متراکم و Qwen3.5-9B کوچک‌تر، سه نوع طراحی متفاوت را در یک خانواده فراهم می‌کند.

این مدل نیز به‌صورت محلی و در قالب GGUF کم‌دقت اجرا شد. پس از حدود ۱۰ ساعت اجرا، تنها ۴۰ نمونه توسط این مدل ارزیابی شده بود. با توجه به این نرخ پردازش، برآورد شد که اجرای کامل و ایمن مدل بر روی کل مجموعه داده به بیش از ۷۰ ساعت زمان نیاز خواهد داشت. از این‌رو، با در نظر گرفتن محدودیت‌های زمانی و سخت‌افزاری، ادامه اجرای حالت پایه این مدل عملی تشخیص داده نشد. در نتیجه، اجرای آن متوقف شد و این مدل نیز از مرحله ارزیابی روش‌های پرامپت‌دهی کنار گذاشته شد.

۳-۳-۹- تنظیمات مشترک استنتاج

در تمام مدل‌ها تلاش شد تنظیمات تولید تا حد امکان یکسان و قابل مقایسه باشند.

در تمام آزمایش‌های اصلی، دمای تولید برابر صفر انتخاب شد:

$$Temperature = 0.$$

هدف از این انتخاب، کاهش تصادفی بودن خروجی و افزایش قابلیت تکرار آزمایش‌ها بود. اگر برای دو پرامپت از نمونه‌گیری تصادفی شدید استفاده شود، بخشی از اختلاف نتیجه ممکن است صرفاً ناشی از تصادف باشد و نه تغییر پرامپت.

در مدل‌هایی که seed قابل تنظیم بود، مقدار ۴۲ به‌عنوان seed پایه در نظر گرفته شد. همچنین قابلیت‌های درونی موسوم به *native thinking* در مدل‌هایی که چنین امکانی داشتند، در

آزمایش‌های مقایسه‌ای غیرفعال شدند. دلیل این تصمیم آن بود که استدلال مورد مطالعه باید حاصل پرامپت تعریف‌شده در پژوهش باشد، نه یک حالت داخلی متفاوت که فقط برخی ارائه‌دهندگان از آن پشتیبانی می‌کنند. در شرایط عادی، پاسخ صحیح و توضیح مرجع سؤال هدف هیچ‌گاه در اختیار مدل قرار نگرفتند و تنها پس از پایان استنتاج برای محاسبه معیارها مورد استفاده قرار گرفتند.

مدل‌های محلی به دلیل محدودیت حافظه GPU های Kaggle عمدتاً به‌صورت کم‌دقت چهار بیتی اجرا شدند. این موضوع یک تصمیم مهندسی برای امکان اجرای مدل بود و جزئی از روش پرامپت‌دهی محسوب نمی‌شود.

۳-۴- ساخت داده‌های کمکی برای روش‌های چندنمونه‌ای و تولید دانش

۳-۴-۱- ستون Explanation و کاربرد آن

یکی از فیلدهای موجود در MMMU ستون explanation است. این ستون با answer تفاوت دارد. پاسخ تنها مشخص می‌کند کدام گزینه صحیح است، در حالی که explanation یک توضیح مرجع درباره علت صحیح بودن پاسخ ارائه می‌دهد. [۸]

به بیان دیگر:

نتیجه صحیح $\rightarrow$ Answer

در حالی که:

توضیح مرجع درباره چرایی نتیجه $\rightarrow$ Explanation

طراحان مجموعه داده این ستون را به‌عنوان توضیح تفصیلی پاسخ صحیح ارائه کرده‌اند تا علاوه بر گزینه نهایی، اطلاعاتی درباره استدلال یا دانش لازم برای رسیدن به آن نیز موجود باشد.

در این پژوهش explanation به‌عنوان زنجیره استدلال مدل در نظر گرفته نشد. explanation متن مرجع مجموعه داده است، در حالی که زنجیره استدلال مورد استفاده در پرامپت‌های چندنمونه‌ای توسط مدل تولید شده و قالب مرحله‌ای دارد.

همه نمونه‌های MMMU دارای explanation قابل استفاده نبودند. مقادیر خالی یا علامت‌هایی مانند ؟، none و null به‌عنوان explanation واقعی در نظر گرفته نشدند.

۳-۴-۲- انتخاب اولیه نمونه‌ها با اولویت Explanation

برای ساخت بانک زنجیره‌های استدلال، ابتدا لازم بود مجموعه‌ای از نمونه‌های مناسب انتخاب شود. صرف صحیح بودن پاسخ نهایی مدل برای پذیرفتن زنجیره استدلال کافی نیست. ممکن است مدل با استدلال ناقص یا حتی نادرست، تصادفاً به گزینه صحیح برسد. وجود explanation مرجع امکان بررسی دقیق‌تر این مسئله را

فراهم می‌کند.

به همین دلیل، در انتخاب مجموعه اولیه از سیاست Explanation-First استفاده شد؛ یعنی اولویت با نمونه‌هایی بود که explanation معتبر داشتند.

در مرحله توسعه، هدف ساخت مجموعه‌ای شامل ۴۵۰ نمونه بود:

$$30 \times 15 = 450.$$

در حالت ایده‌آل از هر موضوع پنج سؤال آسان، پنج سؤال متوسط و پنج سؤال دشوار انتخاب می‌شد، اما اولویت نخست وجود explanation بود و توازن دشواری در مرتبه بعد قرار داشت.

ترتیب انتخاب به‌طور کلی چنین بود:

۱. نمونه‌های دارای explanation معتبر؛

۲. در صورت کمبود، استفاده از سایر نمونه‌های قابل استفاده همان موضوع؛

۳. استفاده از نمونه فاقد explanation تنها در صورت نیاز برای تکمیل ظرفیت.

در نتیجه، وجود توضیح مرجع بر دستیابی مصنوعی به توازن کامل سطح دشواری اولویت داشت.

۳-۴-۳- تولید زنجیره استدلال با Gemma 4 31B

پس از انتخاب نمونه‌ها، برای تولید زنجیره استدلال از Gemma 4 31B استفاده شد. این انتخاب بر اساس عملکرد مدل در آزمایش‌های پایه پروژه انجام شد. Gemma 4 31B در میان مدل‌های مورد بررسی عملکرد بالایی داشت و به همین دلیل برای ساخت نمونه‌های نمایشی قابل اتکا انتخاب شد.

فرایند تولید زنجیره استدلال از دو فراخوانی جداگانه تشکیل شد.

در فراخوانی نخست، مدل سؤال، تصاویر و گزینه‌ها را دریافت می‌کرد، اما پاسخ صحیح و explanation مرجع در اختیار آن قرار نمی‌گرفت.

مدل موظف بود مسئله را به‌صورت مستقل حل کند و reasoning خود را در قالب:

Step 1:

Step 2:

...

Step N:

تولید کند.

پس از آن پاسخ نهایی مدل با پاسخ صحیح مقایسه می‌شد. اگر پاسخ مدل نادرست بود، نمونه وارد مرحله اعتبارسنجی نمی‌شد؛ زیرا هدف ساخت بانک زنجیره‌های استدلال صحیح بود.

۳-۴-۴- اعتبارسنجی زنجیره استدلال با استفاده از Explanation

صحیح بودن گزینه نهایی شرط لازم برای پذیرش زنجیره استدلال بود، اما کافی نبود. به همین دلیل، نمونه‌هایی که در فراخوانی نخست پاسخ صحیح تولید کرده بودند وارد مرحله دوم شدند. در این مرحله Gemma 4 31B دیگر وظیفه حل مجدد مسئله را نداشت، بلکه به عنوان اعتبارسنج زنجیره استدلال عمل می‌کرد. برخلاف مرحله نخست، در این مرحله پاسخ صحیح و explanation مرجع، در صورت وجود، در اختیار مدل قرار می‌گرفت.

اعتبارسنج بررسی می‌کرد که:

- پاسخ نهایی با پاسخ مرجع سازگار باشد؛
- زنجیره استدلال با explanation مرجع تناقض نداشته باشد؛

یکی از بررسی‌های مهم این مرحله، کنترل تناقض با explanation بود.

ممکن است مدل گزینه صحیح را انتخاب کرده باشد اما در استدلال یک مفهوم علمی یا یک رابطه را نادرست بیان کرده باشد. اگر این خطا با توضیح مرجع مجموعه داده ناسازگار باشد، زنجیره استدلال صرفاً به دلیل صحیح بودن گزینه نهایی پذیرفته نمی‌شود.

بنابراین explanation در این پروژه نقش مرجع مستقل برای کنترل کیفیت استدلال را داشت، نه محتوایی که برای تولید اولیه زنجیره استدلال به مدل داده شود.

پس از اعتبارسنجی خودکار، خروجی‌های پذیرفته شده یک بررسی منطقی نهایی نیز پشت سر گذاشتند.

Sample ID: test_Physics_12	Subject: Physics	Domain: STEM	Difficulty: Easy
----------------------------	------------------	--------------	------------------

Image

Question

A block of mass m is placed on a frictionless incline with an angle of 30° as shown in the figure. What is the magnitude of the component of the gravitational force acting parallel to the incline?

Options

A. mg
B. $mg/2$
C. $mg\sqrt{3}/2$
D. $mg/\sqrt{3}$

Chain-of-Thought (Generated by Gemma 4 31B)

- The component of the gravitational force parallel to the incline is given by $F_{\parallel} = mg \sin \theta$.
- Here, $\theta = 30^\circ$, so $\sin 30^\circ = 1/2$.
- Therefore, $F_{\parallel} = mg \times 1/2 = mg/2$.

Final Answer: B

Reference Explanation (from MMMU-Pro)

The component of gravity along the incline is $mg \sin \theta$. With $\theta = 30^\circ$, $\sin 30^\circ = 1/2$, so the parallel component is $mg/2$.

Correct Answer

B $mg/2$

شکل ۳-۲: نمونه‌ای از زنجیره‌ی استدلال تولید شده توسط Gemma4 31B

۳-۴-۵- تشکیل بانک نهایی ۴۰۵ نمونه‌ای

پس از مراحل تولید، بررسی پاسخ، اعتبارسنجی و بازبینی نهایی، بانک اصلی نمونه‌های نمایشی شامل ۴۰۵ نمونه پذیرفته‌شده تشکیل شد.


برای هر نمونه، علاوه بر سؤال، تصاویر، گزینه‌ها و پاسخ صحیح، زنجیره استدلال تولیدشده و تعداد مراحل آن ذخیره شد.

تعداد مراحل استدلال با متغیر:

$$N_{\text{steps}}$$

ثبت شد و بعداً در روش انتخاب نمونه بر اساس پیچیدگی زنجیره استدلال مورد استفاده قرار گرفت.

همچنین بررسی شد که هیچ نمونه‌ای از این بانک با Eval300 مشترک نباشد.



شکل ۳-۳: مراحل تولید زنجیره‌ی استدلال برای دیتاست کمکی توسط Gemma4 31B

۳-۴-۶- ساخت بانک دانش

روش تولید دانش به نمونه‌هایی نیاز دارد که به‌جای صرفاً نمایش پاسخ یا مراحل حل، یک دانش قابل انتقال را در اختیار مدل قرار دهند.

در این مرحله نیز explanation منبع اصلی استخراج مفهوم بود.

تفاوت دانش با زنجیره‌ی استدلال در این است که زنجیره‌ی استدلال نحوه حل همان سؤال را مرحله‌به‌مرحله توضیح می‌دهد، اما دانش باید یک اصل عمومی‌تر باشد که بتواند برای حل مسائل مشابه نیز مفید واقع شود.

در فرایند ساخت، ۲۵۹ نمونه کاندید به‌صورت جداگانه بررسی شدند. اگر explanation مستقیماً پاسخ همان سؤال را بیان می‌کرد، عبارت تا حد امکان به یک اصل، رابطه، تعریف یا سرنخ عمومی تبدیل می‌شد تا پاسخ مستقیم وارد دانش نشود.

در صورتی که explanation دارای یک ناسازگاری آشکار علمی یا محاسباتی بود، آن بخش به دانش منتقل نمی‌شد و تنها قسمت قابل دفاع حفظ می‌شد.

بانک نهایی دانش شامل ۱۴۹ نمونه یکتا بود. هدف اولیه پنج نمونه برای هر یک از ۳۰ موضوع بود؛ ۲۹ موضوع دارای پنج نمونه شدند و برای Architecture and Engineering چهار نمونه مناسب باقی ماند:

$$29 \times 5 + 4 = 149.$$

هر ردیف این بانک شامل سؤال، اطلاعات تصویر، گزینه‌ها، explanation در صورت وجود، زنجیره‌ی استدلال معتبر، تعداد مراحل و دانش استخراج‌شده بود.

۳-۴-۷- ساخت بازنمایی‌های برداری

روش‌های مبتنی بر شباهت نیازمند تبدیل سؤال و تصویر به بردارهای عددی بودند.

برای این منظور از CLIP ViT-L/14 استفاده شد.

برای هر سؤال، متن و تصاویر به صورت جداگانه پردازش شدند.

در بخش متنی تنها متن اصلی سؤال وارد رمزگذار شد و موارد زیر از بازنمایی حذف شدند:

- گزینه‌ها؛
- پاسخ صحیح؛
- explanation؛
- زنجیره استدلال .

هدف از این تصمیم آن بود که بازیابی نمونه‌های مشابه بر اساس خود مسئله انجام شود و اطلاعات مربوط به پاسخ در انتخاب نمونه‌های نمایشی اثر نگذارد.

هر تصویر نیز به صورت مستقل به بردار تبدیل شد. بنابراین اگر یک سؤال دارای چند تصویر بود، هر تصویر بازنمایی مخصوص به خود را حفظ می‌کرد و در مرحله ساخت داده، تصاویر با یکدیگر میانگین‌گیری نمی‌شدند.

بردارهای خروجی CLIP دارای بعد ۷۶۸ بودند:

$$e \in \mathbb{R}^{768}.$$

بردارها نرمال‌سازی شدند تا بتوان از شباهت کسینوسی برای مقایسه آن‌ها استفاده کرد.

در نهایت چهار مجموعه بازنمایی تشکیل شد:

$$E_Q^{text}, E_Q^{image}, E_D^{text}, E_D^{image},$$

که به ترتیب مربوط به متن سؤال‌های ارزیابی، تصاویر آن‌ها، متن نمونه‌های نمایشی و تصاویر نمونه‌های نمایشی بودند.

۳-۵- روش‌های پرامپت‌دهی

۳-۵-۱- معیار انتخاب روش‌های پرامپت‌دهی

انتخاب روش‌های پرامپت‌دهی در این پژوهش صرفاً با هدف مقایسه چند روش رایج انجام نشد. روش‌ها با توجه به ماهیت توانایی‌هایی انتخاب شدند که MMMU و MMMU-Pro برای سنجش آن‌ها طراحی شده‌اند.

طراحان MMMU مسائل این مجموعه را نیازمند ترکیبی از ادراک بصری، دانش تخصصی و استدلال سنجیده معرفی می‌کنند. MMMU-Pro نیز با حذف سؤال‌هایی که بدون تصویر قابل حل بودند، همین هدف

را با سخت‌گیری بیشتری دنبال می‌کند. [۱۵]

بر این اساس، در انتخاب روش‌های پرامپت‌دهی سه مؤلفه مورد توجه قرار گرفت:

"ادراک بصری"، "دانش" و "استدلال".

منظور از این تقسیم‌بندی آن نیست که هر روش فقط یکی از این توانایی‌ها را اندازه‌گیری می‌کند؛ زیرا در یک مسئله چندوجهی این سه مؤلفه به یکدیگر وابسته‌اند. هدف آن بود که روش‌هایی انتخاب شوند که بخش متفاوتی از فرایند حل مسئله را برجسته کنند.

برای مثال، گراف صحنه مدل را وادار می‌کند قبل از پاسخ‌گویی محتوای تصویر را در قالب ساختاریافته بیان کند؛ [۱۱] برنامه‌ریزی و حل مرحله برنامه‌ریزی را پیش از اجرای استدلال قرار می‌دهد؛ [۱۰] و تولید دانش تلاش می‌کند دانش مرتبط موجود در مدل را پیش از پاسخ نهایی فعال سازد. [۲۳]

در نتیجه، هدف از این بخش تنها بررسی افزایش یا کاهش دقت نبود، بلکه بررسی این موضوع نیز بود که آیا می‌توان با مداخله در بخش‌های مختلف فرایند حل مسئله، رفتار مدل را بهبود داد.

روش‌ها در دو گروه اصلی بررسی شدند:

۱. روش‌های بدون نمونه؛
۲. روش‌های چندنمونه‌ای و یادگیری درون‌متنی چندوجهی .

۳-۵-۲- روش‌های بدون نمونه

در روش بدون نمونه، هیچ مثال حل‌شده‌ای پیش از سؤال هدف در اختیار مدل قرار نمی‌گیرد. مدل تنها مسئله اصلی و دستور مربوط به روش را دریافت می‌کند.

این گروه برای پژوهش حاضر اهمیت دارد، زیرا اجازه می‌دهد تأثیر تغییر ساختار instruction یا افزودن یک مرحله میانی بدون تأثیر کیفیت و انتخاب نمونه‌های نمایشی بررسی شود. در تمام روش‌های این گروه، سؤال، تصاویر، گزینه‌ها و قالب پاسخ نهایی تا حد امکان ثابت باقی ماندند.

۳-۵-۳- حالت پایه

برای تمام روش‌ها یک حالت پایه بر اساس مقاله‌ی MMMU-pro به‌عنوان مرجع مقایسه تعریف شد. [۱۵] در این حالت هیچ نمونه نمایشی، طرح حل، گراف صحنه یا دانش تولیدشده‌ای به مدل داده نمی‌شود. متن انتهایی پرامپت از مدل می‌خواهد سؤال چندگزینه‌ای را پاسخ دهد، استدلال خود را توضیح دهد و آخرین خط را با قالب مشخص ارائه کند:

Answer the preceding multiple choice question.

The last line of your response should be of the following format:

“Answer: \$LETTER” ...

Explain your reasoning before answering.[۱۵]

بنابراین حالت پایه این پژوهش فقط پاسخ کوتاه تولید نمی‌کند، بلکه دارای توضیح قابل مشاهده است؛ با این حال مدل به روش خاصی مانند استدلال مرحله‌ای، برنامه‌ریزی یا ساخت گراف مجبور نمی‌شود. این حالت مبنای تمام مقایسه‌های بعدی قرار گرفت. این پرامپت بر روی هر هفت مدل منتخب ارزیابی شد. علاوه بر این، برای مدل Gemma 4 31B، آزمایش جداگانه‌ای با فعال بودن حالت Thinking و با استفاده از تنظیمات پیش‌فرض مدل نیز انجام گرفت.

۳-۵-۴- زنجیره استدلال بدون نمونه

روش Chain-of-Thought Prompting توسط Wei و همکاران با هدف ایجاد مراحل میانی استدلال در حل مسائل چندمرحله‌ای معرفی شد. [۲۴]

دلیل انتخاب این روش در پژوهش حاضر ارتباط مستقیم آن با مؤلفه استدلال در MMMU-Pro است. اگر مدل در حالت پایه برخی مراحل محاسباتی یا منطقی را به صورت ضمنی یا ناقص انجام دهد، درخواست صریح استدلال مرحله‌ای می‌تواند آن را به تجزیه مسئله به مراحل کوچک‌تر سوق دهد.

این انتخاب علاوه بر مبنای عمومی CoT، مستقیماً با روش ارزیابی MMMU-Pro نیز مرتبط است. نویسندگان MMMU-Pro خود اثر Chain-of-Thought را بررسی کرده‌اند و در قالب رسمی ارزیابی از عبارت: Think step by step before answering.

استفاده کرده‌اند. [۱۵]

در پژوهش حاضر همین قالب به حالت پایه افزوده شد. بنابراین مهم‌ترین تفاوت این روش با Baseline، الزام صریح مدل به تفکر مرحله‌به‌مرحله بود و سایر بخش‌های ورودی تغییر نکردند.

این پرامپت صرفاً بر روی چهار مدلی ارزیابی شد که برای بررسی و مقایسه روش‌های پرامپت‌دهی انتخاب شده بودند.

۳-۵-۵- Plan-and-Solve

روش Plan-and-Solve Prompting توسط Wang و همکاران در سال ۲۰۲۳ ارائه شد. [۱۰] یکی از انگیزه‌های اصلی این روش، مشاهده خطاهایی بود که در آن مدل هنگام استدلال یک یا چند مرحله ضروری را از قلم می‌اندازد. نویسندگان این مسئله را در کنار خطاهای محاسباتی و سوءبرداشت معنایی به عنوان یکی از مشکلات Zero-shot CoT بررسی می‌کنند.

قالب اصلی روش از مقاله Plan-and-Solve گرفته شد و با دستور:

Let's first understand the problem and devise a plan to solve the problem. Then, let's carry out the plan and solve the problem step by step.

مدل را ابتدا به طراحی plan و سپس اجرای آن هدایت می‌کند. [۱۰]

این روش در پژوهش حاضر به طور خاص برای بررسی این فرض انتخاب شد که برنامه‌ریزی پیش از شروع

حل می‌تواند احتمال فراموش شدن مراحل ضروری استدلال را کاهش دهد.
 باین حال، در پیاده‌سازی این پژوهش یک تغییر آگاهانه در قالب اصلی ایجاد شد. به جای انجام برنامه‌ریزی و اجرا در یک فراخوانی، فرایند به دو فراخوانی جداگانه تقسیم شد.
 در مرحله نخست:

$$(Q, I) \rightarrow Plan$$

و مدل تنها مأمور طراحی برنامه حل بود.
 در مرحله دوم:

$$(Q, I, Plan) \rightarrow Reasoning + Answer.$$

Plan تولیدشده در مرحله نخست بدون اصلاح یا بازنویسی در اختیار مدل قرار گرفت و از مدل خواسته شد همان برنامه را گام‌به‌گام اجرا کند.
 این طراحی سبب می‌شود مرحله برنامه‌ریزی از مرحله حل قابل تفکیک باشد و مدل در مرحله دوم صراحتاً بر اساس همان plan پیش برود.
 این پرامپت صرفاً بر روی چهار مدلی ارزیابی شد که برای بررسی و مقایسه روش‌های پرامپت‌دهی انتخاب شده بودند.

۳-۵-۶- زنجیره استدلال ترکیبی و گراف صحنه

روش Compositional Chain-of-Thought توسط Mitra و همکاران در سال ۲۰۲۴ برای مدل‌های چندوجهی ارائه شد. [۱۱]
 انگیزه اصلی این روش آن است که مدل ممکن است پیش از شروع reasoning، برداشت دقیقی از اشیا، ویژگی‌ها یا روابط موجود در تصویر نداشته باشد. در چنین شرایطی، حتی reasoning منطقی بر پایه اطلاعات بصری نادرست به پاسخ اشتباه منجر خواهد شد. [۱۱]
 در CCOT ابتدا مدل از تصویر و سؤال یک گراف صحنه تولید می‌کند. قالب این مرحله مستقیماً از مقاله اصلی اقتباس شده است و از مدل خواسته می‌شود:

۱. اشیای مرتبط با سؤال؛

۲. ویژگی‌های مرتبط اشیا؛

۳. روابط مرتبط میان اشیا

را استخراج کند.

در مقاله، خروجی گراف صحنه در قالب JSON ارائه می‌شود تا اطلاعات به‌شکل ساخت‌یافته و قابل

استفاده در مرحله بعد باقی بمانند [۱۱]. همین قالب در این پژوهش نیز حفظ شد.

برای هر تصویر:

$$(I_j, Q) \rightarrow SG_j^{JSON}$$

تولید شد.

در مرحله دوم، تصویر و گراف مربوط به همان تصویر همراه مسئله در اختیار مدل قرار گرفتند:


$$I_1, SG_1, \dots, I_n, SG_n, Q \rightarrow Answer.$$

دلیل انتخاب این روش در پژوهش حاضر ارتباط مستقیم آن با ادراک بصری بود. گراف صحنه یک بازنمایی میانی قابل مشاهده از برداشت مدل نسبت به تصویر ایجاد می‌کند.

از این رو، گراف‌های تولیدشده نیز ذخیره شدند تا در بررسی نمونه‌ها مشخص شود آیا خطای نهایی مدل از همان مرحله برداشت بصری وارد شده است یا گراف صحنه اطلاعات صحیحی داشته و خطا در استدلال بعدی ایجاد شده است.

به این ترتیب، CCoT علاوه بر آن که یک روش بهبود پاسخ است، ابزاری برای مشاهده بخشی از فرایند ادراک مدل نیز فراهم می‌کند.

این پرامپت صرفاً بر روی چهار مدلی ارزیابی شد که برای بررسی و مقایسه روش‌های پرامپت‌دهی انتخاب شده بودند.



شکل ۳-۰: نمونه‌ای از مراحل پرامپت گراف صحنه [۱۱]

۳-۵-۷- تولید دانش

روش Generated Knowledge Prompting توسط Liu و همکاران در سال ۲۰۲۲ ارائه شد. [۲۳] ایده اصلی این روش آن است که مدل ممکن است دانش مورد نیاز برای پاسخ به سؤال را در پارامترهای

خود داشته باشد، اما آن دانش هنگام مواجهه مستقیم با سؤال فعال نشود. بنابراین ابتدا دانش مرتبط تولید می‌شود و سپس همان دانش به عنوان زمینه اضافی در اختیار مدل قرار می‌گیرد. [۲۳]

از این رو، این روش در پژوهش حاضر با هدف بررسی مؤلفه دانش تخصصی انتخاب شد.

در مرحله نخست، چند نمونه سؤال-دانش به مدل نمایش داده شد و برای سؤال هدف سه دانش مستقل تولید گردید:

$$K_q = \{k_1, k_2, k_3\}.$$

قالب تولید دانش از ساختار مقاله اصلی GKP اقتباس شد. [۲۳]

برای ایجاد تنوع، هر یک از سه دانش با نمونه‌گیری جداگانه تولید شدند. پس از تولید، دانش‌ها ثابت شدند تا مرحله پاسخ‌گویی در اجراهای بعدی دقیقاً از همان دانش‌ها استفاده کند.

در مرحله بعد، هر دانش به طور مستقل همراه سؤال در اختیار مدل قرار گرفت:

$$(q, k_1), (q, k_2), (q, k_3).$$

مقاله اصلی GKP برای انتخاب پاسخ از احتمال گزینه‌ها استفاده می‌کند. [۲۳] بر همین اساس، در پژوهش حاضر نیز برای گزینه a :

$$S(a) = \max_m P(a, | q k_m)$$

محاسبه شد و پاسخ نهایی از رابطه:

$$\hat{a} = \arg \max_a S(a)$$

به دست آمد.

به دلیل نیاز این روش به احتمال یا Log Probability گزینه‌ها، GKP تنها روی مدل‌هایی اجرا شد که در محیط مورد استفاده امکان استخراج این اطلاعات را فراهم می‌کردند. در مجموعه مدل‌های این پژوهش، این آزمایش برای Qwen3.5-9B و InternVL3.5-8B انجام شد.

بنابراین هدف اصلی این آزمایش بررسی آن بود که آیا فعال‌سازی صریح دانش مرتبط پیش از پاسخ‌گویی می‌تواند خطاهایی را کاهش دهد که ممکن است از به کار گرفته نشدن دانش مناسب ناشی شده باشند.

۳-۵-۸- روش‌های چندنمونه‌ای و یادگیری درون‌متنی

در روش‌های چندنمونه‌ای، چند مثال حل‌شده پیش از سؤال هدف در اختیار مدل قرار می‌گیرند. برخلاف آموزش یا تنظیم دقیق مدل، در این حالت وزن‌های مدل تغییر نمی‌کنند و مثال‌ها تنها بخشی از زمینه ورودی

هستند. این رفتار تحت عنوان **یادگیری درون‌متنی** شناخته می‌شود.

در حالت چندوجهی، طراحی این فرایند پیچیده‌تر است؛ زیرا علاوه بر متن، تصویر نیز بخشی از نمونه نمایشی است. در نتیجه عواملی مانند تعداد نمونه‌ها، نحوه انتخاب آن‌ها، ترتیب نمونه‌ها، ترتیب متن و تصویر و محل قرارگرفتن دستور می‌توانند بر عملکرد اثر بگذارند.

در طراحی این بخش، دو پژوهش به‌طور خاص مورد توجه قرار گرفتند.

پژوهش *What Makes Multimodal In-Context Learning Work?* اثر Baldassini و همکاران، روش‌های انتخاب نمونه بر اساس شباهت چندوجهی از جمله RICES را بررسی می‌کند و نشان می‌دهد شباهت میان سؤال هدف و نمونه‌های نمایشی می‌تواند در عملکرد یادگیری درون‌متنی مؤثر باشد. [۲۵]

پژوهش *What Factors Affect Multi-Modal In-Context Learning? An In-Depth Exploration*

نیز عوامل مختلف مؤثر بر یادگیری درون‌متنی چندوجهی، از جمله انتخاب نمونه، ترتیب نمونه‌ها و ساختار پرامپت را به‌صورت نظام‌مند بررسی می‌کند. [۲۲]

بر اساس این مطالعات، سه تصمیم در طراحی آزمایش حاضر اتخاذ شد.

نخست، تعداد نمونه‌ها در تمام روش‌های اصلی برابر سه در نظر گرفته شد:

$$K = 3.$$

این انتخاب با تنظیم سه نمونه‌ای مورد استفاده در مطالعه Qin و همکاران همسو است. [۲۲] همچنین نتایج آن مطالعه نشان می‌دهد افزایش تعداد نمونه‌ها لزوماً همیشه موجب افزایش عملکرد نمی‌شود؛ بنابراین سه نمونه توازی میان ارائه اطلاعات کافی و محدود کردن حجم ورودی ایجاد می‌کند.

دوم، دستور اصلی قبل از نمونه‌های نمایشی قرار گرفت. این تصمیم با یافته‌های مربوط به introductory instruction در همان مطالعه سازگار است؛ قرار گرفتن دستور پیش از نمونه‌ها به مدل کمک می‌کند پیش از مشاهده نمونه‌ها، وظیفه مورد انتظار را درک کند. [۲۲]

سوم، در ساختار نمونه‌های نمایشی، ابتدا اطلاعات تصویری و سپس متن سؤال ارائه شد. این ترتیب نیز با یافته‌های مطالعه مذکور درباره ترتیب modality ها در نمونه‌های چندوجهی همسو است. [۲۲]

۳-۵-۹- سه نمونه‌ای تصادفی بدون زنجیره استدلال

برای ایجاد یک حالت مرجع ساده، سه نمونه نمایشی به‌صورت تصادفی انتخاب شدند.

در این حالت هر نمونه نمایشی شامل تصویر، سؤال، گزینه‌ها و پاسخ صحیح بود، اما زنجیره استدلال آن در اختیار مدل قرار نمی‌گرفت.

در نسخه نهایی مورد گزارش، انتخاب به‌صورت مخصوص هر سؤال هدف انجام شد. یعنی برای هر query

سه نمونه تصادفی مستقل انتخاب شدند:

$$D_R(q_i) = \{d_{i1}, d_{i2}, d_{i3}\}.$$

در نتیجه، سه نمونه مربوط به یک سؤال معمولاً با نمونه‌های سؤال دیگر متفاوت هستند. نمونه‌گیری بدون جایگذاری انجام شد و در انتخاب آن از شباهت، موضوع یا سطح دشواری استفاده نشد. برای حفظ بازتولیدپذیری، تصادفی‌بودن کنترل شد؛ به این معنا که برای هر سؤال seed مشخص و قابل تکراری ساخته شد. بنابراین اگر آزمایش دوباره اجرا شود، همان سؤال همان سه نمونه را دریافت خواهد کرد. هدف این روش بررسی اثر صرف مشاهده چند نمونه حل‌شده بدون انتخاب هوشمند و بدون نمایش reasoning بود.

این پرامپت صرفاً بر روی چهار مدلی ارزیابی شد که برای بررسی و مقایسه روش‌های پرامپت‌دهی انتخاب شده بودند.

۳-۵-۱۰- چندنمونه‌ای مبتنی بر شباهت بدون زنجیره استدلال

در این روش، انتخاب تصادفی با انتخاب بر اساس شباهت جایگزین شد. ایده استفاده از نمونه‌های مشابه از پژوهش‌های مربوط به RICES و به‌ویژه مقاله *What Makes Multimodal In-Context Learning Work?* [۲۵] از آنجا که MMMU-Pro شامل موضوعات علمی متفاوت است، ابتدا نمونه‌های کاندید به همان موضوع سؤال محدود شدند:

$$D_q = \{d \mid \text{Subject}(d) = \text{Subject}(q)\}.$$

سپس شباهت متن و تصویر به‌طور جداگانه محاسبه شد. شباهت متنی:

$$S_T(q, d) = \cos(E_q^{\text{text}}, E_d^{\text{text}})$$

و شباهت تصویری برای نمونه‌های چندتصویری برابر میانگین تمام جفت‌های تصویر بود:

$$S_I(q, d) = \frac{1}{|I_q| |I_d|} \sum_i \sum_j \cos(E_{q,i}^{\text{image}}, E_{d,j}^{\text{image}}).$$

امتیاز نهایی از مجموع دو بخش به دست آمد:

$$S(q, d) = S_T(q, d) + S_I(q, d).$$

استفاده هم‌زمان از متن و تصویر با یافته‌های مقاله *What Factors Affect Multi-Modal In-Context*

Learning? درباره مزیت انتخاب چندوجهی نسبت به انتخاب تکوجهی همسو است. [۲۲]

باین حال، فرمول دقیق فوق مخصوص طراحی این پژوهش است و عیناً از یک مقاله کپی نشده است؛ زیرا لازم بود ساختار چندتصویری MMMU-Pro نیز در محاسبه شباهت لحاظ شود. سه نمونه با بالاترین امتیاز انتخاب شدند:

$$D^*(q) = Top3 S(q, d).$$

در این حالت نیز زنجیره استدلال نمونه‌ها در اختیار مدل قرار نگرفت؛ بنابراین اثر انتخاب نمونه مرتبط مستقل از اثر نمایش استدلال بررسی می‌شود. این پرامپت صرفاً بر روی چهار مدلی ارزیابی شد که برای بررسی و مقایسه روش‌های پرامپت‌دهی انتخاب شده بودند.

۳-۵-۱۱- چند نمونه‌ای مبتنی بر شباهت همراه زنجیره استدلال

در روش بعدی، نحوه انتخاب نمونه دقیقاً مشابه بخش قبل بود، اما علاوه بر سؤال و پاسخ، زنجیره استدلال معتبر نیز در اختیار مدل قرار گرفت.

دلیل افزودن CoT به نمونه‌ها از پژوهش Chain-of-Thought Prompting Elicits Reasoning in Large Language Models گرفته شده است. Wei و همکاران نشان دادند که نمونه‌هایی که علاوه بر پاسخ صحیح، مراحل رسیدن به پاسخ را نیز نمایش می‌دهند، می‌توانند مدل را به تولید reasoning میانی برای سؤال جدید سوق دهند. [۲۴]

بنابراین هر نمونه نمایشی در این روش دارای ساختار:

{Image, Question, Options, Reasoning, Answer}

بود.

زنجیره‌های استدلال مورد استفاده همان زنجیره‌هایی بودند که توسط Gemma 4 31B تولید و سپس اعتبارسنجی شده بودند.

این طراحی امکان مقایسه مستقیمی میان دو وضعیت زیر فراهم می‌کند:

Similarity + Answer

و:

Similarity + CoT + Answer.

از آنجا که سیاست انتخاب نمونه در هر دو حالت یکسان است، می‌توان بررسی کرد آیا تغییر عملکرد تنها ناشی از مشاهده نمونه مشابه است یا نمایش نحوه استدلال نمونه مشابه نیز نقش اضافی دارد. این پرامپت صرفاً بر روی چهار مدلی ارزیابی شد که برای بررسی و مقایسه روش‌های پرامپت‌دهی انتخاب

شده بودند.

۳-۵-۱۲- انتخاب نمونه بر اساس پیچیدگی زنجیره استدلال

روش Complexity-Based Prompting توسط Fu و همکاران با این فرض ارائه شده است که تمام زنجیره‌های استدلال ارزش آموزشی یکسانی ندارند. [۲۶]

در این روش، نمونه‌هایی با استدلال پیچیده‌تر و مراحل بیشتر در اولویت قرار می‌گیرند. منطق اصلی مقاله آن است که یک زنجیره استدلال طولانی‌تر معمولاً شامل مراحل پایه‌ای موجود در مسائل ساده‌تر نیز هست. به بیان ساده، استدلال پیچیده می‌تواند الگوهایی مانند استخراج اطلاعات، انتخاب رابطه، محاسبه و نتیجه‌گیری را هم‌زمان در خود داشته باشد؛ در حالی که یک نمونه بسیار کوتاه ممکن است تنها بخشی از این الگو را نمایش دهد. [۲۶]

در پژوهش حاضر پیچیدگی با تعداد مراحل زنجیره استدلال تعریف شد:

$$C(d) = N_{\text{steps}}(d).$$

ابتدا نمونه‌های همان موضوع انتخاب شدند و سپس تعداد steps ها معیار اصلی رتبه‌بندی بود:

$$N_{\text{steps}} \downarrow.$$

در صورت برابری تعداد مراحل، سطح دشواری به‌عنوان معیار دوم استفاده شد:

$$Hard > Medium > Easy.$$

اگر همچنان چند نمونه در وضعیت برابر قرار داشتند، شباهت چندوجهی متن و تصویر به‌عنوان معیار سوم مورد استفاده قرار گرفت:

$$Similarity \downarrow.$$

بنابراین ترتیب کلی معیارها چنین بود:

$$\boxed{\text{شباهت چندوجهی} \rightarrow \text{سطح دشواری} \rightarrow \text{تعداد مراحل}}$$

سه نمونه دارای بالاترین اولویت انتخاب شدند و زنجیره استدلال کامل آن‌ها نیز در اختیار مدل قرار گرفت. در نتیجه، برخلاف روش مبتنی بر شباهت که سؤال اصلی آن «کدام نمونه به مسئله هدف نزدیک‌تر است؟» است، در روش پیچیدگی سؤال اصلی این است که (کدام نمونه الگوی استدلال غنی‌تری برای نمایش به مدل دارد؟)

این پرامپت صرفاً بر روی چهار مدلی ارزیابی شد که برای بررسی و مقایسه روش‌های پرامپت‌دهی انتخاب

شده بودند.

۳-۶- پروتکل اجرا و استخراج پاسخ

۳-۶-۱- محیط اجرای آزمایش‌ها

تمام مراحل آزمایش در محیط Kaggle Notebooks مدیریت شدند.

در این پژوهش، Kaggle تنها برای اجرای مدل‌های محلی استفاده نشد، بلکه محیط اصلی اجرای کل فرایند بود. بارگذاری داده، بازسازی Eval300، ساخت پرامپت، انتخاب نمونه‌های نمایشی، ساخت بازنمایی‌ها، فراخوانی مدل‌ها، ذخیره پاسخ و تحلیل اولیه نتایج همگی از طریق notebookهای این محیط انجام شدند. مدل‌هایی که امکان اجرای محلی آن‌ها با منابع موجود وجود داشت، از طریق llama.cpp اجرا شدند. برای مدل‌هایی که اجرای محلی آن‌ها با منابع موجود مناسب نبود، درخواست از همان notebookهای Kaggle به رابط برنامه‌نویسی رسمی ارائه‌دهنده مدل ارسال شد. به این ترتیب، تفاوت local و API تنها به محل انجام محاسبات اصلی مدل مربوط بود و مدیریت آزمایش در هر دو حالت از طریق یک محیط واحد انجام شد.

۳-۶-۲- حفظ ترتیب تصاویر

در سؤالات MMMU-Pro تعداد و محل تصاویر یکسان نیست. برخی نمونه‌ها یک تصویر، برخی چند تصویر و برخی تصاویر مرتبط با گزینه‌های پاسخ دارند. در پیاده‌سازی، تصاویر به‌عنوان مجموعه‌ای بدون ترتیب در ابتدای ورودی قرار نگرفتند. markerهای موجود در سؤال و گزینه‌ها استخراج شده و ترتیب واقعی آن‌ها حفظ شد. در نتیجه اگر سؤال دارای چند تصویر باشد، ترتیب قرارگیری آن‌ها با ترتیب مورد انتظار مسئله منطبق باقی می‌ماند. این موضوع به‌ویژه در روش CCoT اهمیت دارد، زیرا هر گراف صحنه باید دقیقاً در کنار تصویر متناظر خود قرار گیرد.

۳-۶-۳- ضرورت طراحی استخراج‌گر پاسخ

خروجی مدل‌های زبانی-بصری یک متن آزاد است، در حالی که برای محاسبه دقت در MMMU-Pro لازم است از پاسخ مدل یک گزینه مشخص استخراج شود. برای مثال مدل ممکن است چند پاراگراف استدلال تولید کرده و در انتها بنویسد:

Answer: C

در چنین شرایطی باید بخش توضیح از پاسخ نهایی جدا شود.

اگر این فرایند با یک روش ثابت انجام نشود، نتیجه آزمایش می‌تواند به‌شدت به نحوه تفسیر متن وابسته

شود. برای مثال، ممکن است مدل در استدلال ابتدا گزینه A را بررسی کرده و سپس آن را رد کند. اگر سیستم تمام متن را برای یافتن حروف گزینه جست‌وجو کند، احتمال استخراج نادرست وجود خواهد داشت. به همین دلیل، در این پژوهش یک استخراج‌گر پاسخ قطعی و مستقل از پاسخ صحیح طراحی شد. سه ویژگی اصلی آن عبارت بودند از:

قطعی بودن + عدم دسترسی به پاسخ صحیح + تمرکز بر پاسخ نهایی.

۳-۶-۴- فضای پویا برای گزینه‌های پاسخ

از آنجا که همه سؤال‌ها دقیقاً ده گزینه ندارند، استخراج‌گر نیز نمی‌تواند برای تمام نمونه‌ها مجموعه ثابتی از حروف A تا J را معتبر بداند. برای سؤال q با n_q گزینه:

$$\mathcal{A}_q = \{A_1, \dots, A_{n_q}\}$$

تعریف شد.

بنابراین برای سؤال چهارگزینه‌ای تنها:

$$\{A, B, C, D\}$$

و برای سؤال ده‌گزینه‌ای:

$$\{A, \dots, J\}$$

معتبر هستند.

در نتیجه اگر مدل برای یک سؤال چهارگزینه‌ای پاسخ G تولید کند، پاسخ قابل قبول تلقی نمی‌شود.

۳-۶-۵- قالب پاسخ نهایی

در تمام پرامپت‌های اصلی از مدل خواسته شد آخرین خط پاسخ را در قالب زیر تولید کند:

Answer: \$LETTER

که در آن \$LETTER تنها یک جای‌نگهدار است.

برای مثال پاسخ واقعی باید به شکل:

Answer: B

باشد.

وجود قالب ثابت در انتهای پاسخ سبب می‌شود مدل بتواند استدلال آزاد تولید کند، در حالی که تصمیم نهایی همچنان در محل از پیش تعیین‌شده قرار دارد.

۳-۶-۶- استخراج پاسخ از آخرین خط

استخراج گر اصلی ابتدا آخرین خط غیر خالی پاسخ را بررسی می کند.
شکل اصلی مورد انتظار:

Answer: B

است.

برای جلوگیری از آن که اختلاف های بسیار جزئی نگارشی به عنوان خطای محتوایی ثبت شوند،
شکل هایی مانند:

Answer: \$B

Answer: \$B\$

Answer: (B)

نیز قابل استخراج هستند.

باین حال، این انعطاف تنها در آخرین خط پاسخ اعمال می شود. متن استدلال برای حدس زدن گزینه
اصلی جست و جو نمی شود.

۳-۶-۷- عدم حدس پاسخ از متن استدلال

فرض شود مدل در متن خود بنویسد:

ابتدا گزینه A محتمل به نظر می رسد، اما با توجه به نمودار گزینه C صحیح است.

اما به دلیل پایان یافتن طول تولید، هیچ خط نهایی Answer: ایجاد نشود.

در این پژوهش سیستم از متن بالا حدس نمی زند که پاسخ C بوده است.

در چنین حالتی:

No Valid Final Answer $\Rightarrow$ Parse Failure.

این تصمیم عمداً محافظه کارانه اتخاذ شد تا سیستم ارزیابی خود به مدل در تکمیل یا تفسیر پاسخ
کمک نکند.

۳-۶-۸- پاسخ های ناقص و پایان ناشی از محدودیت طول

در برخی اجراها ممکن است مدل پیش از تولید پاسخ نهایی به سقف طول خروجی برسد.

اگر پاسخ نهایی معتبر وجود نداشته باشد، چنین نمونه ای به عنوان پاسخ قابل استخراج ثبت نمی شود.

این نمونه صرفاً به این دلیل که استدلال آن ظاهراً به یک گزینه اشاره می کند، به پاسخ صحیح یا غلط
خاصی تبدیل نمی شود.

همچنین چنین خروجی ای فقط به دلیل ناقص بودن مجدداً تولید نمی شود؛ زیرا تولید دوباره یک پاسخ
نامطلوب می تواند به مدل فرصت اضافی دهد و دقت نهایی را به صورت مصنوعی افزایش دهد.

۳-۶-۹- عدم استفاده از انتخاب تصادفی جایگزین

در برخی ارزیابی‌های چندگزینه‌ای ممکن است در صورت استخراج‌نشدن پاسخ، یک گزینه به‌صورت تصادفی انتخاب شود.

در این پژوهش چنین روشی در معیار اصلی استفاده نشد.
اگر پاسخ نهایی قابل استخراج نباشد:

$Prediction = Unparsed.$

هیچ انتخاب تصادفی برای جایگزینی آن انجام نمی‌شود.

این تصمیم به‌ویژه در مسائل دارای ده گزینه اهمیت دارد؛ زیرا حتی یک انتخاب تصادفی نیز دارای احتمال ۱۰ درصد برای صحیح‌بودن است و می‌تواند نتیجه را اندکی بهبود مصنوعی دهد.

۳-۶-۱۰- تفکیک استخراج پاسخ از رعایت دقیق قالب

دو مفهوم متفاوت ثبت شدند:

۱. قابلیت استخراج پاسخ؛

۲. رعایت دقیق قالب درخواست‌شده.

برای مثال:

Answer: \$B\$

از نظر محتوایی به‌وضوح گزینه B را بیان می‌کند و توسط استخراج‌گر قابل شناسایی است، اما دقیقاً با قالب درخواست‌شده:

Answer: B

برابر نیست.

بنابراین نرخ استخراج پاسخ و نرخ رعایت کامل قالب به‌صورت جداگانه نگهداری شدند.

۳-۶-۱۱- مستقل‌بودن استخراج‌گر از پاسخ صحیح

استخراج prediction پیش از مقایسه با پاسخ صحیح انجام می‌شود.

اگر raw response را با r_i نمایش دهیم:

$$\hat{y}_i = f_{\text{parser}}(r_i, \mathcal{A}_i).$$

تنها پس از تعیین $\hat{y}_i$ ، پاسخ با جواب مرجع مقایسه می‌شود:

$$Correct_i = \mathbb{1}[\hat{y}_i = y_i].$$

بنابراین استخراج‌گر نمی‌تواند برای رفع ابهام از Gold answer استفاده کند.

این ویژگی مانع آن می‌شود که در پاسخ‌های مبهم، سیستم ارزیابی ناخواسته به گزینه صحیح تمایل پیدا کند.

۳-۶-۱۲- ثابت‌بودن استخراج‌گر میان تمام روش‌ها

برای مقایسه منصفانه پرامپت‌ها، روش استخراج پاسخ نیز باید ثابت باشد. اگر برای حالت پایه استخراج‌گر سخت‌گیرانه و برای زنجیره‌ی استدلال استخراج‌گر انعطاف‌پذیرتری استفاده شود، بخشی از اختلاف دقت می‌تواند ناشی از تفاوت شیوه امتیازدهی باشد. از این‌رو نسخه استخراج‌گر در تمام آزمایش‌های مقایسه‌ای ثابت نگه داشته شد و پاسخ‌های ذخیره‌شده نیز در صورت نیاز مجدداً با همان نسخه پردازش شدند.

۳-۶-۱۳- جداسازی خطای قالب از خطای محتوایی

عدم استخراج پاسخ لزوماً به معنای اشتباه ادراکی، دانشی یا استدلالی نیست. ممکن است مدل استدلال صحیحی تولید کند اما به دلیل پایان طول خروجی یا رعایت نکردن قالب، پاسخ نهایی مشخصی ارائه نکند.

به همین دلیل موارد زیر به‌طور مستقل نگهداری شدند:

- خطای محتوایی؛
- خطای قالب یا استخراج؛
- پاسخ ناقص یا قطع‌شده .

این جداسازی برای مرحله تحلیل خطا اهمیت زیادی دارد؛ زیرا یک خطای صرفاً قالبی نباید به اشتباه به‌عنوان خطای ادراکی یا استدلالی مدل طبقه‌بندی شود.

۳-۶-۱۴- کنترل نسخه‌ها و بازتولیدپذیری

از آنجا که آزمایش‌ها طی نشست‌های مختلف Kaggle اجرا شدند، برای جلوگیری از تغییر ناخواسته اجزای آزمایش مجموعه‌ای از کنترل‌ها در نظر گرفته شد. نسخه مجموعه‌داده ثابت شد و فایل شناسه‌های Eval300 با مقدار درهم‌سازی SHA-256 کنترل شد. در مدل‌های محلی نیز فایل مدل، نگاشتگر چندوجهی و در موارد لازم فایل اجرایی runtime بررسی شدند.

برای پرامپت‌ها نیز نسخه و درهم‌سازی متن دستور ذخیره شد.

در روش‌های چندنمونه‌ای، شناسه نمونه‌های انتخاب‌شده برای هر query نگهداری شد. در روش‌های مبتنی بر شباهت، فایل‌های بازنمایی برداری، نوع رمزگذار، ابعاد بردار و سیاست نرمال‌سازی نیز ثبت شدند. بدین ترتیب تنها اجراهایی می‌توانند ادامه یک آزمایش قبلی در نظر گرفته شوند که مشخصات اصلی

آن‌ها با اجرای قبلی سازگار باشد.

۷-۳- بررسی امکان استفاده از مدل داور برای تشخیص نوع خطا

۷-۳-۱- انگیزه و هدف آزمایش

یکی از اهداف اصلی پژوهش حاضر، فراتر رفتن از مقایسه صرف پاسخ صحیح و غلط و بررسی نوع خطایی بود که در فرایند پاسخ‌گویی مدل‌های زبانی-بصری رخ می‌دهد. همان‌گونه که در بخش‌های پیشین بیان شد، مسائل MMMU-Pro برای حل‌شدن به ترکیبی از ادراک بصری، دانش تخصصی و استدلال نیاز دارند. در نتیجه، دو مدل ممکن است دقت نهایی یکسانی داشته باشند، اما منشأ پاسخ‌های نادرست آن‌ها کاملاً متفاوت باشد. در مرحله نخست، این پرسش مطرح شد که آیا می‌توان فرایند تعیین نوع خطا را با استفاده از یک مدل زبانی-بصری دیگر به صورت خودکار انجام داد. استفاده از یک مدل داور در صورت برخورداری از دقت کافی می‌توانست تحلیل تعداد زیادی از پاسخ‌ها را سریع‌تر کرده و وابستگی تحلیل به بررسی انسانی را کاهش دهد. برای ارزیابی این ایده، پیش از به کارگیری مدل داور بر روی خروجی‌های اصلی MMMU-Pro، یک آزمایش کنترل‌شده روی مجموعه‌ای انجام شد که نوع خطای هر نمونه از قبل مشخص بود. به این ترتیب می‌توانستیم مستقیماً اندازه‌گیری کنیم که یک مدل داور تا چه حد قادر است نوع خطای موجود در یک زنجیره استدلال نادرست را به درستی تشخیص دهد.

برای این منظور از مجموعه داده MMErrorR استفاده شد. MMErrorR توسط Shi و همکاران با تمرکز بر ارزیابی توانایی مدل‌های زبانی-بصری در تشخیص reasoning نادرست طراحی شده است. برخلاف benchmarkهایی که تنها پاسخ نهایی را بررسی می‌کنند، هر نمونه MMErrorR شامل یک زنجیره استدلال دارای خطا است و در وظیفه Error Type Classification مدل از وجود خطا آگاه است و باید نوع آن را تشخیص دهد [۱۲]. مجموعه رسمی شامل ۱۹۹۷ نمونه در شش حوزه اصلی و ۲۴ زیرحوزه است.

استفاده از MMErrorR در این مرحله تنها با هدف ارزیابی امکان‌پذیری مدل داور انجام شد. داده‌های این مجموعه در ارزیابی هفت مدل روی MMMU-Pro یا در تحلیل نهایی خطاهای پروژه به عنوان داده آزمایش استفاده نشدند.

۷-۳-۲- انتخاب انواع خطا و ساخت مجموعه ارزیابی

طبقه‌بندی اصلی MMErrorR شامل چهار نوع خطا است:

- خطای ادراک بصری؛
- خطای استدلال؛
- خطای درک سؤال؛

- خطای به کارگیری دانش .

با توجه به هدف پژوهش حاضر و همچنین سه مؤلفه اصلی مورد توجه در MMMU و MMMU-Pro ، تحلیل این پایان نامه بر سه نوع خطا متمرکز شد:

A: Visual Perception Error

B: Reasoning Error

D: Knowledge Deployment Error.

دسته Question Comprehension Error از این آزمایش کنار گذاشته شد. این تصمیم سبب شد طبقه بندی مورد استفاده مستقیماً با سه محور ادراک، استدلال و دانش که در تحلیل رفتار مدل ها مورد توجه بودند هم راستا شود.

برای آن که عملکرد مدل داور تحت تأثیر فراوانی نامتوازن کلاس ها قرار نگیرد، یک مجموعه ارزیابی متوازن شامل ۳۰۰ نمونه ساخته شد:

$$100A + 100B + 100D = 300.$$

در نتیجه، اگر یک مدل به صورت افراطی یک کلاس را بیشتر از سایر کلاس ها انتخاب کند، این رفتار مستقیماً در معیارهای کلاس به کلاس و ماتریس درهم ریختگی قابل مشاهده خواهد بود.

در آزمایش Gemma 4 31B علاوه بر توازن کلی سه کلاس، توزیع حوزه ها در داخل هر کلاس نیز حفظ شد. برای هر نوع خطا، سهم شش حوزه اصلی MMError متناسب با توزیع همان کلاس در مجموعه منبع در نظر گرفته شد و تعداد صحیح نمونه ها با روش largest-remainder محاسبه گردید. این طراحی باعث می شد ۱۰۰ نمونه یک کلاس به طور اتفاقی از یک یا دو حوزه خاص تشکیل نشوند .

در تمام آزمایش ها، پاسخ صحیح و برچسب واقعی نوع خطا در اختیار مدل داور قرار نمی گرفتند. ورودی مدل شامل تصویر، متن سؤال و زنجیره استدلال نادرست بود و مدل باید تنها بر اساس همین اطلاعات نوع خطا را تعیین می کرد.

از منظر طراحی، هر نمونه به طور مستقل بررسی می شد. بنابراین آزمایش ها از نوع طبقه بندی مستقل هر نمونه، بدون نمونه نمایشی و چندوجهی بودند و نتیجه یک نمونه بر تصمیم نمونه های دیگر تأثیری نداشت.

۳-۷-۳- ارزیابی LLaVA-Critic-7B به عنوان مدل داور

نخستین آزمایش با استفاده از LLaVA-Critic-7B انجام شد. این مدل توسط Xiong و همکاران به طور خاص برای ارزیابی خروجی مدل های چندوجهی توسعه یافته است. LLaVA-Critic بر پایه LLaVA-OneVision ساخته شده و با داده های مخصوص ارزیابی و نقد چندوجهی آموزش داده شده است. نویسندگان آن، مدل را یک ارزیاب عمومی برای سناریوهای LMM-as-a-Judge معرفی می کنند [۳].

بنابراین فرض اولیه آن بود که مدلی که به‌طور اختصاصی برای نقد و ارزیابی پاسخ‌های چندوجهی آموزش دیده است، می‌تواند گزینه مناسبی برای تشخیص نوع خطا نیز باشد.

برای هر نمونه، مدل سه جزء اصلی را دریافت می‌کرد:

Image + Question + Erroneous Reasoning.

همچنین تعریف سه نوع خطا در پرامپت قرار داده شد. مدل از قبل مطلع بود که زنجیره ارائه‌شده دارای خطا است؛ بنابراین وظیفه آن تشخیص وجود یا عدم وجود خطا نبود، بلکه باید مشخص می‌کرد خطای اصلی متعلق به کدام یک از سه دسته است.

در این آزمایش از مدل خواسته شد هیچ توضیح اضافی تولید نکند و تنها یکی از حروف A، B یا D را برگرداند:

Return exactly one uppercase letter: A, B, or D.

هدف از محدود کردن خروجی آن بود که اثر خطاهای قالب‌بندی کاهش یابد و طبقه‌بندی تا حد امکان به یک مسئله مستقیم سه کلاسه تبدیل شود.

استنتاج به‌صورت قطعی انجام شد. نمونه‌گیری غیرفعال بود، temperature برابر صفر و حداکثر طول پاسخ برابر هشت token در نظر گرفته شد. همچنین مجموعه ارزیابی شامل دقیقاً ۱۰۰ نمونه از هر یک از سه نوع خطا بود.

نتیجه این آزمایش نشان داد که تخصص مدل در نقش Critic لزوماً به معنای توانایی بالای آن در تفکیک منشأ خطا نیست. دقت کلی مدل برابر با:

$$Accuracy = 29.0\%$$

و میانگین F1 سه کلاس برابر با:

$$Macro-F1 = 0.2314$$

به دست آمد. علاوه بر این، ۴۶ پاسخ از ۳۰۰ پاسخ با قالب تعریف‌شده قابل استخراج نبودند.

Recall سه دسته نیز تفاوت زیادی داشت:

جدول ۳-۱: دقت مدل LLaVA-Critic-7B در تفکیک منشأ خطا

نوع خطا	Recall
ادراک بصری	۸٪
استدلال	۷۳٪
به‌کارگیری دانش	۶٪

بررسی ماتریس درهم‌ریختگی نشان داد مسئله فقط پایین‌بودن دقت نبود، بلکه مدل به‌شدت به سمت خطای استدلال گرایش داشت. در میان ۲۵۴ پاسخ قابل استخراج، توزیع پیش‌بینی‌ها به شکل زیر بود:

$$Pred(A) = 16, Pred(B) = 223, Pred(D) = 15.$$

بنابراین حدود ۸۷٫۸ درصد پاسخ‌های قابل استخراج به کلاس B نسبت داده شده بودند، در حالی که توزیع واقعی مجموعه ارزیابی کاملاً متوازن بود. این رفتار را می‌توان نوعی فروپاشی تصمیم به سمت یک کلاس غالب در نظر گرفت. در چنین شرایطی حتی اگر Recall یک کلاس نسبتاً مناسب باشد، مدل عملاً قادر به تفکیک سه منشأ متفاوت خطا نیست. در نتیجه، LLaVA-Critic-7B با وجود آن‌که برای وظایف ارزیابی چندوجهی طراحی شده است، در این تنظیم نتوانست عملکرد لازم برای استفاده به‌عنوان تشخیص‌دهنده خودکار نوع خطا را ارائه کند.

۳-۷-۴ استفاده از Gemma 4 31B به‌عنوان مدل داور

پس از نتیجه ضعیف LLaVA-Critic، آزمایش دوم با یک مدل زبانی-بصری عمومی اما به‌مراتب قوی‌تر، یعنی Gemma 4 31B IT انجام شد.

در این مرحله فرض این بود که ممکن است طبقه‌بندی نوع خطا بیش از آن‌که به «تخصص critic بودن» مدل وابسته باشد، به توانایی خود مدل در فهم تصویر، دنبال‌کردن استدلال و تمایز میان دانش نادرست و استدلال نادرست وابسته باشد. از این‌رو از یکی از قوی‌ترین مدل‌های موجود در مجموعه آزمایش استفاده شد. برخلاف آزمایش LLaVA-Critic که از مدل تنها یک حرف خواسته می‌شد، در این روش Gemma اجازه داشت ابتدا نمونه را تحلیل کرده و سپس برچسب نهایی را ارائه کند.

ورودی هر نمونه شامل موارد زیر بود:

Image + Question + Erroneous Reasoning + Error Taxonomy + Decision Rules.

تعریف سه خطای موردنظر نیز به صورت صریح در پرامپت ارائه می‌شد. برای مثال، در تعریف خطای ادراک تأکید شده بود که اطلاعات بصری به اشتباه برداشت شده‌اند، اما استدلال پس از فرض آن اطلاعات نادرست می‌تواند عمدتاً صحیح باشد. در مقابل، برای خطای استدلال فرض می‌شود اطلاعات بصری درست استخراج شده اما خطا در مراحل محاسبه یا استنتاج رخ داده است. در خطای دانشی نیز مشکل در انتخاب یا استفاده از دانش، قانون یا مفهوم بیرونی قرار دارد. این تعاریف مستقیماً در پرامپت ثابت آزمایش ثبت شده‌اند.

در انتهای پاسخ از مدل خواسته می‌شد نتیجه را با قالب مشخصی ارائه کند:

Final label: A

و تنها A، B یا D به عنوان خروجی معتبر پذیرفته می‌شدند. استخراج گر این آزمایش نیز سخت‌گیرانه بود و پاسخ‌هایی که آخرین خط آن‌ها مطابق قالب مورد انتظار نبود، نادرست محسوب می‌شدند. برای افزایش توان استدلال مدل، قابلیت داخلی thinking در بالاترین حالت مستندشده برای Gemma 4 در رابط Google فعال شد:

thinkingLevel = high.

تنظیمات تولید نیز برابر بود با:

Temperature = 1.0,
top_p = 0.95,
top_k = 64,
Seed = 42,

و:

MaxOutputTokens = 32768.

این تنظیمات در اجرای نهایی و قابل بازتولید آزمایش ثبت شده‌اند. همچنین مانند آزمایش قبل، پاسخ صحیح و برچسب واقعی نوع خطا هرگز وارد درخواست مدل نمی‌شدند. این اطلاعات تنها پس از دریافت prediction برای محاسبه معیارهای ارزیابی مورد استفاده قرار می‌گرفتند.

۳-۵ نتایج Gemma 4 31B در تشخیص نوع خطا

استفاده از Gemma 4 31B موجب بهبود قابل توجهی نسبت به LLaVA-Critic شد.

دقت نهایی به:

Accuracy = 65.33%

رسید و:

$$Macro-F1 = 0.6538$$

به دست آمد. به دلیل متوازن بودن سه کلاس، Balanced Accuracy نیز برابر با ۶۵٫۳۳ درصد بود. تمام ۳۰۰ خروجی نیز با موفقیت مطابق قالب تعریف شده استخراج شدند.

Recall سه نوع خطا عبارت بود از:

جدول ۳-۲: دقت مدل Gemma 4 31B در تفکیک منشأ خطا

نوع خطا	Recall
ادراک بصری	۷۳٪
استدلال	۶۲٪
به کارگیری دانش	۶۱٪

ماتریس درهم ریختگی به صورت زیر حاصل شد:

جدول ۳-۳: ماتریس درهم ریختگی نتایج تفکیک خطا توسط Gemma4 31B

نوع واقعی	استدلال	ادراک	دانش
ادراک بصری	۱۵	۷۳	۱۲
استدلال	۶۲	۹	۲۹
به کارگیری دانش	۲۳	۱۶	۶۱

این نتیجه دو نکته مهم را نشان می دهد.

نخست، برخلاف LLaVA-Critic، مدل Gemma چهار فروپاشی به سمت یک کلاس خاص نشد. تعداد

prediction های هر کلاس برابر بود با:

$$Pred(A) = 98, Pred(B) = 100, Pred(D) = 102.$$

یعنی توزیع خروجی تقریباً با توزیع متوازن مجموعه ارزیابی برابر بود.

دوم، با وجود این بهبود قابل توجه، هنوز:

$$100\% - 65.33\% = 34.67\%$$

از نمونه‌ها به نوع خطای نادرست نسبت داده شدند. به بیان دیگر، تقریباً یک نمونه از هر سه نمونه با وجود استفاده از یک مدل قوی، طبقه‌بندی صریح و قابلیت استدلال گسترده، به درستی طبقه‌بندی نشد.

این مسئله برای کاربرد موردنظر در پایان‌نامه اهمیت زیادی داشت. اگر برچسب‌های مدل داور مستقیماً به عنوان نوع خطای واقعی پذیرفته می‌شدند، این میزان خطا می‌توانست نتیجه تحلیل بعدی را به طور محسوس تغییر دهد. برای مثال، ممکن بود یک روش پرامپت‌دهی ظاهراً تعداد زیادی خطای استدلال را اصلاح کرده باشد، در حالی که بخش قابل توجهی از آن نمونه‌ها در واقع خطای دانش بوده‌اند.

در نتیجه، اگرچه Gemma 4 31B نشان داد که استفاده از یک VLM قوی برای تشخیص نوع خطا تا حد زیادی بهتر از critic کوچک‌تر عمل می‌کند، سطح اطمینان به دست آمده برای استفاده بدون بازبینی انسانی از برچسب‌ها کافی در نظر گرفته نشد.

لازم به تأکید است که عدد ۶۵٫۳۳ درصد، امتیاز رسمی Gemma روی کل MMError نیست. این نتیجه مربوط به مجموعه تشخیصی متوازن ۳۰۰ نمونه‌ای پژوهش حاضر، با حذف نمونه‌های Question Comprehension Error و محدود کردن فضای تصمیم به A/B/D است. همین محدودیت تفسیر در طراحی notebook نیز به صراحت ثبت شده است.

۳-۶ مقایسه دو رویکرد داوری خودکار

نتایج دو آزمایش نشان دادند که توانایی مدل‌های چندوجهی در نقد خروجی، به طور مستقیم معادل توانایی آن‌ها در تشخیص منشأ دقیق خطا نیست.

با وجود بهبود محسوس عملکرد Gemma 4 31B نسبت به LLaVA-Critic-7B، دقت ۶۵٫۳۳ درصد برای هدف این پژوهش کافی نبود. در این مسئله، برچسب نوع خطا مستقیماً مبنای تحلیل اثر روش‌های مختلف پرامپت‌دهی قرار می‌گیرد؛ بنابراین خطای حدود یک سوم نمونه‌ها در مرحله تعیین نوع خطا می‌توانست به نتیجه‌گیری نادرست درباره منشأ خطا و اثر هر روش منجر شود. به همین دلیل، استفاده از مدل زبانی-بصری به عنوان داور خودکار برای تحلیل نهایی انواع خطا در این پژوهش کنار گذاشته شد و برچسب‌های تولیدشده توسط این دو مدل در تحلیل نهایی خروجی‌های MMMU-Pro مورد استفاده قرار نگرفتند.

در نتیجه، آزمایش‌های LLaVA-Critic-7B و Gemma 4 31B در این پژوهش به عنوان یک مرحله امکان‌سنجی در نظر گرفته می‌شوند. آزمایش نخست نشان داد که استفاده مستقیم از یک مدل تخصصی نقد چندوجهی، در این تنظیم، با دقت پایین و گرایش شدید به یک کلاس همراه است. استفاده از یک مدل زبانی-

بصری قوی تر همراه با تعریف صریح دسته‌های خطا و قابلیت استدلال، عملکرد را به میزان قابل توجهی بهبود داد، اما میزان خطای باقی‌مانده همچنان بیشتر از آن بود که بتوان از برچسب‌های تولیدشده به‌عنوان مبنای قابل اتکای تحلیل نهایی استفاده کرد. از این‌رو، پس از این مرحله، روش داوری خودکار کنار گذاشته شد و تحلیل نوع خطا به‌صورت انسانی ادامه یافت.

۳-۸ انتخاب تحلیل انسانی به‌عنوان روش نهایی

۳-۸-۱ انتخاب تحلیل انسانی و تعیین دامنه بررسی

نتایج آزمایش‌های بخش پیشین نشان داد که استفاده از مدل داور، حتی در صورت به‌کارگیری یک مدل زبانی-بصری قدرتمند و ارائه تعریف صریح انواع خطا، دقت موردنیاز برای برچسب‌گذاری نهایی را فراهم نمی‌کند. از آنجا که تشخیص نادرست نوع خطا می‌توانست مستقیماً تحلیل اثر روش‌های پرامپت‌دهی را تحت تأثیر قرار دهد، در ادامه پژوهش تصمیم گرفته شد تعیین نوع خطا به‌صورت دستی و با بررسی مستقیم پاسخ‌های مدل‌ها انجام شود.

این تصمیم با شیوه تحلیل خطا در خانواده MMMU نیز هم‌راستا است. در مقاله اصلی MMMU، نویسندگان برای بررسی منشأ خطاهای مدل، نمونه‌ای از پاسخ‌های نادرست را انتخاب کرده و آن‌ها را با استفاده از ارزیابان متخصص، دانش حوزه و توضیح مرجع موجود در مجموعه داده بررسی کردند [۹]. در MMMU-Pro نیز نویسندگان با پیروی از همین روش، مجموعه‌ای از پاسخ‌های نادرست GPT-4o را به‌صورت کیفی بررسی کرده و منشأ خطاها را در دسته‌هایی مانند ادراک، دانش و استدلال تحلیل کردند [۱۵]. بنابراین، تحلیل انسانی در پژوهش حاضر علاوه بر نتیجه آزمایش‌های امکان‌سنجی، با روش تحلیل خطای benchmark مورد استفاده نیز سازگار بود.

باین‌حال، بررسی دستی تمام خروجی‌های هفت مدل در تمام روش‌های پرامپت‌دهی حجم بسیار زیادی از نمونه‌ها را ایجاد می‌کرد و انجام یک تحلیل دقیق و سازگار برای تمام آن‌ها عملی نبود. از این‌رو، برای مرحله تحلیل خطا دامنه بررسی به دو مدل محدود شد:

Gemma 4 26B-A4B

و

InternVL3.5-8B.

این انتخاب باعث شد حجم نمونه‌های مورد بررسی دستی در حد قابل مدیریت باقی بماند و در عین حال دو مدل از دو خانواده و دو مقیاس متفاوت در تحلیل حضور داشته باشند. Gemma 4 26B-A4B نماینده یک مدل بزرگ‌تر مبتنی بر معماری MOE بود، در حالی که InternVL3.5-8B یک مدل کوچک‌تر از خانواده‌ای

متفاوت را نمایندگی می‌کرد. بنابراین تحلیل خطا تنها به رفتار یک مدل یا یک خانواده معماری محدود نشد. در مرحله بعد، برای هر یک از این دو مدل، خروجی حالت پایه با خروجی روش‌های پرامپت‌دهی مقایسه شد و نمونه‌هایی که وضعیت پاسخ آن‌ها در اثر اعمال پرامپت تغییر کرده بود، برای بررسی دقیق‌تر انتخاب شدند. هدف این تحلیل تنها تعیین صحیح یا غلط بودن پاسخ نبود، بلکه مشخص کردن این موضوع بود که چه نوع خطایی در پاسخ اولیه وجود داشته و آیا روش پرامپت‌دهی توانسته آن خطا را برطرف کند، بدون تغییر باقی بگذارد یا خطای جدیدی ایجاد کند.

۳-۸-۲- دسته‌های خطا و تدوین دستورالعمل عملیاتی

سه نوع خطای مورد استفاده در این پژوهش مستقیماً از طبقه‌بندی مقاله MMError گرفته شدند: [۱۲]

VPE: Visual Perception Error

KDE: Knowledge Deployment Error

RE: Reasoning Error.

دسته Question Comprehension Error که در طبقه‌بندی اصلی MMError وجود دارد، در دامنه تحلیل حاضر مورد استفاده قرار نگرفت. MMError به‌طور مشخص برای بررسی استدلال نادرست و طبقه‌بندی نوع خطا در محیط چندوجهی طراحی شده است. [۱۲]

باین‌حال، برای آن‌که دو داور بتوانند این سه تعریف را به‌صورت یکنواخت روی خروجی‌های طبیعی مدل‌ها اعمال کنند، برای هر دسته معیارهای عملیاتی و قواعد مرزی طبق تعریف هر خطا در MMError تدوین شد. [۱۲]

خلاصه قواعد تصمیم‌گیری به شکل زیر بود:

جدول ۳-۴: قواعد تصمیم‌گیری در تحلیل خطا

نوع خطا	معیار عملیاتی اصلی
VPE	حداقل یک واقعیت بصری مرتبط با سؤال به اشتباه استخراج یا تفسیر شده باشد و این اشتباه در پاسخ نهایی نقش مؤثر داشته باشد.
KDE	اطلاعات بصری مرتبط درست دریافت شده باشند، اما مدل یک واقعیت، مفهوم، قانون یا فرمول نادرست یا نامتناسب را انتخاب یا به کار گرفته باشد.
RE	ادراک بصری و دانش موردنیاز صحیح باشند، اما خطا در محاسبه،

استنتاج منطقی، نسبت‌ها، واحدها یا ترکیب اطلاعات رخ داده باشد.

به‌طور خاص، برای مرزبندی VPE و RE بررسی می‌شد که آیا خطا پیش از استدلال و در برداشت اطلاعات تصویر رخ داده است یا اطلاعات تصویر درست بوده و عملیات بعدی نادرست انجام شده است. همچنین برای تفکیک KDE و RE یک قاعده ثابت در نظر گرفته شد: انتخاب قانون، فرمول یا مفهوم نادرست به KDE نسبت داده می‌شد، در حالی که انتخاب قاعده صحیح همراه با اجرای محاسباتی یا منطقی نادرست در گروه RE قرار می‌گرفت. این مرزبندی در فرم داوری به‌طور صریح ثبت شده بود.

۳-۸-۳- بررسی ارتباط خطا با پاسخ نهایی

در فرایند داوری، وجود هر اشتباه جزئی در استدلال برای تعیین نوع خطای اصلی کافی در نظر گرفته نشد. ممکن بود مدل جمله‌ای نادرست درباره تصویر یا یک واقعیت فرعی بیان کند که هیچ نقشی در انتخاب گزینه نهایی نداشته باشد. در چنین حالتی، آن اشتباه نباید صرفاً به دلیل وجودش موجب انتساب نمونه به VPE یا KDE می‌شد.

بنابراین داورها بررسی می‌کردند که آیا خطای مشاهده‌شده مرتبط با وظیفه و در مسیر تولید پاسخ نهایی مؤثر بوده است. برای مثال، اگر مدل رنگ یک شیء را اشتباه بیان کرده باشد اما سؤال هیچ وابستگی‌ای به رنگ نداشته باشد و پاسخ غلط از یک محاسبه نادرست ناشی شده باشد، اشتباه در رنگ مبنای برچسب VPE قرار نمی‌گیرد. این اصل در دستورالعمل با تأکید بر ارتباط خطا با نتیجه نهایی تعریف شده بود. این قاعده به‌ویژه برای خروجی‌های طولانی مدل‌ها اهمیت داشت؛ زیرا در استدلال‌های چندمرحله‌ای ممکن است چند عبارت نادرست وجود داشته باشند، در حالی که تنها یکی از آن‌ها عامل اصلی انحراف پاسخ باشد.

۳-۸-۴- داوری مستقل توسط دو ارزیاب

هر نمونه ابتدا به‌صورت مستقل توسط دو داور انسانی بررسی شد. هر دو داور از معیارهای یکسان استفاده می‌کردند، اما تا پایان مرحله مستقل به برچسب یکدیگر دسترسی نداشتند.

داوری صرفاً شامل ثبت یک حرف VPE، KDE یا RE نبود. فرم طراحی‌شده، داور را وادار می‌کرد ابتدا مؤلفه‌های اصلی استدلال را جداگانه بررسی کند. در بخش ادراک، مشخص می‌شد که آیا مدل ادعایی درباره تصویر داشته و آیا آن ادعا با واقعیت تصویر سازگار بوده است. در بخش دانش، صحت انتخاب و کاربرد دانش، فرمول، قانون یا مفهوم بررسی می‌شد. در بخش استدلال نیز درستی محاسبات، استنتاج منطقی، واحدها، نسبت‌ها و ترکیب کمیت‌ها ارزیابی می‌شد. فرم مستقل داوری این بررسی‌ها را به‌صورت ستون‌های جداگانه ثبت می‌کرد.

پس از بررسی این مؤلفه‌ها، داور کاندید نوع خطا را ثبت کرده و یک شاهد کوتاه از خروجی مدل برای توجیه تصمیم خود وارد می‌کرد. بنابراین برچسب نهایی صرفاً یک تصمیم بدون توضیح نبود و برای هر نمونه شواهد قابل بازبینی نگهداری می‌شد.

علاوه بر نوع خطا، دو متغیر جداگانه برای توصیف کیفیت داوری ثبت شد: قدرت شواهد و میزان اطمینان داور.

قدرت شواهد نشان می‌داد که خطای موردنظر تا چه اندازه مستقیماً از خروجی مدل قابل مشاهده است. در سطح Strong، مدل به‌طور صریح یک واقعیت بصری، فرمول، دانش یا محاسبه نادرست را بیان کرده بود. در سطح Moderate، خطا از چند مرحله استدلال قابل استنباط بود اما جمله مستقیمی که خطا را آشکار کند وجود نداشت. در سطح Weak، تشخیص نوع خطا تا حد زیادی به تفسیر داور وابسته بود یا استدلال مدل اطلاعات محدودی ارائه می‌کرد.

میزان اطمینان مفهوم متفاوتی داشت. High زمانی ثبت می‌شد که تنها یک نوع خطا با شواهد و معیارها سازگار باشد. Medium زمانی استفاده می‌شد که یک دسته محتمل‌تر باشد، اما مرز قابل توجهی با دسته دیگری وجود داشته باشد. در حالت Low، اطلاعات موجود برای نسبت دادن مطمئن خطا کافی نبود.

تفکیک این دو متغیر اهمیت داشت؛ زیرا ممکن است یک داور از برچسب خود اطمینان نسبتاً بالایی داشته باشد، اما شواهد موجود در متن استدلال به‌صورت غیرمستقیم بیان شده باشند.

۳-۸-۵- مدیریت موارد مبهم و پاسخ‌های دارای چند خطا

پاسخ‌های طبیعی مدل‌های زبانی-بصری الزاماً فقط یک خطا ندارند. ممکن است یک مدل ابتدا اطلاعاتی را از تصویر اشتباه بخواند و سپس در ادامه همان پاسخ یک خطای محاسباتی مستقل نیز مرتکب شود. به همین دلیل، داوران مجبور نبودند در تمام موارد فوراً یکی از سه برچسب را انتخاب کنند. برای نمونه‌هایی که شواهد کافی وجود نداشت، استدلال بیش از حد کوتاه بود، مدل تنها گزینه نهایی را داده بود، مرز میان KDE و RE روشن نبود یا بیش از یک منشأ مستقل برای خطا مشاهده می‌شد، وضعیت موقت UNCERTAIN / Insufficient Evidence قابل ثبت بود. چنین نمونه‌هایی برای بررسی مشترک علامت‌گذاری می‌شدند.

همچنین وجود یک خطای ثانویه الزاماً نوع خطای اصلی را تغییر نمی‌داد. داور باید بررسی می‌کرد کدام خطا ارتباط بیشتری با رسیدن مدل به پاسخ نادرست دارد. اگر دو خطا مستقل بودند و تعیین یک منشأ غالب از روی شواهد امکان‌پذیر نبود، نمونه مستقیماً وارد مرحله حل اختلاف می‌شد.


۳-۸-۶- حل اختلاف و تعیین برچسب انسانی نهایی

پس از تکمیل داوری مستقل، برچسب‌های دو ارزیاب با یکدیگر مقایسه شدند. اگر هر دو داور به یک نوع

خطا رسیده بودند و ابهام حل نشده‌ای وجود نداشت، همان برچسب به عنوان برچسب نهایی پذیرفته می‌شد. در نمونه‌هایی که دو داور برچسب متفاوتی ثبت کرده بودند یا یکی از آن‌ها نمونه را مبهم تشخیص داده بود، مرحله حل اختلاف از طریق گفت‌وگو و توافق انجام شد. در این مرحله، دو داور شواهد ثبت شده، استدلال مدل و قواعد مرزی را مجدداً مرور کرده و درباره علت اختلاف بحث می‌کردند. سپس با رسیدن به توافق، یکی از سه دسته VPE، KDE، یا RE به عنوان Human Gold Error Type ثبت می‌شد. قدرت شواهد نهایی و توضیح کوتاه مربوط به دلیل انتخاب برچسب نیز در فرم نهایی نگهداری می‌شد.

این ساختار «داوری مستقل و سپس حل اختلاف از طریق گفت‌وگو در مطالعات پیشین نیز استفاده شده است. برای نمونه، در VISCO سه حاشیه نویسنده متخصص نمونه‌ها را مستقل بررسی کردند و برای موارد اختلاف، پس از هر ۵۰ نمونه جلسه بحث برگزار شد تا حاشیه نویسی‌های یکدیگر را مرور کرده و اختلاف‌ها را حل کنند [۲۷].

۳-۸-۷- حل اختلاف و تعیین برچسب انسانی نهایی



شکل ۳-۵: مراحل برچسب‌گذاری انسانی برای تحلیل نوع خطا

پس از تکمیل داوری مستقل، برچسب‌های دو ارزیاب با یکدیگر مقایسه شدند. اگر هر دو داور به یک نوع خطا رسیده بودند و ابهام حل نشده‌ای وجود نداشت، همان برچسب به عنوان برچسب نهایی پذیرفته می‌شد. در نمونه‌هایی که دو داور برچسب متفاوتی ثبت کرده بودند یا یکی از آن‌ها نمونه را مبهم تشخیص داده بود، مرحله حل اختلاف از طریق گفت‌وگو و توافق انجام شد. در این مرحله، دو داور شواهد ثبت شده، استدلال

مدل و قواعد مرزی کدبوک را مجدداً مرور کرده و درباره علت اختلاف بحث می‌کردند. سپس با رسیدن به توافق، یکی از سه دسته VPE، KDE یا RE به عنوان Human Gold Error Type ثبت می‌شد. قدرت شواهد نهایی و توضیح کوتاه مربوط به دلیل انتخاب برچسب نیز در فرم نهایی نگهداری می‌شد.

این ساختار «داوری مستقل و سپس حل اختلاف از طریق discussion» در مطالعات پیشین نیز استفاده شده است. برای نمونه، در VISCO سه متخصص نمونه‌ها را مستقل بررسی کردند و برای موارد اختلاف، پس از هر ۵۰ نمونه جلسه بحث برگزار شد تا annotation‌های یکدیگر را مرور کرده و اختلاف‌ها را حل کنند. [۲۷]

۹-۳- طراحی سامانه انتخاب تطبیقی روش پرامپت

۹-۳-۱- انگیزه طراحی

پس از اجرای روش‌های مختلف پرامپت‌دهی روی Gemma 4 26B-A4B مشاهده شد که اثر روش‌ها در تمام موضوع‌ها و حوزه‌ها یکسان نیست. یک روش ممکن است در مجموعه‌ای از مسائل موجب بهبود دقت شود، اما در گروه دیگری تغییر محسوسی ایجاد نکند یا حتی عملکرد را کاهش دهد.

بر این اساس این فرض مطرح شد که به جای اعمال یک روش ثابت بر تمام مسائل، می‌توان ابتدا نوع علمی سؤال را مشخص و سپس روشی را انتخاب کرد که در مسائل مشابه عملکرد مناسب‌تری نشان داده است.

ساختار کلی روش پیشنهادی به شکل زیر تعریف شد:

داده ورودی ← تشخیص حوزه ← روش انتخاب ← Gemma 4 26B ← پاسخ

هدف این طراحی آن بود که از تفاوت رفتار روش‌های پرامپت‌دهی در گروه‌های مختلف داده استفاده شود، بدون آن‌که برای هر سؤال تمام روش‌ها اجرا و سپس بهترین پاسخ انتخاب شود.

۹-۳-۲- بررسی دو سطح موضوع و حوزه

برای استخراج سیاست انتخاب پرامپت، اثر روش‌های مختلف ابتدا در دو سطح موضوع و حوزه بررسی شد. در سطح موضوع، برای هر یک از ۳۰ موضوع میزان تغییر دقت هر روش نسبت به حالت پایه محاسبه شد. در سطح دوم، موضوع‌های مرتبط در شش حوزه اصلی تجمیع شدند و همان تحلیل در سطح حوزه تکرار شد.

برای هر گروه g و روش p :

$$\Delta Acc_{g,p} = Acc_{g,p} - Acc_{g,Baseline}.$$

این تحلیل امکان مقایسه دو نوع سیاست را فراهم کرد: سیاست جزئی‌تر مبتنی بر ۳۰ موضوع و سیاست کلی‌تر مبتنی بر شش حوزه.

با وجود آن که سیاست Subject-level امکان تطبیق دقیق‌تری را فراهم می‌کرد، در روش نهایی حوزه به‌عنوان سطح مسیریابی انتخاب شد.

دلیل نخست آن بود که در مجموعه توسعه تنها ده نمونه از هر موضوع وجود داشت. بنابراین تغییر نتیجه تنها یک نمونه، دقت یک موضوع را ده واحد درصد تغییر می‌داد:

$$\frac{1}{10} \times 100 = 10\%.$$

در مقابل، هر حوزه شامل چند موضوع و در نتیجه تعداد بیشتری نمونه بود. در مجموعه توسعه، بسته به حوزه، بین ۴۰ تا ۷۰ نمونه برای برآورد عملکرد وجود داشت. در نتیجه اثر یک نمونه منفرد بر برآورد دقت بسیار کمتر بود و انتخاب روش در سطح حوزه پایدارتر در نظر گرفته شد.

دلیل دوم به مرحله استفاده واقعی مربوط بود. برای مسیریابی در یک ورودی جدید باید گروه علمی سؤال از روی متن، گزینه‌ها و تصاویر تشخیص داده شود. تفکیک شش حوزه نسبت به تشخیص دقیق یکی از ۳۰ موضوع مسئله ساده‌تر و کم‌ریسک‌تری است. از این‌رو حوزه از نظر پایداری آماری و قابلیت تشخیص در زمان استنتاج مبنای مناسب‌تری برای مسیریاب در نظر گرفته شد. مقادیر حاصل از مقایسه موضوع و حوزه در فصل نتایج گزارش می‌شوند.

۳-۹-۳- قاعده انتخاب روش پرامپت‌دهی برای هر حوزه

پس از انتخاب حوزه به‌عنوان سطح نهایی مسیریابی، دقت تمام روش‌ها برای هر یک از شش حوزه بررسی شد.

در مرحله نخست، تمام روش‌هایی که به بیشترین دقت در آن حوزه رسیده بودند مشخص شدند. اگر تنها یک روش بیشترین دقت را داشت، همان روش مستقیماً انتخاب شد. اگر چند روش دقت کاملاً یکسانی داشتند، یک معیار ثانویه برای حل تساوی به کار رفت: روش دارای هزینه و پیچیدگی اجرایی کمتر انتخاب شد.

بنابراین قاعده نهایی انتخاب به‌صورت زیر تعریف شد:

$$p_d^* = \begin{cases} \arg \max_p Acc_{d,p}, & \text{برتر روش در صورت وجود یک} \\ \text{از میان روش‌های هم‌دقت روش کم‌هزینه‌ترین} & \text{در صورت تساوی} \end{cases}$$

در ارزیابی هزینه، سربار کلی روش در نظر گرفته شد؛ از جمله تعداد فراخوانی‌های مدل، نیاز به نمونه‌های نمایشی، بازیابی شباهت، پردازش CLIP و افزایش اندازه زمینه ورودی.

پس از اعمال این قاعده، نگاشت Domain-to-Strategy ثابت شد و پس از آغاز ارزیابی مجموعه جدید دیگر تغییر نکرد.

۳-۹-۴- تشکیل مجموعه مستقل برای ارزیابی روش

از آنجا که سیاست انتخاب روش پرامپت نویسی از Eval300 استخراج شده بود، استفاده مجدد از همان داده‌ها برای ارزیابی نهایی می‌توانست برآوردی خوش‌بینانه ایجاد کند. به همین دلیل یک مجموعه جداگانه شامل ۵۰۰ نمونه MMMU-Pro تشکیل شد که با مجموعه ۳۰۰ تایی اولیه هم‌پوشانی نداشت. این مجموعه در انتخاب روش مناسب هر حوزه نقشی نداشت و برای ارزیابی رفتار سیاست ثابت‌شده استفاده شد.

۳-۹-۵- طبقه‌بند چندوجهی حوزه

برای آن‌که سامانه هنگام دریافت یک سؤال جدید به metadata مجموعه داده وابسته نباشد، یک طبقه‌بند چندوجهی برای تشخیص حوزه آموزش داده شد. مدل پایه Qwen3-VL-2B-Instruct انتخاب شد تا در کنار توانایی پردازش متن، بتواند از محتوای تصویر نیز برای تعیین حوزه علمی استفاده کند. ورودی مدل شامل سؤال، تمام گزینه‌ها و تصاویر مسئله بود. پاسخ صحیح، explanation، استدلال و خروجی مدل پاسخ‌دهنده در اختیار طبقه‌بند قرار نمی‌گرفتند. معماری نهایی دارای یک سر اصلی برای طبقه‌بندی مستقیم شش حوزه و یک سر کمکی برای ۳۰ موضوع بود. وظیفه اصلی آموزش، تشخیص حوزه بود و موضوع تنها به‌عنوان supervision کمکی با وزن کمتر مورد استفاده قرار گرفت:

$$\mathcal{L} = \mathcal{L}_{Domain} + 0.1\mathcal{L}_{Subject}.$$

در مرحله استنتاج، توزیع احتمال حوزه مستقیم با توزیع حوزه حاصل از جمع احتمال موضوع‌های متعلق به هر حوزه ترکیب می‌شود:

$$P_{final}(d | x) = \alpha P_D(d | x) + (1 - \alpha) \sum_{s \in S_d} P(s | x).$$

پارامترهای مربوط به این ترکیب و تنظیم احتمال‌ها تنها با استفاده از بخش اعتبارسنجی پاک‌سازی شده MMMU انتخاب شدند و داده‌های MMMU-Pro برای انتخاب آن‌ها مورد استفاده قرار نگرفتند.

۳-۹-۶- آماده‌سازی داده و جلوگیری از هم‌پوشانی

برای آموزش طبقه‌بند از MMMU استفاده شد. با توجه به اینکه MMMU-Pro از MMMU مشتق شده

است، استفاده مستقیم از داده‌ها می‌توانست موجب نشت نمونه‌های آزمون شود. از این رو پیش از آموزش، تمام نمونه‌های MMMU با کل ۱۷۳۰ نمونه MMMU-Pro مقایسه شدند و نمونه دارای حداقل یکی از شرایط زیر حذف شد:

شناسه یکسان؛

متن سؤال یکسان پس از نرمال‌سازی؛

تصویر یکسان.

برای تصاویر، مقایسه بر اساس محتوای تصویری رمزگشایی شده انجام شد تا تغییر در قالب فشرده‌سازی فایل باعث عبور نمونه مشترک از کنترل هم‌پوشانی نشود.

پس از این پاک‌سازی، داده‌های dev و test در MMMU برای آموزش و بخش validation پاک‌سازی شده برای انتخاب checkpoint و تنظیم سیاست ترکیب احتمال‌ها استفاده شدند.

۳-۹-۷- تنظیم مدل

به دلیل محدودیت منابع محاسباتی، تنظیم مدل با روش QLoRA انجام شد. [۲۸] وزن‌های اصلی مدل در قالب چهار بیتی نگهداری شدند، بخش بصری ثابت ماند و تنها adapter های کم‌رتبه بخش زبانی همراه با سرهای طبقه‌بندی آموزش داده شدند.

در تنظیم نهایی رتبه LoRA برابر ۱۶ و ضریب مقیاس برابر ۳۲ در نظر گرفته شد. [۲۹] مدل حداکثر برای سه دوره آموزش داده شد و انتخاب checkpoint بر اساس دقت حوزه روی مجموعه اعتبارسنجی صورت گرفت. جزئیات کامل تنظیمات در کد و فایل تنظیمات اجرای پژوهش ثبت شده‌اند.

۳-۹-۸- اتصال طبقه‌بند به مسیر یاب و مدل پاسخ‌دهنده


پس از پیش‌بینی حوزه، نتیجه وارد مسیر یاب ثابت می‌شود:

$$\hat{d} \rightarrow R \rightarrow p^*.$$

سپس مسئله با پرامپت متناظر به Gemma 4 26B-A4B IT ارسال می‌شود.

پرامپت‌های مورد استفاده در مسیر یاب همان نسخه‌های تثبیت شده آزمایش‌های اصلی هستند و شامل زنجیره استدلال، روش گراف صحنه، برنامه ریزی و حل و سه نمونه‌ای مبتنی بر پیچیدگی می‌شوند. بنابراین مسیر یاب نسخه جدیدی از این روش‌ها ایجاد نمی‌کند؛ تنها تعیین می‌کند برای هر سؤال کدام یک اجرا شود.

خروجی مدل نیز با همان استخراج‌گر پاسخ مورد استفاده در سایر آزمایش‌ها پردازش می‌شود:



شکل ۳-۶: خط لوله‌ی طراحی سامانه انتخاب تطبیقی روش پرامپت‌دهی

۳-۹-۹- پیاده‌سازی نهایی سامانه

برای استفاده یکپارچه از روش، اجزای طبقه‌بند، مسیرپاب، پرامپت‌ها، بازیابی نمونه‌های Few-shot و استخراج پاسخ در قالب یک بسته نرم‌افزاری واحد سازمان‌دهی شدند.

رابط اصلی سامانه یک تابع $solve(...)$ است که سؤال، تصویر یا تصاویر و گزینه‌ها را دریافت کرده و مراحل تشخیص حوزه، انتخاب روش، اجرای مدل و استخراج پاسخ را به‌صورت خودکار انجام می‌دهد.

سامانه همچنین امکان استفاده از چند منبع برای حوزه را حفظ می‌کند؛ از جمله طبقه‌بند آموزش‌دیده، طبقه‌بندی از طریق API، metadata مجموعه MMMU-Pro و تعیین دستی حوزه. باین‌حال، حالت اصلی برای استفاده مستقل از benchmark، طبقه‌بند آموزش‌دیده است.

جدول Domain-to-Strategy، متن Prompt‌ها، نسخه مجموعه‌داده و سایر اجزای اصلی در پیاده‌سازی ثابت نگه داشته شدند تا رفتار سامانه در اجرای مجدد قابل بازتولید باشد.

چند روش برای استفاده از رابط اصلی سامانه:

Usage examples

Ordinary user input

```
answer = solve(QUESTION, IMAGES, API_KEY)
```

Trained-classifier mode

```
answer = solve(
    QUESTION, IMAGES, API_KEY,
    domain_mode="trained_classifier",
    trained_classifier=my_classifier,
)
```

MMMU-Pro benchmark mode

```
answer = solve(
    api_key=API_KEY,
    domain_mode="mmmu_pro",
    sample_id="test_Physics_123",
)
```

۳-۱۰- جمع‌بندی

در این فصل، چارچوب اجرایی پژوهش به‌صورت یکپارچه طراحی شد تا ارزیابی مدل‌ها، مقایسه روش‌های پرامپت‌دهی و تحلیل نوع خطا در شرایط قابل کنترل و بازتولیدپذیر انجام شود. برای این منظور، مجموعه ارزیابی ثابت، بانک‌های کمکی، تنظیمات اجرای مدل‌ها و استخراج‌گر پاسخ به‌گونه‌ای طراحی شدند که اثر متغیرهای جانبی تا حد امکان کاهش یابد. همچنین برای تحلیل خطا، پس از بررسی امکان استفاده از داور خودکار، برچسب‌گذاری انسانی به‌عنوان روش نهایی انتخاب شد.

در ادامه، روش‌های مختلف پرامپت‌دهی با هدف اثرگذاری بر مؤلفه‌های ادراک بصری، دانش و استدلال پیاده‌سازی شدند و در نهایت، بر پایه تفاوت عملکرد این روش‌ها در حوزه‌های مختلف، سامانه انتخاب تطبیقی پرامپت طراحی شد.

به این ترتیب، این فصل زیرساخت روش‌شناختی لازم برای تحلیل نتایج فصل بعد را فراهم می‌کند؛ به‌گونه‌ای که تغییرات مشاهده‌شده در عملکرد مدل‌ها بتوانند با اطمینان بیشتری به خود مدل، نوع مسئله و روش پرامپت‌دهی نسبت داده شوند.

فصل چهارم

نتایج

۴-۱- مقدمه

در این فصل، نتایج آزمایش‌های انجام‌شده بر روی مدل‌های زبانی-بصری ارائه و تحلیل می‌شوند. ابتدا عملکرد مدل‌ها در شرایط خط پایه بررسی می‌شود تا تصویری از توانایی اولیه هر مدل و تفاوت آن‌ها از نظر دقت و پایداری تولید پاسخ به دست آید. سپس برای مشخص شدن نقاط قوت و ضعف مدل‌ها، نتایج بر اساس ویژگی‌های مختلف مسائل، از جمله حوزه و موضوع علمی، سطح دشواری و نوع محتوای بصری تحلیل می‌شوند. در ادامه، اثر روش‌های مختلف پرامپت‌دهی نسبت به خط پایه بررسی می‌شود. این مقایسه تنها به تغییر دقت کلی محدود نیست، بلکه وابستگی اثر هر روش به مدل، حوزه علمی و نوع ورودی بصری نیز مورد توجه قرار می‌گیرد؛ زیرا نتایج نشان می‌دهند یک روش واحد الزاماً در همه مدل‌ها و همه انواع مسائل رفتار مشابهی ندارد.

برای بررسی دقیق‌تر منشأ این تغییرات، در بخش بعدی تحلیل نوع خطا بر پایه برچسب‌گذاری انسانی انجام می‌شود تا مشخص شود روش‌های پرامپت‌دهی چگونه بر خطاهای ادراکی، دانشی و استدلالی اثر می‌گذارند. در نهایت، روش‌ها از نظر دقت و هزینه محاسباتی مقایسه شده و بر پایه الگوهای به‌دست‌آمده، استفاده از انتخاب تطبیقی روش پرامپت‌دهی نیز ارزیابی می‌شود. به این ترتیب، هدف فصل علاوه بر مقایسه عملکرد مدل‌ها، بررسی این موضوع است که چه روشی، برای چه مدلی و در چه نوع مسئله‌ای می‌تواند مفیدتر باشد.

۴-۲- ارزیابی عملکرد مدل‌های زبانی-بصری در شرایط خط پایه

شرایط خط پایه مرجع اصلی برای مقایسه آزمایش‌های بعدی است. در این شرایط، مدل بدون نمونه

نمایشی اضافی مورد ارزیابی قرار گرفت و ساختار ورودی و پروتکل ارزیابی مطابق فصل سوم ثابت نگه داشته شد. بنابراین، نتایج این بخش تصویری از عملکرد اولیه مدل‌ها پیش از اعمال مداخله‌های پرامپتی ارائه می‌کنند.

۴-۲-۱- عملکرد Gemma 4 31B

Gemma 4 31B در شرایط خط پایه به دقت ۷۰٫۱۳ درصد با ۳۰۰ خروجی معتبر دست یافت که بالاترین نتیجه ثبت‌شده در میان نتایج پایه موجود در این پژوهش است. از نظر اجرایی نیز مشکل قابل‌توجهی در بازیابی پاسخ نهایی مشاهده نشد و تمام خروجی‌های ثبت‌شده دارای پاسخ قابل استخراج بودند. این نتیجه از آن جهت اهمیت دارد که دقت بالاتر مدل با پایداری مناسب تولید همراه بوده است. بنابراین، برخلاف برخی مدل‌های دیگر، بخش قابل‌توجهی از خطاهای این مدل را نمی‌توان به محدودیت طول پاسخ یا شکست استخراج نسبت داد و اختلاف عملکرد آن عمدتاً باید در سطح پاسخ محتوایی بررسی شود. در یک اجرای مستقل و گسترده‌تر، همین مدل با پیکربندی تولید متفاوت و متناسب با تنظیمات آن روی بخش بزرگ‌تری از MMMU-Pro ارزیابی شد. دقت Strict برابر با ۷۶٫۵۸ درصد و نرخ تبعیت از قالب پاسخ برابر با ۹۷٫۷۷ درصد بود. عملکرد مناسب و پایداری بالای مدل در این اجرای گسترده‌تر نیز تأیید شد. بر همین اساس، Gemma 4 31B به‌عنوان مدل مولد در مرحله ساخت مجموعه Pooling و تولید داده‌های کمکی مورد استفاده قرار گرفت.

۴-۲-۲- عملکرد Gemma 4 26B

Gemma 4 26B در مجموعه ۳۰۰ نمونه‌ای، ۱۹۵ پاسخ صحیح تولید کرد و به دقت ۶۵ درصد رسید. دقت متوازن برابر با ۰٫۶۵۶۴ و MCC برابر با ۰٫۶۱۱۰ ثبت شد. مقایسه دو مدل Gemma 4 26B-A4B از نظر معماری نیز قابل توجه است. Gemma 4 31B یک مدل Dense است، در حالی که Gemma 4 26B-A4B از معماری Mixture-of-Experts استفاده می‌کند و تنها بخشی از پارامترهای آن در هر مرحله فعال می‌شوند. اختلاف حدود پنج واحد درصدی میان این دو مدل در آزمایش حاضر وجود دارد، اما این اختلاف را نمی‌توان مستقیماً به Dense یا MoE بودن نسبت داد؛ زیرا ظرفیت فعال، شیوه آموزش و سایر جزئیات معماری نیز متفاوت‌اند.

۴-۲-۳- عملکرد Qwen3.8-27B

Qwen3.8-27B در ارزیابی خط پایه به دقت ۶۲٫۰۸ درصد دست یافت. دقت متوازن برابر با ۰٫۶۱۷۲ ثبت شد که با سطح دقت کلی مدل هم‌راستا است. از نظر اجرایی، این مدل یکی از پرهزینه‌ترین مدل‌های محلی مورد بررسی بود. اجرای خط پایه آن در محیط Kaggle حدود ۱۰ ساعت زمان برد که نشان‌دهنده هزینه زمانی بالای استنتاج در مقایسه با مدل‌های

کوچک‌تر است. همچنین میانگین طول پاسخ‌های تولیدشده نسبتاً بالا بود و در بیست نمونه خروجی به سقف ۸۱۹۲ توکن رسید. در نتیجه، هرچند مدل عملکرد نسبتاً مناسبی از نظر دقت نشان داد، زمان طولانی استنتاج و تولید پاسخ‌های پرحجم از محدودیت‌های مهم آن برای اجرای گسترده آزمایش‌های متعدد پرامپت‌دهی محسوب می‌شوند.

۴-۲-۴ عملکرد Qwen3.5-9B

Qwen3.5-9B برای تمام ۳۰۰ نمونه پاسخ تولید کرد و ۱۸۰ پاسخ صحیح داشت؛ در نتیجه، دقت آن برابر با ۶۰ درصد بود و دقت متوازن برابر با ۰٫۵۷۸۷ به دست آمد.

یکی از مشخصه‌های برجسته این مدل طول زیاد استدلال تولیدشده بود. ۲۷ پاسخ، معادل ۹ درصد کل مجموعه، به سقف ۸۱۹۲ توکن رسیدند و پیش از تولید پاسخ نهایی قطع شدند. با کنارگذاشتن این موارد، تبعیت از قالب پاسخ در خروجی‌های کامل بالا بود.

از دیدگاه معماری، Qwen3.5-9B از ساختار ترکیبی Gated DeltaNet و Attention استفاده می‌کند. عملکرد ۶۰ درصدی آن، با وجود اندازه بسیار کوچک‌تر از مدل‌های حدود ۳۰ میلیارد پارامتری، نشان می‌دهد که اندازه کل مدل به‌تنهایی شاخص مناسبی برای پیش‌بینی عملکرد روی MMMU-Pro نیست.

۴-۲-۵ عملکرد Qwen3-VL-30B-A3B

این مدل در اجرای ثبت‌شده روی ۴۰ نمونه، ۳۳ پاسخ کامل تولید کرد که از میان آن‌ها ۲۰ پاسخ صحیح بودند؛ بنابراین دقت در میان خروجی‌های کامل برابر با ۶۰٫۶۱ درصد بود. با این حال، به دلیل محدودبودن این اجرا به بخشی از مجموعه ارزیابی، این مقدار صرفاً به‌عنوان یک نتیجه اولیه در نظر گرفته می‌شود و نباید مستقیماً با دقت نهایی مدل‌های ارزیابی‌شده روی کل مجموعه مقایسه شود.

یکی از محدودیت‌های برجسته این مدل، هزینه بالای استنتاج محلی و طول زیاد خروجی‌ها بود. هفت پاسخ، معادل ۱۷٫۵ درصد نمونه‌های اجراشده، به سقف ۸۱۹۲ توکن رسیدند و پیش از تکمیل پاسخ قطع شدند. همچنین میانگین زمان پردازش هر نمونه حدود ۴۹۵ ثانیه بود که نشان می‌دهد اجرای محلی این مدل نسبت به مدل‌های کوچک‌تر به‌مراتب زمان‌برتر است. در خروجی‌های کامل نیز بخشی از تفاوت میان دقت استخراج‌شده توسط استخراج‌گر اصلی و استخراج‌گر تشخیصی ناشی از عدم رعایت دقیق قالب نهایی پاسخ بود، نه فقدان پاسخ محتوایی.

۴-۲-۶ عملکرد InternVL3.5-8B

InternVL3.5-8B برای تمام ۳۰۰ نمونه پاسخ معتبر تولید کرد. ۱۴۲ پاسخ صحیح و ۱۵۸ پاسخ نادرست ثبت شد و دقت برابر با ۴۷٫۳۳ درصد به دست آمد. دقت متوازن برابر با ۰٫۴۳۹۹ و MCC برابر با ۰٫۴۰۸۸

بود.

از نظر اجرایی، InternVL یکی از پایدارترین مدل‌های محلی بود. تنها یک خروجی به سقف طول رسید و ۹۹٫۳۳ درصد پاسخ‌ها توسط استخراج‌گر اصلی قابل بازیابی بودند. میانگین خروجی نیز حدود ۴۶۱ توکن بود.

بنابراین، برخلاف Qwen3.5-9B، بخش عمده ضعف دقت InternVL ناشی از طول بیش‌ازحد پاسخ یا شکست استخراج نیست. این مدل خروجی کوتاه‌تر و پایدارتر تولید کرده، اما نرخ خطای محتوایی بالاتری داشته است.

۴-۲-۷- عملکرد Nemotron 3 Nano Omni

در اجرای پایه Nemotron، برای ۲۹۶ نمونه از ۳۰۰ نمونه پاسخ معتبر دریافت شد. از این تعداد ۱۲۳ پاسخ صحیح بود و دقت در مجموعه معتبر برابر با ۴۱٫۵۵ درصد به دست آمد و دقت متوازن برابر با ۰٫۳۸۲۹ بود.

هیچ خروجی معتبر این مدل به دلیل محدودیت طول قطع نشد، اما چهار نمونه به علت مشکلات زیرساختی پاسخ معتبر نهایی نداشتند. بنابراین، این مدل هم از نظر شرایط اجرا و هم از نظر معماری با مدل‌های محلی تفاوت دارد.

نکته مهم این است که Nemotron نیز مانند Gemma 4 26B از ساختار MoE استفاده می‌کند، اما رفتار عملکردی آن بسیار متفاوت بود. همین تفاوت نشان می‌دهد که MoE بودن به تنهایی نمی‌تواند علت عملکرد بهتر یا ضعیف‌تر یک مدل باشد و جزئیات مدل پایه، آموزش، بخش بصری و نحوه ترکیب مؤلفه‌های معماری نقش تعیین‌کننده دارند.

۴-۲-۸- مقایسه تطبیقی عملکرد پایه مدل‌ها

جدول ۴-۱: مقایسه‌ی عملکرد مدل‌ها در شرایط خط پایه


مدل	Architecture	دقت
Gemma 4 31B	Dense Transformer	۷۰,۱۳٪
Gemma 4 26B-A4B	MoE Transformer	۶۵,۰۰٪
Qwen3.8-27B	Dense, Gated DeltaNet + Attention	۶۲,۰۸٪
Qwen3.5-9B	Gated DeltaNet + Attention	۶۰,۰۰٪
Qwen3-VL-30B-A3B	MoE Multimodal	*۶۰,۶۱٪
InternVL3.5-8B	Dense Transformer-based VLM	۴۷,۳۳٪
Nemotron 3 Nano Omni	MoE, Mamba + Attention	**۴۱,۵۵٪

* دقت این مدل براساس ۳۳ نمونه‌ای است که خروجی کامل برای آنها تولید شده است.

** دقت این مدل براساس 296 نمونه‌ای است که خروجی کامل برای آنها تولید شده است.

جدول نشان می‌دهد بین اندازه یا کلاس کلی معماری و دقت، رابطه خطی ساده‌ای وجود ندارد. Gemma 4 31B بهترین نتیجه را ثبت کرده است، اما Nemotron با وجود اندازه کل مشابه در انتهای جدول قرار دارد. همچنین Qwen3.5-9B با حدود ۹ میلیارد پارامتر توانسته دقتی بسیار بالاتر از InternVL3.5-8B و Nemotron ثبت کند.

از این رو، اگرچه ظرفیت مدل می‌تواند یک عامل مؤثر باشد، نتایج حاضر نشان می‌دهند که کیفیت طراحی و آموزش چندوجهی حداقل به اندازه مقیاس مدل اهمیت دارد.



شکل ۴-۱: دقت مدل‌ها در شرایط خط پایه

۴-۳- تحلیل عملکرد مدل‌ها بر اساس ویژگی‌های مجموعه داده

دقت کلی یک میانگین بر مجموعه‌ای ناهمگون از مسائل است و نمی‌تواند به‌تنهایی نقاط قوت و ضعف مدل‌ها را مشخص کند. به همین دلیل، عملکرد مدل‌ها در ادامه با توجه به حوزه علمی، موضوع، دشواری و ساختار ورودی بصری بررسی می‌شود.

۴-۳-۱- حوزه علمی

الگوی عملکرد مدل‌ها در حوزه‌های مختلف یکسان نبود. Gemma 4 31B بالاترین عملکرد خود را در Business با دقت ۸۰ درصد و سپس Tech and Engineering با ۷۷٫۹۴ درصد ثبت کرد. Qwen3.5-9B نیز در Business به ۸۰ درصد رسید، در حالی که دقت آن در Science برابر با ۵۲ درصد و در Tech and Engineering برابر با ۵۰ درصد بود. InternVL3.5-8B الگوی متفاوتی مشاهده شد. Humanities and Social Science با ۶۲٫۵ درصد بهترین حوزه بود، در حالی که Tech and Engineering تنها ۳۰ درصد دقت داشت. بنابراین، حتی رتبه‌بندی نسبی مدل‌ها نیز می‌تواند با تغییر حوزه مسئله تغییر کند. این نتیجه اهمیت گزارش تحلیل حوزه‌ای را نشان می‌دهد؛ زیرا یک مدل با دقت کلی پایین‌تر ممکن است در یک حوزه خاص عملکرد رقابت‌پذیری داشته باشد.

نکته دیگری که در مقایسه حوزه‌ها دیده می‌شود، بیشتر بودن دامنه نوسان عملکرد در مدل‌های کوچک‌تر است. فاصله میان بهترین و ضعیف‌ترین حوزه برای Qwen3.5-9B حدود ۳۰ واحد درصد و برای InternVL3.5-8B حدود ۳۲٫۵ واحد درصد بود، در حالی که این فاصله در مدل‌های بزرگ‌تر مورد بررسی عموماً محدودتر باقی ماند؛ برای مثال در Gemma 4 31B حدود ۲۰ واحد درصد و در Qwen3.8-27B حدود ۲۰٫۲۵ واحد درصد بود. این الگو می‌تواند نشان دهد که مدل‌های کوچک‌تر در این آزمایش نسبت به تغییر حوزه تخصصی

حساسیت بیشتری داشته‌اند، هرچند این تفاوت را نمی‌توان صرفاً به اندازه مدل نسبت داد.




شکل ۴-۲: مقایسه‌ی دقت مدل‌ها در شرایط خط پایه در سطح حوزه‌ی علمی

۲-۳-۴- موضوع

تفاوت‌ها در سطح موضوع حتی بیشتر از سطح حوزه بود. InternVL3.5-8B در چند موضوع به دقت ۷۰ درصد رسید، اما در Power and Energy هیچ پاسخ صحیحی نداشت و در Mechanical Engineering تنها ۱۰ درصد دقت ثبت کرد.

در Qwen3.5-9B، Economics، Finance و Marketing هر یک به ۹۰ درصد رسیدند، در حالی که Biology تنها ۲۰ درصد دقت داشت.

این اختلاف نشان می‌دهد یک حوزه علمی خود شامل مسائل بسیار متفاوتی است. برای مثال، عملکرد بالا در Physics و پایین در Biology می‌تواند در یک حوزه کلی Science اتفاق بیفتد. بنابراین، نتیجه‌گیری در سطح حوزه باید با تحلیل موضوع تکمیل شود.




شکل ۴-۳: مقایسه‌ی دقت مدل‌ها در شرایط خط پایه در سطح موضوع

۴-۳-۳- سطح دشواری

سطح دشواری یکی از منظم‌ترین عوامل همراه با کاهش عملکرد بود. برای InternVL3.5-8B، دقت از ۵۹،۰۹ درصد در مسائل آسان به ۵۰ درصد در مسائل متوسط و ۳۱،۸۲ درصد در مسائل دشوار کاهش یافت. در Qwen3.5-9B نیز همین روند مشاهده شد؛ دقت از ۷۰،۴۵ درصد در مسائل آسان به ۵۹،۶۸ درصد در مسائل متوسط و ۵۰ درصد در مسائل دشوار رسید. همزمان، طول پاسخ و زمان استنتاج نیز افزایش یافت. نکته قابل توجه در مقایسه این دو مدل آن است که InternVL با افزایش دشواری، استدلال طولانی‌تری تولید نکرد، اما نرخ موفقیت آن به شدت افت کرد. در مقابل، Qwen3.5-9B در مسائل دشوار هم زمان بیشتر و هم توکن بیشتری مصرف کرد. بنابراین، مدل‌ها حتی در نحوه واکنش محاسباتی به افزایش دشواری نیز رفتار متفاوتی دارند.

در مدل‌های Gemma، افت عملکرد میان سؤالات آسان و دشوار محدودتر بود. این مشاهده می‌تواند با ظرفیت بیشتر آن‌ها هم‌زمان باشد. این الگو نشان می‌دهد در این مقایسه، شیب افت عملکرد با افزایش دشواری برای مدل‌های کوچک‌تر بیشتر بوده است و مسائل دشوارتر توانسته‌اند تفاوت ظرفیت عملکردی مدل‌ها را آشکارتر کنند.




شکل ۴-۴: عملکرد مدل‌ها در سطوح دشواری مختلف در شرایط خط پایه

۴-۳-۴- نوع محتوای بصری

در چند مدل، جدول‌ها یکی از آسان‌ترین انواع ورودی بصری بودند. Qwen3.5-9B در سؤالات دارای جدول به دقت ۸۲٫۴۶ درصد رسید، در حالی که دقت آن در نت موسیقی برابر با ۴۵٫۴۵ درصد بود. InternVL3.5-8B نیز در جدول‌ها به ۵۷٫۸۹ درصد رسید، در حالی که نت موسیقی و نمودارها به ترتیب ۳۶٫۳۶ و ۳۷٫۹۳ درصد بودند.

تکرار عملکرد مناسب‌تر روی جدول‌ها در چند مدل نشان می‌دهد که ساختار منظم سطر و ستون می‌تواند برای مدل‌های زبانی-بصری قابل استفاده‌تر از برخی نمایش‌های تخصصی باشد.



شکل ۴-۵: مقایسه‌ی عملکرد مدل‌ها در شرایط خط پایه برای انواع محتواهای بصری

۴-۴- ارزیابی روش‌های پرامپت‌دهی

در این بخش، اثر روش‌های مختلف پرامپت‌دهی بر عملکرد مدل‌های زبانی-بصری بررسی می‌شود. هدف اصلی آن است که مشخص شود هر روش تا چه اندازه می‌تواند نسبت به خط پایه، دقت مدل را بهبود دهد.

جدول ۴-۲: میزان تاثیر روش‌های مختلف پرامپت‌دهی بر عملکرد مدل‌ها

روش	Gemma 4 26B	Nemotron 3	Qwen3.5-9B	InternVL3.5-8B
Zero-shot CoT	+۰٫۶۷	+۱٫۳۶	-۰٫۶۷	+۱٫۰۰
Scene Graph	-۰٫۳۳	-۲٫۷۰	-۱٫۳۴	-۴٫۳۳
Plan-and-Solve	+۳٫۰۰	+۱٫۰۲	+۳٫۰۰	-۱٫۶۷
Generated Knowledge	-	-	+۱٫۷۹	-۰٫۳۶
Random 3-shot	-۰٫۳۳	-۱٫۳۵	-۰٫۳۳	+۰٫۳۳
Similarity 3-shot	+۱٫۳۳	-۴٫۰۷	+۱٫۳۳	-۲٫۰۲
Similarity + CoT	+۰٫۶۷	-۱٫۶۹	-۵٫۶۷	-۱٫۶۷
Complexity-based 3-shot	+۱٫۰۰	-۳٫۷۳	-۶٫۰۰	-۲٫۰۰

مقادیر جدول بر حسب واحد درصد هستند.

۴-۴-۱- زنجیره استدلال بدون نمونه

جدول ۴-۳: عملکرد روش زنجیره‌ی استدلال بدون نمونه در چهار مدل

مدل	خط پایه زوجی	با زنجیره استدلال	تغییر دقت
Gemma 4 26B	۶۵٫۲۲٪	۶۵٫۸۹٪	+۰٫۶۷٪
Nemotron 3 Nano Omni	۴۱٫۶۹٪	۴۳٫۰۵٪	+۱٫۳۶٪
Qwen3.5-9B	۶۰٫۰۰٪	۵۹٫۳۳٪	-۰٫۶۷٪
InternVL3.5-8B	۴۷٫۳۳٪	۴۸٫۳۳٪	+۱٫۰۰٪

اثر زنجیره استدلال میان مدل‌ها نسبتاً محدود اما ناهمگون بود. در Gemma 4 26B دقت نسبت به خط پایه از ۶۵٫۲۲ به ۶۵٫۸۹ درصد افزایش یافت؛ یعنی ۰٫۶۷ واحد درصد. در Nemotron 3 افزایش ۱٫۳۶ واحد درصدی مشاهده شد و InternVL نیز یک واحد درصد بهبود داشت. در مقابل، Qwen3.5-9B با ۰٫۶۷ واحد درصد افت مواجه شد.

این نتایج نشان می‌دهد درخواست صریح برای استدلال مرحله‌به‌مرحله یک اثر عمومی و مستقل از مدل ندارد. بررسی نوع خطا، نشان داد این روش در اصلاح خطاهای استدلالی نسبتاً مؤثر بوده است؛ بنابراین اثر آن بیشتر در تغییر ماهیت خطاها ظاهر شده تا افزایش چشمگیر دقت.

در Qwen3.5-9B، مدل از قبل در خط پایه استدلال‌های بسیار طولانی تولید می‌کرد. در چنین شرایطی، افزودن دستور دیگری برای تشریح استدلال ممکن است اطلاعات مفید تازه‌ای به فرایند حل اضافه نکرده باشد. این مشاهده با افت محدود دقت و افزایش طول پاسخ سازگار است، هرچند نمی‌توان آن را مستقیماً به معماری مدل نسبت داد.

۴-۲- گراف صحنه

گراف صحنه تنها روشی بود که در هر چهار مدل مورد آزمایش کاهش دقت ایجاد کرد.

جدول ۴-۴: عملکرد روش گراف صحنه در چهار مدل

مدل	خط پایه زوجی	گراف صحنه	تغییر
Gemma 4 26B	۶۵,۰۰٪	۶۴,۶۷٪	-۰,۳۳٪
Nemotron 3	۴۱,۵۵٪	۳۸,۸۵٪	-۲,۷۰٪
Qwen3.5-9B	۶۰,۲۰٪	۵۸,۸۶٪	-۱,۳۴٪
InternVL3.5-8B	۴۷,۳۳٪	۴۳,۰۰٪	-۴,۳۳٪

در Gemma 4 26B، روش گراف صحنه ۱۷ پاسخ نادرست را اصلاح کرد، اما ۱۸ پاسخ صحیح را از دست داد. بررسی بازنمایی‌های میانی نشان داد که از ۱۶ خطای محتوایی جدید، در هفت مورد خود گراف صحنه اطلاعات بصری نادرست یا ناکافی داشت و در ۹ مورد دیگر گراف قابل استفاده بود، اما خطا در مراحل بعدی دانش یا استدلال رخ داد.

در Nemotron افت بیشتر و برابر با ۲,۷ واحد درصد بود. یکی از محدودیت‌های قابل توجه این اجرا کیفیت پایین ساختار مرحله میانی بود. همزمان، بیشترین پسرفت محتوایی در داده‌های این اجرا به پردازش اطلاعات بصری مربوط بود. بنابراین، برای Nemotron کیفیت مرحله تولید بازنمایی یکی از محدودیت‌های مهم این روش بوده است.

Qwen3.5-9B نیز با افت ۱,۳۴ واحد درصد مواجه شد. در بازبینی مرحله میانی دو نوع شکست مشاهده شد: در بخشی از نمونه‌ها خود گراف صحنه اطلاعات تصویر را نادرست استخراج کرده بود و در بخشی دیگر بازنمایی صحیح بود، اما مدل در استفاده از آن برای استنتاج بعدی شکست خورد.

بیشترین افت گراف صحنه در InternVL3.5-8B و برابر با ۴,۳۳ واحد درصد بود. این روش ۲۱ پاسخ را اصلاح کرد، اما ۳۴ پاسخ صحیح را به نادرست تبدیل کرد. تحلیل بازنمایی‌های میانی نشان داد مشکلات تنها ادراکی نبودند؛ علاوه بر استخراج بصری، تفسیر دانشی اطلاعات موجود در گراف نیز یکی از نقاط شکست مهم بود.

در نتیجه، مشکل اصلی این روش را نمی‌توان صرفاً «تولید گراف نامناسب» دانست. این فرایند دارای دو نقطه آسیب‌پذیر است: ابتدا کیفیت بازنمایی میانی و سپس توانایی مدل برای استفاده صحیح از آن بازنمایی. افزودن یک مرحله ساختاری میانی، در صورتی که اطلاعات نادرست وارد آن شود، می‌تواند حتی پاسخ صحیح خط پایه را به پاسخ نادرست تبدیل کند.

از دیدگاه معماری نیز نتیجه مهمی مشاهده می‌شود. Gemma 4 26B که از ساختار MOE استفاده می‌کند کمترین افت را داشت، اما Nemotron که آن نیز دارای ساختار MOE است افت بسیار بیشتری نشان داد. بنابراین، مقاومت Gemma در این روش را نمی‌توان صرفاً به نوع معماری نسبت داد.

۴-۳-۴ روش برنامه‌ریزی و حل

جدول ۴-۵: عملکرد روش برنامه‌ریزی و حل در چهار مدل

مدل	خط پایه	برنامه‌ریزی و حل	تغییر دقت
Gemma 4 26B	۶۵,۰۰٪	۶۸,۰۰٪	+۳,۰۰٪
Nemotron 3 Nano Omni	۴۱,۵۵٪	۴۲,۵۷٪	+۱,۰۲٪
Qwen3.5-9B	۶۰,۰۰٪	۶۳,۰۰٪	+۳,۰۰٪
InternVL3.5-8B	۴۷,۳۳٪	۴۵,۶۷٪	-۱,۶۷٪

روش برنامه‌ریزی و حل برخلاف گراف صحنه نتایج بسیار متفاوتی بین مدل‌ها ایجاد کرد.

Gemma 4 26B از ۶۵ به ۶۸ درصد رسید که افزایش ۳ واحد درصدی بود. علاوه بر این، تعداد پاسخ‌های نهایی ناقص از ۱۱ به صفر کاهش یافت. در مقابل، مصرف کل توکن تقریباً ۲,۳۲ برابر شد.

Qwen3.5-9B نیز دقیقاً سه واحد درصد افزایش داشت و از ۶۰ به ۶۳ درصد رسید. تعداد پاسخ‌های نهایی

ناقص از ۲۷ به ۵ کاهش یافت، هرچند مرحله برنامه‌ریزی خود در برخی نمونه‌ها طولانی یا ناقص بود.

این کاهش می‌تواند نشان دهد که الزام مدل به پیروی از یک برنامه از پیش تعیین‌شده، فرایند تولید پاسخ

را منظم‌تر کرده و احتمال انحراف یا ادامه‌دادن بی‌رویه استدلال تا رسیدن به محدودیت طول را کاهش داده است.

در Nemotron افزایش محدودتری در حدود ۱۰۰۲ واحد درصد مشاهده شد. در مقابل، InternVL از ۴۷,۳۳ به ۴۵,۶۷ درصد کاهش یافت. با این حال، در InternVL تعداد قابل‌توجهی از خطاهای استدلالی اصلاح شدند؛ مشکل این بود که همزمان خطاهای دانشی و ادراکی و شکست‌های تولید جدید ایجاد شدند. این تفاوت نشان می‌دهد یک مرحله برنامه‌ریزی اضافی تنها زمانی مفید است که خود برنامه تولیدشده کیفیت کافی داشته باشد و مدل بتواند خطاهای احتمالی آن را در مرحله پاسخ نهایی اصلاح کند. در هر دو مدل Qwen و InternVL مشاهده شد که وقتی خطا وارد مرحله برنامه‌ریزی می‌شد، مرحله پاسخ نهایی معمولاً همان مسیر را ادامه می‌داد و نقش یک بازیکن مستقل را ایفا نمی‌کرد.

از نظر معماری، Qwen3.5-9B با وجود اندازه کوچک‌تر، از این روش به‌اندازه Gemma 4 26B سود برد. در نتیجه، اثر مثبت برنامه‌ریزی به ظرفیت بسیار بزرگ مدل محدود نبوده است. در مقابل، InternVL با مقیاس مشابه Qwen افت داشت؛ بنابراین، نمی‌توان افت آن را صرفاً به اندازه مدل نسبت داد.

۴-۴-۴- تولید دانش

روش تولید دانش تنها برای مدل‌هایی اجرا شد که اطلاعات لازم برای تجمیع پاسخ‌های چند اجرا در دسترس بود.

جدول ۴-۶: عملکرد روش تولید دانش در دو مدل

مدل	خط پایه زوجی	تولید دانش	تغییر دقت
Gemma 4 26B	—	—	اجرا نشد
Nemotron 3 Nano Omni	—	—	اجرا نشد
Qwen3.5-9B	۶۴,۲۹٪	۶۶,۰۷٪	+۱,۷۹٪
InternVL3.5-8B	۴۹,۲۸٪	۴۸,۹۱٪	-۰,۳۶٪

Qwen3.5-9B در مجموعه زوجی از ۶۴,۲۹ به ۶۶,۰۷ درصد رسید؛ یعنی نسبت به حالت پایه ۱,۷۹ واحد درصد افزایش داشته است.

InternVL3.5-8B از ۴۹,۲۸ به ۴۸,۹۱ درصد رسید و افت بسیار محدود ۰,۳۶ واحد درصدی داشت. نکته مهم‌تر از دقت کلی، تغییر ترکیب خطاها بود که در بخش تحلیل خطا بررسی خواهد شد. بنابراین، فعال‌سازی دانش اضافی موجود در خود مدل لزوماً باعث کاهش خطاهای دانشی نمی‌شود. کیفیت دانش تولیدشده و توانایی مدل برای تشخیص مرتبط یا نامرتب بودن آن اهمیت اساسی دارد.

۴-۴-۵- روش سه‌نمونه‌ای با انتخاب تصادفی

استفاده از سه نمونه نمایشی تصادفی در هیچ‌یک از مدل‌ها به بهبود قابل توجهی منجر نشد.

جدول ۴-۷: عملکرد روش سه‌نمونه‌ای با انتخاب تصادفی در چهار مدل

مدل	خط پایه	سه‌نمونه‌ای تصادفی	تغییر دقت
Gemma 4 26B	۶۵,۰۰٪	۶۴,۶۷٪	-۰,۳۳٪
Nemotron 3 Nano Omni	۴۱,۵۵٪	۴۰,۲۰٪	-۱,۳۵٪
Qwen3.5-9B	۶۰,۰۰٪	۵۹,۶۷٪	-۰,۳۳٪
InternVL3.5-8B	۴۷,۳۳٪	۴۷,۶۷٪	+۰,۳۳٪

Gemma 4 26B حدود ۰,۳۳ واحد درصد افت کرد Nemotron ۱,۳۵ واحد درصد و Qwen3.5-9B نیز ۰,۳۳ واحد درصد افت داشتند. InternVL تنها ۰,۳۳ واحد درصد افزایش نشان داد. نتیجه مهم این است که وجود چند مثال حل‌شده به‌تنهایی کافی نیست. نمونه‌های تصادفی می‌توانند رفتار مدل را تغییر دهند، اما جهت این تغییر قابل پیش‌بینی نیست. برای مثال، در InternVL وضعیت ۵۷ نمونه تغییر کرد، در حالی که سود نهایی فقط یک پاسخ صحیح بود. بنابراین، یک تغییر کوچک در دقت می‌تواند تغییر رفتاری بسیار بزرگ‌تری در سطح نمونه پنهان کند.

۴-۴-۶- روش سه‌نمونه‌ای مبتنی بر شباهت بدون زنجیره استدلال

جدول ۴-۸: عملکرد روش سه نمونه‌ای مبتنی بر شباهت بدون زنجیره استدلال در چهار مدل

مدل	خط پایه	سه‌نمونه‌ای مبتنی بر شباهت	تغییر دقت
Gemma 4 26B	۶۵,۰۰٪	۶۶,۳۳٪	+۱,۳۳٪
Nemotron 3 Nano Omni	۴۱,۶۹٪	۳۷,۶۳٪	-۴,۰۷٪
Qwen3.5-9B	۶۰,۰۰٪	۶۱,۳۳٪	+۱,۳۳٪
InternVL3.5-8B	۴۷,۴۷٪	۴۵,۴۵٪	-۲,۰۲٪

در Gemma 4 26B دقت از ۶۵ به ۶۶,۳۳ درصد افزایش یافت. تحلیل نمونه‌ها نشان داد مزیت اصلی در

خطاهای دانشی بود و پنج خطای دانشی اصلاح و تنها دو خطای جدید از این نوع ایجاد شد. Qwen3.5-9B نیز ۱,۳۳ واحد درصد افزایش نشان داد. در این مدل نیز تراز خطاهای دانشی مثبت بود، هرچند خطاهای ادراکی اندکی افزایش یافتند.

در مقابل، Nemotron ۴,۰۷ واحد درصد افت کرد و InternVL حدود ۲,۰۲ واحد درصد کاهش نشان داد. در InternVL، انتخاب نمونه‌های مشابه باعث کاهش تعدادی از خطاهای ادراکی شد، اما همزمان خطاهای استدلالی و دانشی افزایش یافتند.

این تضاد بسیار مهم است. شباهت نمونه نمایشی شرط کافی برای مفید بودن آن نیست. یک نمونه ممکن است از نظر متن و تصویر نزدیک باشد، اما الگوی حل آن برای مدل یا سؤال هدف مناسب نباشد. رفتار معماری نیز یک الگوی ساده ارائه نمی‌کند. با معماری MOE سود برد، Nemotron با معماری MOE افت کرد، Qwen کوچک سود برد و InternVL کوچک افت کرد. بنابراین، عامل اصلی را باید در تعامل میان نمونه بازیابی شده و مدل جست‌وجو کرد، نه صرفاً در اندازه یا نوع معماری.

۴-۷- روش سه‌نمونه‌ای مبتنی بر شباهت همراه با زنجیره استدلال

جدول ۴-۹: عملکرد روش سه نمونه‌ای مبتنی بر شباهت همراه با زنجیره استدلال در چهار مدل

مدل	خط پایه	شباهت + زنجیره استدلال	تغییر دقت
Gemma 4 26B	۶۵,۰۰٪	۶۵,۶۷٪	+۰,۶۷٪
Nemotron 3 Nano Omni	۴۱,۵۵٪	۳۹,۸۶٪	-۱,۶۹٪
Qwen3.5-9B	۶۰,۰۰٪	۵۴,۳۳٪	-۵,۶۷٪
InternVL3.5-8B	۴۷,۳۳٪	۴۵,۶۷٪	-۱,۶۷٪

افزودن زنجیره استدلال به نمونه‌های مشابه، نتایج را در بیشتر مدل‌ها بدتر کرد. Gemma 4 26B همچنان ۰,۶۷ واحد درصد بهبود داشت، اما این مقدار کمتر از افزایش ۱,۳۳ واحد درصدی همان روش بدون زنجیره استدلال بود. مصرف توکن نیز به بیش از دو برابر خط پایه رسید. Nemotron، ۱,۶۹ واحد درصد افت کرد. در Qwen3.5-9B افت بسیار بزرگ‌تر و برابر با ۵,۶۷ واحد درصد بود. تعداد پاسخ‌های ناقص Qwen نیز از ۲۷ به ۳۵ افزایش یافت و تعداد خطاهای محتوایی جدید بیش از دو برابر خطاهای اصلاح‌شده بود.

InternVL، نیز ۱,۶۷ واحد درصد افت داشت. نکته مهم این بود که از نظر تعداد خطاهای محتوایی، ۲۷ خطا اصلاح و ۲۷ خطای جدید ایجاد شد؛ اما ترکیب خطاها به شدت تغییر کرد. خطاهای استدلالی کاهش

یافتند، در حالی که خطاهای دانشی افزایش یافتند. همزمان تعداد خروجی‌های ناقص از یک مورد به ۲۳ مورد رسید.

بنابراین، بررسی‌ها نشان داد که ارائه زنجیره استدلال نمونه‌های مشابه نه تنها تضمین‌کننده بهبود نیست، بلکه می‌تواند مسیر استدلال خاصی را به مدل تحمیل کند که با مسئله هدف سازگار نباشد. افزایش شدید طول زمینه نیز می‌تواند پایداری تولید پاسخ را کاهش دهد.

۴-۸- روش سه نمونه‌ای مبتنی بر پیچیدگی استدلال

جدول ۴-۱۰: عملکرد روش سه نمونه‌ای مبتنی بر پیچیدگی در چهار مدل

مدل	خط پایه	روش مبتنی بر پیچیدگی	تغییر دقت
Gemma 4 26B	۶۵,۰۰٪	۶۶,۰۰٪	+۱,۰۰٪
Nemotron 3 Nano Omni	۴۱,۶۹٪	۳۷,۹۷٪	-۳,۷۳٪
Qwen3.5-9B	۶۰,۰۰٪	۵۴,۰۰٪	-۶,۰۰٪
InternVL3.5-8B	۴۷,۳۳٪	۴۵,۳۳٪	-۲,۰۰٪

در این روش، نمونه‌هایی انتخاب شدند که زنجیره استدلال آن‌ها دارای تعداد مراحل بیشتری بود. نتیجه کلی نشان داد پیچیدگی بیشتر زنجیره استدلال معیار مناسبی برای انتخاب نمونه نمایشی نیست. Gemma 4 26B، یک واحد درصد افزایش دقت داشت. از نظر محتوایی ۱۶ خطا اصلاح و ۱۰ خطای جدید ایجاد شد.

Qwen3.5-9B، بیشترین افت را داشت و از ۶۰ به ۵۴ درصد رسید. تعداد خطاهای محتوایی جدید دو برابر اصلاحات بود و پاسخ‌های ناقص نیز افزایش یافتند.

InternVL، نیز دو واحد درصد افت کرد. در این مدل ۱۷ خطای استدلالی اصلاح و ۱۱ خطای جدید ایجاد شد، اما خطاهای دانشی الگوی کاملاً معکوس داشتند: تنها چهار خطای دانشی اصلاح و ۱۲ خطای دانشی جدید ایجاد شد.

این نتیجه نشان می‌دهد طولانی‌تر بودن استدلال نمونه نمایشی به معنای «نمونه آموزشی بهتر» نیست. یک زنجیره استدلال پیچیده ممکن است جزئیات یا فرض‌های خاص نمونه مبدأ را وارد زمینه کند و مدل آن‌ها را در مسئله جدید به‌طور نامناسب به کار گیرد.

۴-۵- تحلیل اثر روش‌های پرامپت‌دهی بر حوزه علمی و ویژگی‌های بصری

در بخش پیشین، اثر کلی روش‌های مختلف پرامپت‌دهی بر عملکرد مدل‌ها بررسی شد. باین‌حال، تغییر

دقت کلی به تنهایی مشخص نمی‌کند که یک روش در چه نوع مسائلی مفید یا نامؤثر بوده است. ممکن است یک روش در بخشی از مجموعه ارزیابی موجب بهبود شود، اما در بخش دیگری عملکرد مدل را کاهش دهد و در نتیجه اثر آن در دقت کلی پنهان بماند.


از این رو، در این بخش اثر روش‌های پرامپت‌دهی با توجه به دو ویژگی اصلی مسائل بررسی می‌شود. ابتدا تغییر عملکرد در **حوزه‌های علمی مختلف** تحلیل می‌شود و سپس نقش **ماهیت ورودی بصری** از منظر نوع تصویر مورد بررسی قرار می‌گیرد. در تمام مقایسه‌ها، تغییر دقت نسبت به خط پایه همان مدل گزارش می‌شود؛ بنابراین مقدار مثبت نشان‌دهنده افزایش دقت و مقدار منفی نشان‌دهنده کاهش دقت است.

هدف این بخش تکرار تحلیل بخش ۳-۴ نیست. در بخش ۳-۴ مشخص شد هر مدل در حالت خط پایه در کدام حوزه‌ها و انواع ورودی عملکرد بهتری دارد؛ در اینجا پرسش اصلی آن است که **اعمال روش‌های مختلف پرامپت‌دهی چگونه این عملکرد را در بخش‌های مختلف مجموعه داده تغییر می‌دهد.**

۴-۵-۱ تحلیل حوزه‌ای اثر روش‌های پرامپت‌دهی

در نخستین مرحله، تغییر دقت روش‌های پرامپت‌دهی در شش حوزه اصلی MMMU-Pro بررسی شد. به دلیل تفاوت قابل توجه رفتار مدل‌ها در آزمایش‌های کلی، نتایج ابتدا برای هر مدل به‌طور جداگانه ارائه می‌شوند. پس از آن، الگوهایی بررسی می‌شوند که جهت آن‌ها در چند مدل تکرار شده است.

Gemma 4 26B - ۱-۱-۵-۴




شکل ۴-۶: اثر روش‌های پرامپت‌دهی در سطح حوزه‌ی علمی در مدل Gemma4 26B

نتایج Gemma 4 26B نشان می‌دهد اثر روش‌ها به حوزه علمی وابسته است. برای مثال، روش برنامه‌ریزی و حل بیشترین بهبود خود را در فناوری و مهندسی ایجاد کرد، در حالی که همین روش در برخی حوزه‌های

دیگر سود مشابهی نداشت. همچنین روش مبتنی بر پیچیدگی استدلال در سلامت و پزشکی بهبود قابل توجهی ایجاد کرد، اما در علوم انسانی و اجتماعی موجب افت شد. بنابراین، حتی برای یک مدل ثابت نیز نمی توان یک روش را برای تمام حوزه ها به یک اندازه مناسب دانست.

Qwen3.5-9B -۲-۱-۵-۴



شکل ۴-۷: اثر روش های پرامپت دهی در سطح حوزه ی علمی در مدل Qwen3.5-9B

در Qwen3.5-9B تفاوت حوزه های حتی برجسته تر است. بیشتر روش های آزمایش شده در علوم انسانی و اجتماعی بهبود ایجاد کردند، در حالی که در حوزه کسب و کار هیچ یک از روش های مشترک موجب افزایش دقت نشد. در فناوری و مهندسی نیز برنامه ریزی و حل افزایش قابل توجهی ایجاد کرد، در حالی که برخی روش های دیگر در همان حوزه منفی بودند. این رفتار نشان می دهد اثر یک روش را نمی توان تنها از نتیجه کلی آن برای مدل استنتاج کرد.


InternVL3.5-8B -۳-۱-۵-۴



شکل ۴-۸: اثر روش های پرامپت دهی در سطح حوزه ی علمی در مدل InternVL3.5-8B

در InternVL3.5-8B ، حوزه فناوری و مهندسی الگوی متمایزی نشان داد؛ تمام روش‌های مشترک در این حوزه موجب افزایش دقت شدند. در مقابل، در علوم انسانی و اجتماعی هیچ‌یک از این روش‌ها بهبود ایجاد نکرد و برخی روش‌های چندنمونه‌ای با افت قابل توجه همراه بودند. این تضاد یکی از روشن‌ترین نمونه‌های وابستگی اثر پرامپت به ماهیت مسئله در نتایج این پژوهش است.

Nemotron 3 Nano Omni -۴-۱-۵-۴



شکل ۴-۹: اثر روش‌های پرامپت‌دهی در سطح حوزه‌ی علمی در مدل Nemotron3 Nano Omni

در Nemotron نیز اثر روش‌ها در حوزه‌های مختلف یکسان نبود. سلامت و پزشکی از حوزه‌هایی بود که چند روش توانستند در آن عملکرد مدل را افزایش دهند، در حالی که علوم انسانی و اجتماعی به‌ویژه در روش‌های چندنمونه‌ای کاهش قابل توجهی نشان داد. این نتیجه بار دیگر نشان می‌دهد مشاهده چند نمونه نمایشی، حتی در صورت انتخاب هدفمند، الزاماً در تمام حوزه‌ها به عملکرد بهتر منجر نمی‌شود.

۴-۵-۱-۵-۴- الگوهای مشترک حوزه‌ای میان مدل‌ها

مقایسه چهار مدل نشان داد که بیشتر اثرهای حوزه‌ای به مدل وابسته‌اند؛ با این حال، چند الگوی تکرارشونده نیز مشاهده شد. برای جلوگیری از نتیجه‌گیری بر اساس تغییرات پراکنده، در جدول ۴-۱۱ تنها مواردی ارائه شده‌اند که جهت اثر آن‌ها در هر چهار مدل یکسان یا تقریباً یکسان بوده است.

جدول ۴-۱۱: الگوهای مشترک حوزه‌ای میان مدل‌ها

حوزه علمی	روش	الگوی مشاهده‌شده در چهار مدل	نتیجه
فناوری و مهندسی	سه‌نمونه‌ای مبتنی بر شباهت	افزایش در هر چهار مدل	الگوی مثبت مشترک
فناوری و مهندسی	برنامه‌ریزی و حل	افزایش در سه مدل و بدون تغییر در یک مدل	بدون افت در هیچ مدل
هنر و طراحی	گراف صحنه	کاهش در هر چهار مدل	بدون افت در هیچ مدل
کسب و کار	سه‌نمونه‌ای مبتنی بر شباهت	کاهش یا بدون تغییر	عدم مشاهده بهبود
علوم پایه	سه‌نمونه‌ای مبتنی بر پیچیدگی	کاهش یا بدون تغییر	عدم مشاهده بهبود

مهم‌ترین الگوی مثبت در فناوری و مهندسی مشاهده شد. روش سه‌نمونه‌ای مبتنی بر شباهت در هر چهار مدل موجب افزایش دقت شد و روش برنامه‌ریزی و حل نیز در هیچ‌یک از مدل‌ها افت ایجاد نکرد. این یافته نشان می‌دهد فناوری و مهندسی در مجموعه مورد بررسی یکی از حوزه‌هایی است که بیشترین پاسخ مثبت و پایدار را به این دو نوع مداخله پرامپتی نشان داده است.

در مقابل، روشن‌ترین الگوی منفی مربوط به گراف صحنه در هنر و طراحی بود که در هر چهار مدل موجب کاهش دقت شد. بنابراین، ساخت یک بازنمایی میانی از تصویر در این حوزه نه تنها مزیت مشترکی ایجاد نکرد، بلکه جهت اثر در تمام مدل‌ها منفی بود.

در سایر حوزه‌ها، به‌ویژه علوم انسانی و اجتماعی، جهت اثر روش‌ها میان مدل‌ها متفاوت بود. در نتیجه، نتایج از تعریف یک نگاشت ساده برای همه مدل‌ها پشتیبانی نمی‌کنند و نشان می‌دهند که در بیشتر موارد باید تعامل میان مدل، حوزه و روش پرامپت‌دهی در نظر گرفته شود.

۴-۵-۲- تحلیل اثر روش‌های پرامپت‌دهی بر اساس ویژگی‌های تصویر

حوزه علمی تنها ویژگی‌ای نیست که می‌تواند بر اثر یک روش پرامپت‌دهی تأثیر بگذارد. در مسائل چندوجهی، نوع و ساختار تصویر نیز بخشی از دشواری مسئله را تعیین می‌کند. از این‌رو، در ادامه اثر روش‌ها بر

اساس نوع تصویر بررسی می‌شود.

۴-۵-۲-۱- تحلیل بر اساس نوع تصویر

در سطح نخست، از ستون نوع تصویر موجود در مجموعه داده استفاده شد. جدول ۴-۱۲ الگوهایی را نشان می‌دهد که جهت اثر آن‌ها در چند مدل پایدار بوده و بنابراین برای مقایسه میان مدلی قابل تفسیر هستند.

جدول ۴-۱۲: الگوهای مشترک میان مدل انواع مختلف تصویر

نوع تصویر	روش	Qwen3.5-9B	Nemotron 3	Gemma 4 26B	InternVL3.5-8B	نتیجه
نت موسیقی	برنامه‌ریزی و حل	-۹,۰۹٪	-۹,۰۹٪	-۱۸,۱۸٪	-۹,۰۹٪	افت در هر چهار مدل
نمودارها و چارت‌ها	سه‌نمونه‌ای تصادفی	+۱۰,۳۴٪	۰,۰۰	۰,۰۰	+۶,۹۰٪	مثبت یا بدون تغییر
جداول	سه‌نمونه‌ای مبتنی بر شباهت	-۵,۲۶٪	-۳,۵۷٪	۰,۰۰	-۱,۷۵٪	بدون بهبود در هر چهار مدل
دیاگرام‌ها	شباهت + زنجیره استدلال	-۴,۶۹٪	-۱۱,۲۹٪	-۱,۵۶٪	۰,۰۰	بدون بهبود در هر چهار مدل
نت موسیقی	زنجیره استدلال	۰,۰۰	۰,۰۰	-۱۸,۱۸٪	-۱۸,۱۸٪	بدون مشاهده بهبود
نقاشی‌ها	گراف صحنه	-۱۰,۵۳٪	۰,۰۰	-۵,۲۶٪	۰,۰۰	بدون مشاهده بهبود

نتایج نشان می‌دهد که نوع تصویر با میزان سود حاصل از پرامپت‌دهی مرتبط است. روشن‌ترین الگوی منفی مربوط به نت موسیقی بود؛ برنامه‌ریزی و حل در هر چهار مدل باعث کاهش دقت شد و زنجیره استدلال نیز در هیچ مدلی بهبود ایجاد نکرد. در جداول نیز روش مبتنی بر شباهت در هیچ یک از مدل‌ها موجب افزایش دقت نشد. به‌طور مشابه، افزودن زنجیره استدلال به نمونه‌های مشابه در دیاگرام‌ها هیچ اثر مثبتی در چهار مدل ایجاد نکرد.

در مقابل، روش سه‌نمونه‌ای تصادفی در نمودارها و چارت‌ها در هیچ مدل افت ایجاد نکرد و در-Qwen3.5

9B و InternVL3.5-8B با افزایش دقت همراه بود. این نتایج نشان می‌دهد اثر یک روش که در سطح کل مجموعه ضعیف یا خنثی به نظر می‌رسد، ممکن است در یک نوع خاص از ورودی بصری متفاوت باشد. با توجه به تعداد محدود برخی گروه‌ها، به‌ویژه نت موسیقی، اندازه دقیق تغییرات باید با احتیاط تفسیر شود. به همین دلیل، در این بخش تأکید اصلی بر جهت مشترک تغییر در چند مدل است، نه صرفاً بزرگی عددی تغییر.

۴-۵-۳- جمع‌بندی تحلیل بر اساس ویژگی مسئله

نتایج این بخش نشان داد که اثر روش‌های پرامپت‌دهی تنها به مدل وابسته نیست و با ویژگی‌های مسئله نیز تغییر می‌کند. در سطح حوزه علمی، فناوری و مهندسی پایدارترین الگوی مثبت را برای برخی روش‌ها نشان داد، در حالی که گراف صحنه در هنر و طراحی در تمام مدل‌ها اثر منفی داشت. باین‌حال، این تحلیل تنها نشان می‌دهد در چه نوع نمونه‌هایی عملکرد تغییر کرده است و مشخص نمی‌کند این تغییر ناشی از اصلاح یا ایجاد چه نوع خطایی بوده است. برای پاسخ به این پرسش، در بخش بعدی برچسب‌گذاری انسانی نوع خطا برای دو مدل منتخب انجام می‌شود.

۴-۶- تحلیل نوع خطا مبتنی بر برچسب‌گذاری انسانی

برچسب‌گذاری انسانی نهایی به دو مدل Gemma 4 26B و InternVL3.5-8B محدود شد. این دو مدل علاوه بر تفاوت در مقیاس، از دو خانواده متفاوت هستند و رفتار آن‌ها در آزمایش‌های پرامپت نیز تفاوت قابل‌توجهی داشت. در این مرحله، تنها نمونه‌هایی بررسی شدند که وضعیت پاسخ آن‌ها نسبت به خط پایه تغییر کرده بود؛ یعنی پاسخ درست به نادرست یا پاسخ نادرست به درست تبدیل شده بود. در این بخش، علامت مثبت در جدول‌ها به معنای آن است که تعداد خطاهای اصلاح‌شده از خطاهای جدید بیشتر بوده است و علامت منفی نشان می‌دهد روش موردنظر در آن دسته خطای بیشتری ایجاد کرده است.

۴-۶-۱- تحلیل نوع خطا در Gemma 4 26B


جدول ۴-۱۳: تراز خالص انواع خطا در Gemma 4 26B

خطای استدلالی	خطای ادراکی	خطای دانشی	روش
۰	۰	+۲	زنجیره استدلال
-۱	-۲	۰	گراف صحنه
+۲	-۳	+۳	برنامه‌ریزی و حل
-۱	+۲	+۱	سه‌نمونه‌ای تصادفی
-۱	+۱	+۳	سه‌نمونه‌ای مبتنی بر شباهت
-۳	+۲	+۳	شباهت همراه با زنجیره استدلال
+۱	+۴	+۱	سه‌نمونه‌ای مبتنی بر پیچیدگی

مقادیر جدول تعداد نمونه را نشان می‌دهند. مقدار مثبت به معنای بیشتر بودن تعداد خطاهای اصلاح‌شده از خطاهای جدید و مقدار منفی به معنای بیشتر بودن خطاهای جدید از خطاهای اصلاح‌شده است. نتایج نشان می‌دهد که تمامی روش‌های پرامپت‌دهی، به جز روش **گراف صحنه**، موجب کاهش خطاهای دانشی شدند و گراف صحنه در این نوع خطا تغییری ایجاد نکرد. همچنین گراف صحنه تنها روش جدول است که برای Gemma تراز محتوایی کلی منفی دارد. این نتیجه با تحلیل بازنمایی میانی سازگار است و نشان می‌دهد تبدیل تصویر به یک ساختار متنی می‌تواند یک نقطه خطای جدید به فرایند حل اضافه کند. برای Gemma تمامی روش‌های مبتنی بر نمونه توانستند تعداد خطاهای ادراکی را کاهش دهند. روش سه نمونه‌ای مبتنی بر پیچیدگی تنها روشی بود که توانست به‌طور هم‌زمان هر سه نوع خطای دانشی، ادراکی و استدلالی را کاهش دهد اما استفاده از نمونه‌های مرتبط بیشتر به بازیابی و به‌کارگیری دانش مناسب کمک کرده‌اند تا انتقال مطمئن مسیر استدلال.

با توجه به نتایج این بخش اغلب روش‌های پرامپت‌دهی با افزایش خطاهای استدلالی همراه بودند و از

این منظر تأثیر منفی نشان دادند.



شکل ۴-۱۰: تراز خالص انواع خطا در Gemma 4 26B

۴-۶-۲- تحلیل نوع خطا در InternVL3.5-8B

جدول ۴-۱۴: تراز خالص انواع خطا در InternVL3.5-8B

خطای استدلالی	خطای ادراکی	خطای دانشی	روش
+۷	۰	-۳	زنجیره استدلال
۰	-۶	-۶	گراف صحنه
+۸	-۲	-۴	برنامه‌ریزی و حل
-۲	+۵	-۴	تولید دانش
+۳	۰	-۱	سه‌نمونه‌ای تصادفی
-۵	+۳	-۴	سه‌نمونه‌ای مبتنی بر شباهت
+۵	+۲	-۷	شباهت همراه با زنجیره استدلال
+۶	+۱	-۸	سه‌نمونه‌ای مبتنی بر پیچیدگی

مقادیر جدول تعداد نمونه را نشان می‌دهند. مقدار مثبت به معنای بیشتر بودن تعداد خطاهای اصلاح‌شده از خطاهای جدید و مقدار منفی به معنای بیشتر بودن خطاهای جدید از خطاهای اصلاح‌شده است.

نتایج نشان دادند که در مدل InternVL نیز روش گراف صحنه نتوانست موجب کاهش هیچ‌یک از انواع خطا شود. همچنین تولید دانش اضافی نه‌تنها خطاهای دانشی این مدل را کاهش نداد، بلکه در نمونه‌های تغییرکرده تعداد بیشتری خطای دانشی ایجاد کرد.


تمامی روش‌های پرامپت‌دهی در InternVL با افزایش خطاهای دانشی همراه بودند اما بیشتر روش‌های پرامپت‌دهی موجب کاهش خطاهای استدلالی شدند.

در مدل InternVL3.5-8B مورد استفاده، روش‌های پرامپتی آزمایش‌شده بیشتر توانستند خطاهای استدلالی را کاهش دهند تا خطاهای دانشی را برطرف کنند.

با توجه به نتایج این بخش، در میان این روش‌ها، برنامه‌ریزی و حل، زنجیره استدلال و سه‌نمونه مبتنی بر پیچیدگی بیشترین بهبود را در کاهش خطاهای استدلالی نشان دادند.

برای این مدل، روش‌های مبتنی بر نمونه در خطاهای ادراکی هیچ اثر منفی ایجاد نکردند و اغلب موجب کاهش این نوع خطا شدند. افزودن استدلال نمونه‌های مشابه به بهبود بخشی از مسیرهای استدلالی کمک کرده، اما همزمان مدل را در تعداد بیشتری از مسائل به سمت دانش حوزوی نامناسب سوق داده است. همچنین نمایش نمونه‌هایی با استدلال طولانی‌تر و چندمرحله‌ای‌تر بیش از آنکه دانش مدل را تثبیت کند، در بعضی موارد باعث انتقال تفسیر یا دانش نامناسب شده است. بنابراین، نمونه‌های مشابه از نظر چندوجهی توانسته‌اند در برخی موارد به برداشت بصری بهتر کمک کنند، اما شباهت مسئله به معنای انتقال موفق دانش یا استدلال نیست.

این نتیجه نشان می‌دهد مسئله InternVL صرفاً کمبود اطلاعات زمینه‌ای نیست. مدل ممکن است دانش تولید کند، اما انتخاب، ارزیابی یا به‌کارگیری آن دانش همچنان نادرست باشد.



شکل ۴-۱۱: تراز خالص انواع خطا در InternVL3.5-8B

۴-۶-۳- مقایسه الگوی خطا در Gemma 4 26B و InternVL3.5-8B

جدول‌های ۴-۱۳ و ۴-۱۴ نشان می‌دهند تفاوت دو مدل تنها در مقدار دقت نیست، بلکه در نوع واکنش آن‌ها به پرامپت نیز تفاوت محسوسی وجود دارد.

Gemma در روش‌های مبتنی بر بازیابی، به‌ویژه روش مبتنی بر شباهت، غالباً تراز مثبت در خطاهای دانشی داشت. InternVL در همان دسته روش‌ها تقریباً الگوی معکوسی نشان داد و خطاهای دانشی به یکی از مهم‌ترین منشأهای پسرفت تبدیل شدند.

در مقابل، InternVL در برابر روش‌هایی که فرایند استدلال را صریح‌تر می‌کردند، بهبود قابل‌توجهی در خطاهای استدلالی داشت. برنامه‌ریزی و حل تراز +۸ و زنجیره استدلال تراز +۷ در این دسته ایجاد کردند. در Gemma این سود استدلالی به این اندازه برجسته نبود.

این تفاوت نشان می‌دهد یک پرامپت واحد روی دو مدل الزاماً یک توانایی یکسان را تقویت نمی‌کند. برای InternVL، افزودن ساختار استدلالی بیشتر عمدتاً به اصلاح استدلال کمک کرده، اما مشکل دانش باقی مانده یا تشدید شده است. برای Gemma، بازیابی نمونه‌های مرتبط بیشتر با بهبود استفاده از دانش همراه بوده است.

۴-۷- مقایسه جامع روش‌های پرامپت‌دهی

برای جمع‌بندی، بهترین تغییر مشاهده‌شده برای هر مدل در جدول زیر ارائه شده است.


جدول ۴-۱۵: بهترین روش مشاهده شده برای هر مدل

مدل	بهترین روش در آزمایش‌های انجام‌شده	تغییر دقت
Gemma 4 26B	برنامه‌ریزی و حل	+۳,۰۰٪
Nemotron 3 Nano Omni	زنجیره استدلال بدون نمونه	+۱,۳۶٪
Qwen3.5-9B	برنامه‌ریزی و حل	+۳,۰۰٪
InternVL3.5-8B	زنجیره استدلال بدون نمونه	+۱,۰۰٪

جدول نشان می‌دهد بهترین روش نیز میان مدل‌ها یکسان نیست. حتی در دو مدلی که برنامه‌ریزی و حل بهترین نتیجه را ایجاد کرد، سازوکار اثر کاملاً مشابه نبود. در Gemma بخشی از سود از اصلاح خطاهای محتوایی حاصل شد، در حالی که در Qwen کاهش تعداد پاسخ‌های ناقص سهم قابل توجهی داشت. در مقابل، InternVL بیشترین سود خود را از ساده‌ترین مداخله استدلالی، یعنی زنجیره استدلال بدون نمونه، دریافت کرد. افزودن مراحل پیچیده‌تر، نمونه‌های متعدد یا زنجیره‌های استدلال طولانی‌تر نه تنها سود بیشتری ایجاد نکرد، بلکه غالباً باعث افت دقت و افزایش هزینه شد. Nemotron نیز از زنجیره استدلال سود محدودی برد، اما تقریباً تمام روش‌های چندنمونه‌ای آن افت ایجاد کردند. این امر نشان می‌دهد ظرفیت بالای اسمی یا استفاده از معماری MOE تضمین نمی‌کند که مدل از یادگیری درون‌متنی چندوجهی بهره‌بردار شود.

۴-۷-۱- رابطه هزینه و عملکرد

یکی از الگوهای مهم آزمایش‌ها، افزایش قابل توجه هزینه در روش‌های پیچیده بود.



شکل ۴-۱۲: رابطه‌ی هزینه و عملکرد روش های پرامپت‌دهی در مدل‌های مختلف

محور افقی نشان‌دهنده نسبت مصرف توکن به خط پایه و محور عمودی نشان‌دهنده تغییر دقت خواهد بود. هر نقطه نمایانگر یک ترکیب مدل و روش پرامپت است.

برای مثال، گراف صحنه در Gemma در حدود ۲,۱۹ برابر خط پایه توکن مصرف کرد، در حالی که دقت کاهش یافت. برنامه‌ریزی و حل حدود ۲,۳۲ برابر توکن مصرف کرد و سه واحد درصد افزایش ایجاد کرد. روش مبتنی بر شباهت همراه با زنجیره استدلال نیز بیش از دو برابر هزینه داشت، اما تنها ۰,۶۷ واحد درصد سود ایجاد کرد.

در InternVL، روش مبتنی بر پیچیدگی استدلال مصرف توکن را تقریباً ۳,۸۹ برابر کرد، اما دقت دو واحد درصد کاهش یافت. روش مبتنی بر شباهت همراه با زنجیره استدلال نیز حدود ۳,۵۶ برابر توکن مصرف کرد و باز هم با افت دقت همراه بود.

بنابراین، در ارزیابی نهایی یک روش باید دقت و هزینه همزمان در نظر گرفته شوند. روش پیچیده‌ای که بهبود بسیار کوچک و از نظر آماری نامطمئنی ایجاد می‌کند، لزوماً انتخاب مناسبی برای کاربرد عملی نیست.

۴-۷-۲- جمع‌بندی مقایسه روش‌ها

از کل آزمایش‌ها سه نتیجه اصلی حاصل می‌شود.

نخست، هیچ روش عمومی و برتری برای تمام مدل‌ها وجود نداشت. گراف صحنه در هر چهار مدل منفی بود، اما سایر روش‌ها بسته به مدل جهت متفاوتی داشتند.

دوم، افزایش پیچیدگی پرامپت تضمین‌کننده عملکرد بهتر نبود. روش‌های چندمرحله‌ای، نمونه‌های همراه

با زنجیره استدلال و نمونه‌های دارای استدلال طولانی‌تر در بسیاری از مدل‌ها هزینه را افزایش دادند، اما دقت را بهبود ندادند.

سوم، بهترین روش برای یک مدل الزاماً بهترین روش برای مدل دیگر نبود. این یافته مبنای منطقی مناسبی برای حرکت از «یک پرامپت ثابت برای تمام مسائل» به سمت انتخاب تطبیقی روش پرامپت فراهم می‌کند.

۴-۸- ارزیابی روش انتخاب تطبیقی پرامپت

۴-۸-۱ مقایسه انتخاب روش در سطح موضوع و حوزه

در نخستین مرحله، فرض شد موضوع یا حوزه صحیح هر نمونه از قبل مشخص است و برای هر گروه، بهترین روش بر اساس نتایج مجموعه توسعه انتخاب شد. هدف از این تحلیل، بررسی ظرفیت بالقوه استفاده از سیاست گروه‌محور بود و نه گزارش عملکرد نهایی سامانه.

در صورت انتخاب مستقل بهترین روش برای هر یک از ۳۰ موضوع، دقت توسعه‌ای از:

65%

در حالت پایه به:

76%

افزایش می‌یابد؛ یعنی:

+11

واحد درصد.

در مقابل، اگر تصمیم‌گیری در سطح شش حوزه انجام شود، دقت حاصل برابر:

جدول ۴-۱۶: دقت حاصل از روش انتخاب تطبیقی پرامپت در سطح حوزه برای مدل Gemma 4 26B-A4B

حوزه	تعداد پاسخ صحیح در حالت پایه	تعداد پاسخ صحیح پس از انتخاب بهترین روش	بیشترین افزایش خالص
هنر و طراحی	۲۳	۲۴	+۱
کسب‌وکار	۳۸	۴۰	+۲
سلامت و پزشکی	۳۱	۳۷	+۶
علوم انسانی و اجتماعی	۲۶	۲۷	+۱
علوم پایه	۳۰	۳۳	+۳

فناوری و مهندسی	۴۷	۵۵	+۸
مجموع	۱۹۵	۲۱۶	+۲۱

72%

است که نسبت به حالت پایه:

+7

واحد درصد افزایش نشان می‌دهد.

جدول ۴-۱۷: دقت حاصل از روش انتخاب تطبیقی پرامپت در سطح موضوع برای مدل Gemma 4 26B-A4B

سطح انتخاب روش	تعداد گروه‌ها	تعداد پاسخ صحیح در حالت پایه	تعداد پاسخ صحیح با انتخاب بهترین روش	دقت حالت پایه	دقت حاصل	میزان بهبود
سطح موضوع	۳۰ موضوع	۱۹۵ از ۳۰۰	۲۲۸ از ۳۰۰	۶۵,۰٪	۷۶,۰٪	+۱۱ واحد درصد
سطح حوزه	۶ حوزه	۱۹۵ از ۳۰۰	۲۱۶ از ۳۰۰	۶۵,۰٪	۷۲,۰٪	+۷ واحد درصد

بنابراین سیاست Subject-level در همان مجموعه توسعه سقف بالاتری ایجاد می‌کرد. با این حال این نتیجه به تنهایی برای انتخاب سطح مسیریابی کافی نبود.

هر موضوع تنها شامل ده نمونه بود و در نتیجه نتیجه یک سؤال می‌توانست دقت آن را ده واحد درصد تغییر دهد. در مقابل، حوزه‌ها بین ۴۰ تا ۷۰ نمونه داشتند و بنابراین انتخاب بهترین روش بر اساس تعداد بیشتری مشاهده انجام می‌شد.

از سوی دیگر، تشخیص یکی از شش حوزه نیز در زمان استنتاج ساده‌تر و مطمئن‌تر از تفکیک یکی از ۳۰ موضوع است.

۲-۷-۴- روش‌های دارای بیشترین دقت در هر حوزه

ابتدا، بدون اعمال هیچ معیار ثانویه‌ای، تمام روش‌هایی که در هر حوزه به بیشترین دقت رسیده بودند مشخص شدند.

جدول ۴-۱۸: روش‌های دارای بیشترین دقت در هر حوزه برای مدل Gemma 4 26B-A4B

حوزه	دقت حالت پایه	بیشترین دقت	روش‌های دارای بیشترین دقت
هنر و طراحی	۵۷,۵٪	۶۰,۰٪	زنجیره استدلال، چندنمونه‌ای مبتنی بر شباهت، چندنمونه‌ای مبتنی بر شباهت همراه با زنجیره استدلال
کسب‌وکار	۷۶,۰٪	۸۰,۰٪	زنجیره استدلال، زنجیره استدلال ترکیبی، برنامه‌ریزی و حل
سلامت و پزشکی	۶۲,۰٪	۷۴,۰٪	چندنمونه‌ای مبتنی بر پیچیدگی
علوم انسانی و اجتماعی	۶۵,۰٪	۶۷,۵٪	برنامه‌ریزی و حل، چندنمونه‌ای مبتنی بر شباهت
علوم پایه	۶۰,۰٪	۶۶,۰٪	زنجیره استدلال ترکیبی
فناوری و مهندسی	۶۷,۱۴٪	۷۸,۵۷٪	برنامه‌ریزی و حل

نتایج نشان می‌دهند که هیچ روش واحدی در تمام حوزه‌ها بهترین عملکرد را ندارد. برای مثال، روش گراف صحنه بیشترین دقت را در علوم پایه ایجاد کرده است، در حالی که چندنمونه‌ای مبتنی بر پیچیدگی در سلامت و پزشکی بهترین نتیجه را داشته و برنامه‌ریزی و حل در فناوری و مهندسی بیشترین افزایش را ایجاد کرده است.

این تفاوت مبنای اصلی استفاده از مسیر یاب مبتنی بر حوزه را تشکیل می‌دهد.

۳-۸-۴- حل تساوی میان روش‌های برتر

در سه حوزه بیش از یک روش به دقت نهایی یکسان رسیده‌اند. از این رو صرف معیار Accuracy برای تعیین یک روش واحد کافی نبود.

در این موارد از قاعده از پیش تعریف‌شده انتخاب روش کم‌هزینه‌تر در صورت تساوی دقت استفاده شد. در هنر و طراحی سه روش زنجیره استدلال، چندنمونه‌ای مبتنی بر شباهت و چندنمونه‌ای مبتنی بر

شباهت با زنجیره استدلال همگی به دقت ۶۰ درصد رسیدند. زنجیره استدلال انتخاب شد، زیرا برخلاف روش‌های چندنمونه‌ای به بانک نمونه‌های نمایشی، محاسبه شباهت و افزایش قابل توجه اندازه زمینه نیاز ندارد. در کسب‌وکار نیز زنجیره استدلال، گراف صحنه و برنامه ریزی و حل همگی به دقت ۸۰ درصد رسیدند. زنجیره استدلال انتخاب شد؛ زیرا روش گراف صحنه دارای مرحله تولید گراف صحنه و برنامه ریزی و حل دارای مرحله مستقل برنامه‌ریزی است، در حالی که زنجیره استدلال تنها با یک تغییر در دستور مسئله قابل اجرا است. در علوم انسانی و اجتماعی، برنامه ریزی و حل و چندنمونه‌ای مبتنی بر شباهت هر دو دقت ۶۷٫۵ درصد ایجاد کردند. در چارچوب اجرایی پژوهش برنامه ریزی و حل انتخاب شد، زیرا به بانک نمونه های نمایشی، embeddingهای CLIP و فرایند بازیابی نمونه وابسته نیست.

پس از اعمال این قاعده، سیاست نهایی مسیریاب به شکل زیر تثبیت شد:

جدول ۴-۱۹: سیاست نهایی انتخاب پرامپت در سطح حوزه برای مدل Gemma 4 26B-A4B

حوزه	روش نهایی
هنر و طراحی	زنجیره استدلال
کسب‌وکار	زنجیره استدلال
سلامت و پزشکی	چندنمونه‌ای مبتنی بر پیچیدگی
علوم انسانی و اجتماعی	برنامه‌ریزی و حل
علوم پایه	زنجیره استدلال ترکیبی
فناوری و مهندسی	برنامه‌ریزی و حل

به این ترتیب، معیار نخست انتخاب بیشترین دقت و معیار دوم، تنها در صورت تساوی، هزینه و پیچیدگی اجرایی کمتر بود.

۴-۸-۴- ارزیابی طبقه‌بند حوزه

پس از طراحی سیاست Domain-level، مسئله بعدی تشخیص خودکار حوزه بود. طبقه‌بند-Qwen3-VL-2B روی داده‌ای مستقل از فرایند آموزش ارزیابی شد.

تنظیم مدل Qwen3-VL-2B-Instruct با روش QLoRA روی ۸۰۴۲۶ نمونه پاک‌سازی شده و طی یک دوره آموزش انجام شد. با اندازه دسته فیزیکی یک و انباشت گرادیان ۱۶ مرحله‌ای، در مجموع ۸۰۴۲۶ ریزگام آموزشی و ۵۲۷ گام به‌روزرسانی بهینه‌ساز انجام شد.

در اجرای ارزیابی ثبت‌شده روی مجموعه ۵۰۰ نمونه‌ای، دقت تشخیص حوزه برابر با:

96%

به دست آمد.

این مقدار نشان می‌دهد که استفاده از علاوه بر پایداری بیشتر در مرحله انتخاب Prompt، از نظر طبقه‌بندی نیز عملی است؛ زیرا بخش عمده نمونه‌ها به حوزه صحیح هدایت می‌شوند. این نتیجه همچنین یکی از دلایل انتخاب حوزه به‌جای موضوع برای مسیریاب را تقویت می‌کند. حتی اگر تشخیص موضوع دقیق‌تر با خطا همراه باشد، بسیاری از این خطاها می‌توانند میان دو موضوع از یک حوزه رخ دهند و در نتیجه روش انتخاب‌شده تغییر نکند.

۴-۸-۵- ارزیابی سیاست مسیریابی روی مجموعه مستقل

در ارزیابی مسیریاب، جدول Domain-to-Strategy پیش از شروع آزمایش ثابت شد و در طول اجرای مجموعه آزمون تغییر نکرد.

در اجرای ۵۰۰ نمونه دقت برابر با:

70.2%

به دست آمده است.

۴-۸-۶- ارزیابی پاسخ مستقیم

برای ایجاد یک خط مبنا، Gemma 4 26B-A4B روی همان مجموعه ۵۰۰ نمونه‌ای بدون استفاده از هیچ روش پرامپت نویسی اجرا شد و تنها از مدل خواسته شد گزینه پاسخ را مستقیماً ارائه کند. در ارزیابی خودکار اولیه، دقت برابر با ۴۸.۴۰٪ بود. با بررسی خروجی‌های خام مشخص شد که بخشی از پاسخ‌های صحیح به دلیل رعایت‌نشدن قالب مورد انتظار توسط Parser استخراج نشده‌اند. پس از بازبینی این موارد، دقت محتوایی مدل به ۶۴٪ رسید. بنابراین اختلاف میان دو مقدار بیشتر ناشی از خطای قالب و استخراج پاسخ بود و نه الزاماً خطای محتوایی مدل.

جدول ۴-۲۰: دقت مدل Gemma 4 26B-A4B در شرایط خط پایه روی ۵۰۰ نمونه

دقت	نوع ارزیابی
۴۸.۴۰٪	Parser اولیه
۶۰.۰۰٪ تا ۶۴٪	پس از بررسی خروجی خام

۴-۸-۷- مقایسه عملکرد و هزینه در روش انتخاب تطبیقی پرامپت

جدول ۴-۲۱: مقایسه‌ی عملکرد و هزینه در روش انتخاب تطبیقی پرامپت برای مدل Gemma 4 26B-A4B

روش / نوع ارزیابی	تعداد پاسخ صحیح	دقت	مصرف کل توکن	میانگین زمان پاسخ هر نمونه	تغییر نسبت به خط پایه اصلاح شده
پاسخ مستقیم - استخراج اولیه با Parser	۲۴۲ از ۵۰۰	۴۸٫۴٪	حدود ۰٫۶۴ میلیون	حدود ۴۱ ثانیه	—
پاسخ مستقیم - پس از بررسی خروجی خام	۳۰۰ تا ۳۲۰ از ۵۰۰	۶۰ تا ۶۴٪	حدود ۰٫۶۴ میلیون	حدود ۴۱ ثانیه	مبنای مقایسه
انتخاب تطبیقی پرامپت بر اساس حوزه	۳۵۱ از ۴۹۹	۷۰٫۲٪	حدود ۱٫۶۵ میلیون	حدود ۳۴ ثانیه	۶۰٫۳۴+ تا ۱۰٫۳۴+ واحد درصد

در بررسی خروجی‌های پاسخ مستقیم، ۲۰ نمونه دارای پاسخ مبهم بودند؛ به این معنا که از متن خروجی نمی‌شد با اطمینان یک گزینه نهایی مشخص استخراج کرد. به همین دلیل، تعداد پاسخ‌های صحیح این حالت به صورت بازه‌ای بین ۳۰۰ تا ۳۲۰ پاسخ از ۵۰۰ نمونه، معادل ۶۰ تا ۶۴ درصد، گزارش شده است. روش انتخاب تطبیقی پرامپت توانست دقت Gemma 4 26B-A4B را از محدوده تقریبی ۶۰ تا ۶۴ درصد در حالت پاسخ مستقیم به ۷۰٫۲ درصد برساند؛ بنابراین بهبود حاصل بین:

$$70.2 - 64 = 6.2$$

تا

$$70.2 - 60 = 10.2$$

واحد درصد بوده است. در مجموعه ۵۰۰ نمونه‌ای، این مقدار معادل تقریباً ۳۱ تا ۵۱ پاسخ صحیح بیشتر

است.

این افزایش دقت با افزایش هزینه محاسباتی همراه بوده است. مصرف توکن از حدود ۰٫۶۴ میلیون به ۱٫۶۵ میلیون رسید؛ یعنی:

$$\frac{1.65}{0.64} \approx 2.57$$

برابر. بنابراین روش پیشنهادی یک مصالحه میان دقت و هزینه استنتاج ایجاد می‌کند. با این حال، زمان متوسط پاسخ به هر نمونه افزایش پیدا نکرد و حتی از حدود ۴۱ به ۳۴ ثانیه کاهش یافت. این نتیجه به معنای سریع‌تر بودن ذاتی مسیریاب نیست؛ بررسی خروجی‌های پاسخ مستقیم نشان داد که مدل در برخی نمونه‌ها برخلاف دستور، وارد تولیدهای طولانی می‌شد و زمان خط پایه را افزایش می‌داد. در نتیجه، هزینه اصلی روش پیشنهادی در این آزمایش بیشتر به مصرف توکن و تعداد فراخوانی‌های مدل مربوط بود تا زمان اجرا.

با استفاده از انتخاب تطبیقی روش‌های پرامپت‌دهی، عملکرد Gemma 4 26B-A4B به‌طور محسوسی بهبود یافت و به دقتی نزدیک به مدل بزرگ‌تر Gemma 4 31B رسید.

در نتیجه، با وجود دقت توسعه‌ای بیشتر در سطح موضوع، Domain-level routing به‌عنوان انتخاب محافظه‌کارانه‌تر و قابل‌اتکاتر برای سامانه نهایی انتخاب شد.

۴-۹- جمع‌بندی

نتایج این فصل نشان داد که عملکرد مدل‌های زبانی-بصری را نمی‌توان تنها بر اساس اندازه یا نوع معماری آن‌ها پیش‌بینی کرد و تفاوت عملکرد، به ویژگی‌های مدل و ماهیت مسئله وابسته است. همچنین بررسی روش‌های مختلف پرامپت‌دهی نشان داد که هیچ روش واحدی برای همه مدل‌ها و همه مسائل بهترین نیست و افزایش پیچیدگی پرامپت، استفاده از مراحل بیشتر یا افزودن نمونه‌های استدلالی لزوماً به افزایش دقت منجر نمی‌شود.

تحلیل حوزه‌های علمی، نوع ورودی بصری و برچسب‌گذاری خطاها نیز نشان داد که اثر یک روش می‌تواند در بخش‌های مختلف مجموعه داده و برای مدل‌های مختلف تغییر کند؛ از این رو، ارزیابی صرف بر اساس دقت کلی نمی‌تواند رفتار مدل را به‌طور کامل توضیح دهد. تحلیل خطا مشخص کرد که یک روش ممکن است یک نوع خطا را کاهش دهد و هم‌زمان نوع دیگری را افزایش دهد.

در نهایت، این یافته‌ها مبنای استفاده از انتخاب تطبیقی روش پرامپت‌دهی قرار گرفت. انتخاب پرامپت بر اساس حوزه مسئله در ارزیابی ۵۰۰ نمونه‌ای، دقت Gemma 4 26B-A4B را از حدود ۶۰ تا ۶۴ درصد در حالت پاسخ مستقیم به ۷۰٫۲ درصد رساند. این نتیجه نشان می‌دهد انتخاب روش متناسب با ویژگی مسئله می‌تواند نسبت به استفاده از یک پرامپت ثابت، روش مؤثرتری برای بهبود عملکرد مدل باشد.

فصل پنجم

نتیجه‌گیری و پیشنهادات

۵-۱- نتیجه‌گیری

هدف اصلی این پژوهش، بررسی عملکرد مدل‌های زبانی-بصری در مسائل دانشگاهی چندوجهی و مطالعه این موضوع بود که آیا می‌توان بدون تغییر وزن‌های مدل و صرفاً از طریق تغییر نحوه ارائه مسئله، عملکرد آن‌ها را بهبود داد یا خیر. برای پاسخ به این پرسش، مسئله تنها از دید دقت نهایی بررسی نشد، بلکه تلاش شد سه جنبه مکمل در کنار یکدیگر مطالعه شوند: نخست، توانایی اولیه مدل‌های مختلف در حل مسائل دانشگاهی چندرشته‌ای؛ دوم، میزان و جهت تأثیر روش‌های مختلف پرامپت‌دهی؛ و سوم، نوع خطاهایی که در اثر این روش‌ها اصلاح یا ایجاد می‌شوند. این رویکرد امکان داد اثر پرامپت‌دهی نه صرفاً به‌صورت یک تغییر عددی در دقت، بلکه به‌عنوان تغییری در رفتار حل مسئله مدل بررسی شود.

برای این منظور، از مجموعه داده MMU-Pro استفاده شد که مسائل آن به ترکیبی از ادراک بصری، دانش تخصصی و استدلال نیاز دارند. یک زیرمجموعه ثابت شامل ۳۰۰ نمونه از ۶ حوزه و ۳۰ موضوع تشکیل شد و مجموعه‌ای از مدل‌های زبانی-بصری با اندازه‌ها و معماری‌های متفاوت در شرایط کنترل‌شده مورد ارزیابی قرار گرفتند.

نتایج خط پایه نشان دادند که اختلاف قابل‌توجهی میان عملکرد مدل‌ها وجود دارد. Gemma 4 31B با دقت ۷۰٫۱۳ درصد بالاترین نتیجه را در میان ارزیابی‌های کامل ثبت کرد و پس از آن Gemma 4 26B، Qwen3.8-27B و Qwen3.5-9B قرار گرفتند. در مقابل، InternVL3.5-8B و Nemotron عملکرد پایین‌تری داشتند. این نتایج نشان دادند که تعداد پارامتر یا نوع کلی معماری به‌تنهایی نمی‌تواند عملکرد مدل را پیش‌بینی کند. برای مثال، برخی مدل‌های کوچک‌تر توانستند از مدل‌هایی با تعداد پارامتر بیشتر عملکرد بهتری داشته باشند. بنابراین کیفیت آموزش چندوجهی، معماری بخش بصری، نحوه ترکیب اطلاعات متنی و تصویری و رفتار مدل در زمان استنتاج نیز نقش تعیین‌کننده‌ای دارند.

تحلیل عملکرد بر اساس حوزه، موضوع، دشواری و نوع تصویر نیز نشان داد که رفتار مدل‌ها یکنواخت

نیست. افزایش دشواری تقریباً در تمام مدل‌ها با کاهش دقت همراه بود، این کاهش در مدل‌های کوچک‌تر در برخی موارد شدیدتر بود. همچنین رتبه نسبی مدل‌ها در حوزه‌های مختلف تغییر می‌کرد. این نتیجه نشان می‌دهد دقت کلی به‌تنهایی برای توصیف توانایی یک مدل چندوجهی کافی نیست و ارزیابی باید بر اساس ویژگی‌های مختلف مسئله نیز انجام شود.

در مرحله بعد، روش‌های مختلف پرامپت‌دهی شامل زنجیره استدلال، برنامه‌ریزی و حل، گراف صحنه، تولید دانش و چند روش چندنمونه‌ای بررسی شدند. مهم‌ترین نتیجه این بخش آن بود که هیچ روش پرامپت‌دهی واحدی در تمام مدل‌ها موجب بهبود نشد.

گراف صحنه تنها روشی بود که در تمام مدل‌های مورد بررسی موجب کاهش دقت شد. بررسی مراحل میانی نشان داد دو نوع مشکل در این روش وجود دارد: در برخی نمونه‌ها اطلاعات تصویر در خود گراف به اشتباه استخراج می‌شد و در برخی دیگر گراف صحیح بود اما مدل در استفاده از آن دچار خطا می‌شد. بنابراین اضافه کردن یک مرحله میانی لزوماً باعث بهبود عملکرد نمی‌شود و در صورت غیرقابل اعتماد بودن آن مرحله، حتی می‌تواند یک منبع خطای جدید ایجاد کند.

نتایج روش‌های چندنمونه‌ای نیز نشان داد که صرف ارائه مثال‌های حل‌شده تضمین‌کننده بهبود نیست. انتخاب تصادفی نمونه‌ها تقریباً هیچ سود پایداری نداشت. انتخاب نمونه‌های مشابه برای Gemma و Qwen3.5-9B مفید بود، اما در Nemotron و InternVL باعث افت شد. همچنین افزودن زنجیره استدلال نمونه‌های مشابه یا انتخاب نمونه‌هایی با استدلال طولانی‌تر در اغلب مدل‌ها نتیجه بهتری ایجاد نکرد. بنابراین شباهت بیشتر یا استدلال طولانی‌تر الزاماً به معنای نمونه‌نمایشی مناسب‌تر نیست.

از نظر هزینه نیز روش‌های پیچیده‌تر همیشه توجیه‌پذیر نبودند. بسیاری از روش‌های چندمرحله‌ای و چندنمونه‌ای مصرف توکن و طول ورودی را چند برابر کردند، در حالی که افزایش دقت بسیار محدود بود یا حتی عملکرد کاهش یافت. در نتیجه، برای انتخاب یک روش پرامپت‌دهی باید دقت، هزینه محاسباتی، پایداری تولید پاسخ و تعداد پاسخ‌های ناقص به‌صورت هم‌زمان در نظر گرفته شوند.

یکی از یافته‌های جانبی اما مهم پژوهش، مشاهده رفتار تکرارشونده در برخی مدل‌های خانواده Qwen بود Qwen3.8-27B. در تعداد قابل توجهی از نمونه‌ها وارد چرخه‌ای از بازیابی و بازتولید استدلال می‌شد و پیش از رسیدن به پاسخ نهایی به محدودیت طول خروجی می‌رسید. رفتار مشابهی با شدت کمتر در Qwen3.5-9B نیز مشاهده شد. نکته قابل توجه آن است که روش برنامه‌ریزی و حل در Qwen3.5-9B علاوه بر افزایش دقت، تعداد پاسخ‌های ناقص را از ۲۷ مورد به ۵ مورد کاهش داد. بنابراین اثر یک روش پرامپتی ممکن است صرفاً به افزایش توان حل مسئله محدود نباشد و در برخی مدل‌ها به کنترل بهتر فرایند تولید نیز کمک کند.

برای درک دقیق‌تر علت تغییر پاسخ‌ها، پژوهش تنها به دقت متکی نماند و تحلیل نوع خطا نیز انجام شد. ابتدا امکان استفاده از مدل‌های چندوجهی به‌عنوان داور خودکار بررسی شد. اگرچه Gemma 4 31B عملکرد

بهتری نسبت به مدل critic مورد آزمایش داشت، دقت ۶۵٫۳۳ درصدی آن برای استفاده به عنوان مرجع نهایی کافی نبود. به همین دلیل، تحلیل نهایی خطا به صورت انسانی و با استفاده از دو ارزیاب مستقل انجام شد. خطاها در سه گروه ادراکی، دانشی و استدلالی دسته‌بندی شدند.

تحلیل انسانی نشان داد که تأثیر پرامپت‌ها تنها در مقدار دقت خلاصه نمی‌شود، بلکه می‌تواند نوع خطای مدل را نیز تغییر دهد. در Gemma 4 26B، روش‌های مبتنی بر نمونه در بسیاری از موارد موجب کاهش خطاهای دانشی یا ادراکی شدند، در حالی که اثر آن‌ها بر خطاهای استدلالی محدودتر بود. در InternVL الگوی متفاوتی مشاهده شد؛ بیشتر روش‌ها توانستند بخشی از خطاهای استدلالی را کاهش دهند، اما هم‌زمان خطاهای دانشی افزایش یافتند. بنابراین یک روش ممکن است یک ضعف مدل را کاهش دهد، اما در مقابل نوع دیگری از خطا را افزایش دهد.

این نتایج نشان می‌دهند که یک پرامپت واحد الزاماً یک قابلیت یکسان را در مدل‌های مختلف تقویت نمی‌کند. برای مثال، نمونه‌های مشابه در Gemma بیشتر به بهبود استفاده از دانش کمک کردند، در حالی که در InternVL همین روش‌ها در بسیاری از موارد باعث افزایش خطاهای دانشی شدند. از این رو، اثر پرامپت حاصل تعامل میان ویژگی‌های مدل، نوع مسئله و نحوه ارائه اطلاعات است.

بنابراین پرامپت‌دهی را نباید تنها به عنوان ابزاری برای «کاهش تعداد خطا» در نظر گرفت؛ پرامپت می‌تواند توزیع و منشأ خطاهای مدل را تغییر دهد.

در مجموع، نتیجه اصلی پژوهش آن است که پرامپت‌دهی می‌تواند عملکرد مدل‌های زبانی-بصری را بهبود دهد، اما این تأثیر وابسته به مدل و مسئله است. در نتیجه، استفاده از یک پرامپت ثابت برای تمام مدل‌ها و تمام مسائل روش مناسبی نیست. یافته‌های حوزه‌ای نیز این نتیجه را تقویت کردند؛ برخی روش‌ها در حوزه‌هایی مانند فناوری و مهندسی عملکرد مناسبی داشتند، در حالی که همان روش‌ها در حوزه‌های دیگر سودی ایجاد نکردند.

بر همین اساس، در بخش پایانی پروژه ایده استفاده از یک روش تطبیقی برای انتخاب پرامپت شکل گرفت و طراحی شد که ابتدا حوزه علمی سؤال را تشخیص داده و سپس بر اساس نتایج حاصل از مجموعه توسعه، روش مناسب را انتخاب می‌کند. برای تشخیص حوزه نیز یک طبقه‌بند چندوجهی مبتنی بر Qwen3-VL-2B طراحی و با روش QLoRA تنظیم شد. همچنین یک مجموعه مستقل ۵۰۰ نمونه‌ای برای ارزیابی این سیاست در نظر گرفته شد. که در نهایت این روش منجر به بیش از ۵ درصد افزایش دقت در مدل Gemma 4 26B شد. هرچند مصرف توکن در این روش بیش از ۲ برابر افزایش یافت اما زمان متوسط اجرا به علت کاهش پاسخ‌های طولانی مدل کاهش یافت.

در نهایت، پژوهش حاضر نشان می‌دهد که در ارزیابی مدل‌های زبانی-بصری نباید صرفاً به دقت نهایی توجه کرد. اندازه مدل، پیچیدگی پرامپت، طول استدلال یا شباهت نمونه‌ها هیچ‌کدام به تنهایی تضمین‌کننده

عملکرد بهتر نیستند. بررسی هم‌زمان دقت، هزینه، پایداری تولید و نوع خطا تصویر دقیق‌تری از رفتار واقعی مدل ارائه می‌دهد و می‌تواند مبنای مناسب‌تری برای طراحی سامانه‌های چندوجهی قابل اعتماد باشد.

۲-۵- محدودیت‌ها

مهم‌ترین محدودیت پژوهش، هزینه بالای اجرای مدل‌های چندوجهی بود. به همین دلیل، آزمایش‌های اصلی روی زیرمجموعه ۳۰۰ نمونه‌ای MMMU-Pro انجام شدند و امکان اجرای تمام ترکیب‌های مدل و پرامپت روی کل مجموعه وجود نداشت.

همچنین شرایط اجرای مدل‌ها کاملاً یکسان نبود. برخی مدل‌ها از طریق API و برخی به‌صورت محلی و با کم‌دقت‌سازی چهار بیتی اجرا شدند Qwen3-VL-30B-A3B. نیز به دلیل زمان استنتاج بسیار بالا تنها روی بخشی از نمونه‌ها اجرا شد و نتیجه آن قابل مقایسه مستقیم با نتایج کامل سایر مدل‌ها نیست.

یکی دیگر از محدودیت‌های پژوهش به فرایند تحلیل انسانی خطا مربوط است. در این پژوهش، دو ارزیاب مسائل متعلق به حوزه‌های علمی مختلف را بر اساس یک دستورالعمل مشترک بررسی کردند و با توجه به تخصصی بودن برخی مسائل MMMU-Pro، ممکن است در همه حوزه‌ها دانش تخصصی یکسانی نداشته باشند. همچنین به دلیل زمان بر بودن داوری دستی، تحلیل نوع خطا تنها برای دو مدل و برای نمونه‌هایی انجام شد که وضعیت پاسخ آن‌ها نسبت به خط پایه تغییر کرده بود. در نتیجه، تنها بخش محدودی از کل خروجی‌های تولیدشده امکان تحلیل خطای دقیق انسانی داشت و نتایج این بخش را نمی‌توان بدون بررسی بیشتر به تمام مدل‌ها و همه نمونه‌های مجموعه تعمیم داد.

۲-۳- پیشنهادات برای ادامه پژوهش

با توجه به نتایج و محدودیت‌های پژوهش حاضر، چند مسیر برای توسعه این کار در پژوهش‌های آینده قابل پیشنهاد است.

نخست، می‌توان تعداد نمونه‌های مورد استفاده در آزمایش‌ها را افزایش داد یا آزمایش‌های اصلی را بر روی کل مجموعه MMMU-Pro اجرا کرد. افزایش حجم داده می‌تواند برآورد قابل اطمینان‌تری از اثر هر روش پرامپت‌دهی در سطح موضوع فراهم کند. در پژوهش حاضر، به دلیل محدود بودن تعداد نمونه‌های هر موضوع، انتخاب تطبیقی پرامپت در سطح حوزه پایداری در نظر گرفته شد؛ اما با افزایش داده‌ها می‌توان سیاست انتخاب پرامپت را در سطح ۳۰ موضوع نیز بررسی کرد. در حالت گسترده‌تر، می‌توان با استفاده از نتایج حاصل از اجرای روش‌های مختلف روی تعداد بیشتری از داده‌ها، مدلی را به‌طور اختصاصی برای انتخاب مناسب‌ترین روش پرامپت برای هر سؤال تنظیم دقیق کرد.

دوم، افزایش تعداد و تنوع مدل‌های مورد ارزیابی می‌تواند امکان استخراج الگوهای عمومی‌تر درباره تأثیر روش‌های پرامپت‌دهی را فراهم کند. در این پژوهش مدل‌هایی از چند خانواده و مقیاس مختلف بررسی شدند،

اما افزودن مدل‌های بیشتر، به‌ویژه مدل‌های بزرگ تجاری، می‌تواند مشخص کند که آیا الگوهای مشاهده‌شده در مدل‌های مورد مطالعه به خانواده‌های دیگر نیز تعمیم‌پذیر هستند یا خیر. چنین آزمایشی می‌تواند به درک بهتر رابطه میان ظرفیت مدل و میزان بهره‌مندی آن از روش‌های مختلف پرامپت‌دهی کمک کند.

مسیر مهم دیگر، بررسی دقیق‌تر نحوه آموزش مدل‌ها و داده‌های مورد استفاده در فرایند آموزش آن‌ها است. نتایج پژوهش نشان داد که مدل‌هایی با اندازه یا حتی ساختار معماری نسبتاً مشابه می‌توانند در برابر یک پرامپت رفتار متفاوتی داشته باشند. در پژوهش‌های آینده می‌توان بررسی کرد که آیا این تفاوت‌ها با نوع داده‌های پیش‌آموزش، داده‌های تنظیم دستور، آموزش چندوجهی، روش‌های تقویت استدلال یا سایر مراحل آموزش هر مدل ارتباط دارند. چنین تحلیلی می‌تواند به توضیح دقیق‌تر علت حساسیت متفاوت مدل‌ها به روش‌های پرامپت‌دهی کمک کند.

در زمینه تحلیل خطا نیز می‌توان فرایند داوری انسانی را تخصصی‌تر کرد. در پژوهش حاضر، دو ارزیاب مجموعه‌ای از مسائل متعلق به حوزه‌های علمی مختلف را بر اساس یک دستورالعمل مشترک بررسی کردند. در ادامه می‌توان برای داوری هر حوزه از متخصص همان حوزه استفاده کرد. این رویکرد به‌ویژه در تفکیک خطاهای دانشی از خطاهای استدلالی می‌تواند موجب افزایش قابلیت اعتماد تحلیل شود.

همچنین می‌توان دامنه روش‌های پرامپت‌دهی مورد آزمایش را توسعه داد. پژوهش حاضر چند گروه متفاوت شامل زنجیره استدلال، برنامه‌ریزی، بازنمایی ساختاریافته، تولید دانش و روش‌های چندمنونه‌ای را بررسی کرد؛ با این حال، روش‌های پرامپت‌دهی چندوجهی به‌سرعت در حال توسعه هستند. بررسی تعداد بیشتری از روش‌ها، به‌خصوص روش‌های جدیدتر، می‌تواند مشخص کند آیا روش‌هایی وجود دارند که نسبت به روش‌های بررسی‌شده عملکرد پایدارتر و تعمیم‌پذیرتری در مدل‌ها و حوزه‌های مختلف داشته باشند.

در نهایت، یکی از مسیرهای کاربردی ادامه پژوهش می‌تواند توسعه یک محیط ارزیابی یکپارچه برای مدل‌های زبانی-بصری باشد. در مرحله نخست، چنین محیطی می‌تواند امکان اجرای مدل‌های مختلف با مجموعه‌ای ثابت از روش‌های پرامپت‌دهی بر روی MMMU-Pro و مقایسه خودکار دقت، هزینه، پایداری تولید و سایر معیارها را فراهم کند. در مرحله گسترده‌تر، این چارچوب می‌تواند از چندین مجموعه داده چندوجهی پشتیبانی کند. در این صورت، امکان بررسی هم‌زمان تعامل میان مدل، روش پرامپت‌دهی و مجموعه داده فراهم می‌شود و می‌توان مشخص کرد که آیا یک الگوی مشاهده‌شده مختص MMMU-Pro است یا در بنچمارک‌های چندوجهی دیگر نیز تکرار می‌شود.

در نهایت، توسعه یک داور چندوجهی قابل اعتماد برای تشخیص نوع خطا می‌تواند امکان تحلیل خروجی‌های بسیار بیشتری را فراهم کند. چنین سامانه‌ای می‌تواند مشخص کند هر روش پرامپت‌دهی دقیقاً کدام نوع ضعف را کاهش داده و چه نوع خطای جدیدی ایجاد کرده است و در نتیجه، زمینه را برای انتخاب هوشمندتر و تطبیقی‌تر روش حل مسئله فراهم سازد.

1. al, J.-B.A.e., *Flamingo: A Visual Language Model for Few-Shot Learning*. Advances in Neural Information Processing Systems (NeurIPS), 2022.
2. J. Li, D. Li, S. Savarese, and S. Hoi, "BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models," in *Proc. 40th International Conference on Machine Learning (ICML)*, vol. 202, pp. 19730–19742, 2023
3. Tianyi Xiong, X.W., Dong Guo, Qinghao Ye, Haoqi Fan, Quanquan Gu, Heng Huang, Chunyuan Li, *LLaVA-Critic: Learning to Evaluate Multimodal Models*, in *EEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025.
4. al, A.V.e., *Attention Is All You Need*, in *Advances in Neural Information Processing Systems*. 2017.
5. al, A.D.e., *An Image Is Worth 16×16 Words: Transformers for Image Recognition at Scale*, in *International Conference on Learning Representations (ICLR)*,. 2021.
6. N. Shazeer et al., *Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer*, in *International Conference on Learning Representations (ICLR)*. 2017.
7. T. Kojima, S.S.G., M. Reid, Y. Matsuo, and Y. Iwasawa, *Language Models are Zero-Shot Reasoners*, in *Advances in Neural Information Processing Systems*. 2022.
8. al., X.Y.e., *MMMU: A Massive Multi-discipline Multimodal Understanding and Reasoning Benchmark for Expert AG*, in *IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*. 2024.
9. al, T.B.B.e., *Language Models are Few-Shot Learners*, in *Advances in Neural Information Processing Systems*. 2020.
10. L. Wang, W.X., Y. Lan, Z. Hu, Y. Lan, R. K.-W. Lee, and E.-P. Lim, *Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models*, in *Annual Meeting of the Association for Computational Linguistics (ACL)*. 2023.
11. C. Mitra, B.H., T. Darrell, and R. Herzig, *Compositional Chain-of-Thought Prompting for Large Multimodal Models*, in *IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*. 2024.
12. Y. Shi, Y.X., M. Guo, L. Lu, M. Huang, J. Wang, Z. Zhu, B. Xu, and Z. Huang,, *MMError: A Benchmark for Erroneous Reasoning in Vision-Language Models*, in *64th Annual Meeting of the Association for Computational Linguistics*. 2026.
13. al, L.Z.e., *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*, in *Advances in Neural Information Processing Systems*. 2023.
14. S. Lee, S.K., S. Park, G. Kim, and M. Seo, *Prometheus-Vision: Vision-Language Model as a Judge for Fine-Grained Evaluation*, in *Findings of the Association for Computational Linguistics: ACL*. 2024.
15. al, X.Y.e., *MMMU-Pro: A More Robust Multi-discipline Multimodal Understanding Benchmark*, in *Annual Meeting of the Association for Computational Linguistics (ACL)*. 2025.
16. al., G.T.e., *Gemma 4 Technical Report*. 2026, arXiv preprint arXiv:2607.02770.
17. al., W.W.e., *InternVL3.5: Advancing Open-Source Multimodal Models in Versatility, Reasoning, and Efficiency*. 2025, arXiv preprint arXiv:2508.18265.
18. al., N.e., *Nemotron 3 Nano Omni: Efficient and Open Multimodal Intelligence*. 2026, arXiv preprint arXiv:2604.24954.

19. Team, Q., *Qwen3.8-27B*. 2026, Hugging Face.
20. Team, Q., *Qwen3.5: Towards Native Multimodal Agents*. 2026.
21. al, S.B.e., *Qwen3-VL Technical Report*. 2025.
22. L. Qin, Q.C., H. Fei, Z. Chen, M. Li, and W. Che, *What Factors Affect Multi-Modal In-Context Learning? An In-Depth Exploration*, in *Neural Information Processing System*. 2024.
23. J. Liu, A.L., X. Lu, S. Welleck, P. West, R. Le Bras, Y. Choi, and H. Hajishirzi, *Generated Knowledge Prompting for Commonsense Reasoning*. 2022, ACL.
24. J. Wei, X.W., D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. H. Chi, Q. V. Le, and D. Zhou., *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*, in *Advances in Neural Information Processing Systems*. 2022.
25. . Bertini Baldassini, M.S., M. Cord, L. Soulier, and B. Piwowarski, *What Makes Multimodal In-Context Learning Work?*, in *Computer Vision and Pattern Recognition Workshops (CVPRW)*. 2024.
26. Y. Fu, H.P., A. Sabharwal, P. Clark, and T. Khot., *Complexity-Based Prompting for Multi-Step Reasoning*, in *International Conference on Learning Representations (ICLR)*. 2023.
27. Xueqing Wu, Y.D., Bingxuan Li, Pan Lu, Da Yin, Kai-Wei Chang, Nanyun Peng, *VISCO: Benchmarking Fine-Grained Critique and Correction Towards Self-Improvement in Visual Reasoning*, in *IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*. 2025.
28. Holtzman, i.D.A.P.A. and L. Zettlemoyer, *QLoRA: Efficient Finetuning of Quantized LLMs*, in *NeurIPs*. 2023.
29. Allen-Zhu, E.H.Y.S.P.W.Z. and Y.L.S.W.L.W.W. Chen, *LORA: LOW-RANK ADAPTATION OF LARGE LANGUAGE MODELS*, in *nternational Conference on Learning Representations*. 2022.

پیوست ۱: لیست برنامه‌ها

تمام کدهای مربوط به پیاده‌سازی، آموزش و ارزیابی مدل‌ها به همراه مثال‌های کاربردی و مستندات کامل در مخزن گیت‌هاب پروژه در دسترس است. برای هر روش، راهنمای استفاده و اسکریپت‌های لازم به صورت مجزا ارائه شده‌اند.

<https://github.com/OpenEduVLM/Evaluation-of-VLMs-Based-on-Various-Prompting-Approaches-in-MMMU-pro>